STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 1

Данные, описательная статистика и визуализация

Какие числа и какие графики нужны, чтобы честно описать набор данных

Тема 1 по силлабусу · неделя 1 (занятия 1 и 2) · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- определять шкалу измерения переменной и понимать, какие статистики для неё допустимы;
- вычислять вручную среднее, медиану и моду и выбирать подходящую меру центра;
- вычислять размах, дисперсию, стандартное отклонение и коэффициент вариации и истолковывать их в единицах измерения;
- находить квартили, межквартильный размах и пятичисловую сводку;
- строить частотную таблицу, гистограмму, диаграмму размаха и диаграмму рассеяния и правильно их читать;
- применять правило $1.5 \times \text{IQR}$ для поиска выбросов и честно сообщать, что с ними сделано;
- отличать честный график от обманчивого.

1 Зачем нужна статистика и как работать с конспектом

Статистика — это наука о том, как делать обоснованные выводы из данных, когда результат неопределён. Банк решает, выдавать ли кредит; сеть кофеен решает, где открыть новый филиал; министерство сообщает «средний доход домохозяйства». Во всех трёх случаях за решением стоят числа, и вопрос всегда один: *что эти числа действительно говорят, а что не говорят?*

Курс состоит из четырёх частей, и вся лекция этой недели нужна как словарь для остальных трёх.

Недели 1–2	**Описать**	Что содержится в данных и насколько вероятен тот или иной исход?
Недели 3–7	**Смоделировать**	Распределения вероятностей, математическое ожидание, центральная предельная теорема.
Недели 9–11	**Сделать вывод**	Доверительные интервалы, проверка гипотез, p-значения.
Недели 12–15	**Предсказать**	Регрессия и различие между корреляцией и причинностью.

Как пользоваться конспектом. Читайте раздел целиком, затем закройте текст и пересчитайте разобранный пример вручную, не подглядывая. Только после этого переходите к задачам в конце лекции. Английские термины приведены в таблицах не случайно: основные учебники курса (Newbold, OpenStax) изданы на английском. Правило семестра: **каждое число, которое мы вычисляем,**

мы должны уметь объяснить одним предложением.

СОГЛАШЕНИЯ ЭТОГО КУРСА

Десятичные дроби записываются через точку (35.75, а не 35,75): так их выводят калькулятор, Excel и R. Ответ без единиц измерения ответом не считается: «35.75» ничего не значит, «35.75 млн сум в месяц на филиал» значит.

2 Данные и шкалы измерения

2.1 Единица наблюдения, переменная, совокупность и выборка

ОСНОВНЫЕ ПОНЯТИЯ

Единица наблюдения — объект, о котором собираются данные (кофейня, клиент, регион, месяц). **Переменная** — характеристика единицы, которая может принимать разные значения (выручка, возраст, регион). **Генеральная совокупность** — все единицы, о которых мы хотим сделать вывод; её размер обозначается N. **Выборка** — та часть совокупности, которую мы реально измерили; её размер обозначается n.

В статистике принято различать *параметры* совокупности и *статистики* выборки. Параметры обозначают греческими буквами (μ — среднее совокупности, σ — её стандартное отклонение), а выборочные статистики — латинскими ($\bar{x}$, s). Формулы часто совпадают, меняется только буква, и она подсказывает читателю: вы измерили всех или только часть. Почему это важно, мы поймём в неделях 7 и 9.

2.2 Четыре шкалы измерения

Не всякое число в таблице является числом в математическом смысле. Шкала, в которой измерена переменная, определяет, какие вычисления с ней осмысленны.

Шкала	Что она означает	Пример	Допустимая мера центра
Номинальная	Только названия, порядка нет	Регион, отрасль, название банка	Мода
Порядковая	Есть порядок, расстояния между значениями не равны	Кредитный рейтинг, оценка удовлетворённости 1–5	Мода, медиана
Интервальная	Расстояния равны, истинного нуля нет	Температура в °C, календарный год	Мода, медиана, среднее
Отношений (ratio)	Расстояния равны и есть истинный ноль	Выручка, цена, отработанные часы	Все три; а также осмысленны отношения («вдвое больше»)

ТИПИЧНАЯ ОШИБКА

Число, записанное в таблице, ещё не количественная переменная. Почтовый индекс 100084 — номинальная переменная: его среднее не имеет смысла. То же верно для номера сотрудника и кода региона. Проверочный вопрос: «Имеет ли смысл сложить два таких значения?»

Оценки по шкале Лайкерта («1 — совсем не согласен, …, 5 — полностью согласен») формально порядковые. На практике по ним нередко считают среднее, но это допущение, и о нём нужно говорить вслух.

Количественные переменные делятся ещё на *дискретные* (результат счёта: число клиентов за день, 0, 1, 2, …) и *непрерывные* (результат измерения: выручка, вес, время ожидания).

2.3 Три формы данных

- **Поперечные данные (cross-section)**: много единиц в один момент времени. Пример: выручка 40 кофеен в сентябре 2026 года. Эту форму мы предполагаем в неделях 1–11.
- **Временной ряд (time series)**: одна единица в много моментов. Пример: ежемесячная инфляция в Узбекистане за 2015–2026 годы. Порядок наблюдений важен, поэтому наблюдения не независимы.
- **Панельные данные (panel)**: много единиц и много периодов. Пример: все 14 регионов, каждый год за десять лет. Это основной объект курса эконометрики ECMT301.

3 Рабочий пример: двенадцать кофеен

Весь материал лекции мы иллюстрируем одними и теми же данными. Это месячная выручка двенадцати филиалов одной сети кофеен в Ташкенте за август 2026 года, в миллионах сум. Данные уже упорядочены по возрастанию; филиал 12 расположен в торговом центре.

Номер	1	2	3	4	5	6	7	8	9	10	11	12
Выручка x_i	18	22	25	27	28	30	30	33	36	40	44	**96**

Здесь $n = 12$, сумма $\sum x_i = 429$, наименьшее значение 18, наибольшее 96, шкала отношений. Единица наблюдения — филиал, переменная — месячная выручка.

4 Меры центра

Мера центра отвечает на вопрос: «какое одно число лучше всего описывает типичное значение?» Таких чисел три, и они отвечают на этот вопрос по-разному.

4.1 Среднее арифметическое

ВЫБОРОЧНОЕ СРЕДНЕЕ

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i. \tag{4.1}$$

Для совокупности та же формула даёт μ, где суммирование идёт по всем N единицам.

ПРИМЕР 1. СРЕДНЯЯ ВЫРУЧКА ФИЛИАЛА

$\bar{x} = \dfrac{429}{12} = 35.75$ млн сум на филиал в месяц.

Среднее — это *точка равновесия* данных: если представить значения как грузы на линейке, среднее — та точка, в которой линейка уравновешена. Это записывается точным свойством:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = \sum x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0. \tag{4.2}$$

Отклонения по одну сторону от среднего в точности компенсируют отклонения по другую. В наших данных отклонение филиала 12 равно $96 - 35.75 = +60.25$, а отклонения остальных одиннадцати филиалов в сумме дают -60.25: одно большое значение уравновешивает все остальные, и именно поэтому оно так сильно тянет среднее.

4.2 Медиана

МЕДИАНА

Значение, которое делит упорядоченный ряд пополам: половина наблюдений не больше него, половина не меньше. Алгоритм:

1. упорядочить значения по возрастанию;
2. найти позицию $(n+1)/2$;
3. если n нечётно, медиана — значение в этой позиции; если n чётно, медиана — среднее двух значений, стоящих по обе стороны от позиции.

ПРИМЕР 2. МЕДИАНА ВЫРУЧКИ

При $n = 12$ позиция равна $(12+1)/2 = 6.5$ — между шестым и седьмым значениями. Оба равны 30, поэтому $\text{Me} = (30 + 30)/2 = 30.0$ млн сум. Половина филиалов зарабатывает меньше 30 млн, половина больше. Медиана не учитывает, *насколько* больше, и именно поэтому филиал 12 её не сдвигает.

4.3 Мода

> **МОДА**
>
> Наиболее часто встречающееся значение. Для непрерывных данных говорят о модальном интервале — самом высоком столбце гистограммы. Мод может быть несколько, а может не быть вовсе.

В наших данных значение 30 встречается дважды, остальные по одному разу, поэтому $\text{Мо} = 30$. Мода — единственная мера центра, допустимая для номинальных данных: «самый частый регион клиентов».

4.4 Взвешенное среднее

Если значения имеют разную важность (вес), обычное среднее вводит в заблуждение.

$$\bar{x}_w = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i}. \tag{4.3}$$

ПРИМЕР 3. СРЕДНЯЯ ЦЕНА БАТОНА

Три магазина продали за неделю 200, 500 и 300 батонов по цене 4 000, 4 500 и 5 000 сум. Простое среднее цен равно $4\,500$, но оно игнорирует объёмы продаж. Взвешенное среднее с весами-количествами:

$$\bar{x}_w = \frac{200 \cdot 4000 + 500 \cdot 4500 + 300 \cdot 5000}{200 + 500 + 300} = \frac{4\,550\,000}{1\,000} = 4\,550 \text{ сум}.$$

Это реальная средняя цена, которую заплатил покупатель.

4.5 Выброс и выбор меры центра

Что произойдёт, если исключить филиал 12 из торгового центра?

	Среднее	Медиана	Мода
Все 12 филиалов	35.75	30.0	30
Без филиала 12 ($n = 11$)	30.27	30.0	30
Изменение	-5.48	**0.0**	**0**

Одно наблюдение из двенадцати сдвинуло среднее на 5.48 млн сум (15% от его значения), а медиана не изменилась. Статистика, которая почти не реагирует на экстремальные значения, называется **устойчивой (робастной)**. Медиана устойчива, среднее нет. Ни то ни другое не «неправильно», но сообщать среднее 35.75 значило бы описывать сеть, к которой ни один из остальных одиннадцати филиалов не относится.

Что взять	Когда
Среднее	Распределение примерно симметрично и нужно складывать или прогнозировать итоги (общая выручка $= n\bar{x}$).
Медиана	Данные асимметричны или содержат выбросы: доходы, цены на жильё, время ожидания.
Мода	Переменная категориальна или нужен самый частый вариант.

ТИПИЧНАЯ ОШИБКА

Среднее не обязано походить на какое-либо реальное наблюдение: 35.75 — выручка ни одного из двенадцати филиалов. «Средний человек» часто не существует.

5 Меры разброса

Одного числа центра мало. Рассмотрим две лавки с одинаковой средней недельной выручкой 30 млн сум:

	Недельные продажи	s
Лавка A	29, 30, 30, 31, 30	0.71
Лавка B	5, 55, 12, 48, 30	21.78

У лавки A штат и запасы планируются сами собой; у лавки B каждая неделя — азартная игра. Среднее и медиана у них одинаковые, разница только в разбросе.

5.1 Размах

$$R = x_{\max} - x_{\min} = 96 - 18 = 78.$$

Размах использует только два наблюдения, поэтому одна ошибка в данных разрушает его. Его стоит указывать, но полагаться на него нельзя.

5.2 Дисперсия и стандартное отклонение

Естественная идея: усреднить отклонения от среднего. Но по формуле (4.2) они в сумме дают ноль. Чтобы отклонения не гасили друг друга, их возводят в квадрат.

ВЫБОРОЧНАЯ ДИСПЕРСИЯ И СТАНДАРТНОЕ ОТКЛОНЕНИЕ

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}, \qquad s = \sqrt{s^2}. \tag{5.1}$$

Дисперсия измеряется в квадратах единиц данных («млн сум в квадрате») и является промежуточным шагом, а не результатом. Стандартное отклонение s возвращается в исходные единицы. Читают его так: типичный филиал отстоит от среднего примерно на s.

ПРИМЕР 4. ПЯТЬ ФИЛИАЛОВ ВРУЧНУЮ

Число клиентов за день в одном филиале: 20, 25, 30, 35, 40. Среднее $\bar{x} = 150/5 = 30$.

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
20	-10	100
25	-5	25
30	0	0
35	$+5$	25
40	$+10$	100
$\sum = 150$	$\sum = 0$ (всегда)	$\sum = 250$

$$s^2 = \frac{250}{5-1} = 62.5, \quad s = \sqrt{62.5} = 7.91 \text{ клиента.}$$

Для двенадцати кофеен считать по определению неудобно, поэтому пользуются рабочей формулой, эквивалентной (5.1):

$$s^2 = \frac{\sum x_i^2 - n\bar{x}^2}{n-1}. \tag{5.2}$$

Здесь $\sum x_i^2 = 19\,883$, $n\bar{x}^2 = 12 \cdot 35.75^2 = 15\,336.75$, поэтому

$$s^2 = \frac{19\,883 - 15\,336.75}{11} = \frac{4\,546.25}{11} = 413.30, \qquad s = \sqrt{413.30} = 20.33 \text{ млн сум.}$$

Почему в знаменателе $n-1$, а не n

Среднее $\bar{x}$ вычислено по той же выборке, поэтому данные в среднем ближе к $\bar{x}$, чем к неизвестному μ, и деление на n систематически занижает разброс. Кроме того, по формуле (4.2) отклонения от $\bar{x}$ связаны одним условием (их сумма нулевая), так что свободно варьируются только $n-1$ из них. Число $n-1$ называется *числом степеней свободы*.

ПРИМЕР 5. ПРОВЕРКА НА КРОШЕЧНОЙ СОВОКУПНОСТИ

Пусть совокупность состоит из двух значений 0 и 2, равновероятных. Её дисперсия $\sigma^2 = 1$. Возьмём выборки по два значения с возвращением: их четыре, и они равновероятны.

Выборка	$\bar{x}$	$\sum(x_i - \bar{x})^2$
(0, 0)	0	0
(0, 2)	1	2
(2, 0)	1	2
(2, 2)	2	0

Среднее значение $\sum(x_i - \bar{x})^2$ по четырём выборкам равно $(0+2+2+0)/4 = 1$. Деление на $n-1 = 1$ даёт в среднем 1 — верно, равно σ^2. Деление на $n = 2$ даёт в среднем 0.5 — вдвое занижено. Вывод: с $n-1$ выборочная дисперсия является *несмещённой* оценкой. Подробнее об этом в неделе 9.

5.3 Коэффициент вариации

Стандартные отклонения нельзя сравнивать, если данные измерены в разных единицах или на разных масштабах. Для этого служит относительная мера:

$$CV = \frac{s}{\bar{x}} \times 100\%. \tag{5.3}$$

ПРИМЕР 6. КОФЕЙНИ И БАНК

Сеть кофеен: $\bar{x} = 35.75$, $s = 20.33$, поэтому $CV = 56.9\%$. Отделения банка: $\bar{x} = 1\,240$ млн, $s = 186$ млн, поэтому $CV = 15.0\%$. Стандартное отклонение банка в абсолютных деньгах в девять раз больше, но относительно собственного масштаба его отделения гораздо более однородны.

ТИПИЧНАЯ ОШИБКА

Никогда не сравнивайте два стандартных отклонения, измеренных в разных единицах: сравнивайте коэффициенты вариации. Но CV имеет смысл только для переменных со шкалой отношений и положительным средним (например, для температуры в °C он бессмыслен: нуль условный).

5.4 Что происходит с мерами при преобразовании данных

Пусть каждое значение пересчитано по правилу $y_i = a + b\,x_i$ (смена единиц, надбавка, индексация).

ЛИНЕЙНОЕ ПРЕОБРАЗОВАНИЕ

$$\bar{y} = a + b\bar{x}, \qquad \mathrm{Me}_y = a + b\,\mathrm{Me}_x, \qquad s_y = |b|\,s_x.$$

Прибавление константы a сдвигает центр, но **не меняет разброс**. Умножение на b растягивает и центр, и разброс. Коэффициент вариации не меняется при умножении ($a = 0$), но меняется при сдвиге.

6 Позиционные меры: квартили и пятичисловая сводка

Квартили делят упорядоченные данные на четыре равные по числу наблюдений части. Q_2 — это медиана; Q_1 — медиана нижней половины; Q_3 — медиана верхней половины. Если n нечётно, сама медиана ни в одну половину не входит.

ПРИМЕР 7. КВАРТИЛИ КОФЕЕН

Нижняя половина: 18, 22, 25, 27, 28, 30. Её медиана $Q_1 = (25 + 27)/2 = 26$.
Верхняя половина: 30, 33, 36, 40, 44, 96. Её медиана $Q_3 = (36 + 40)/2 = 38$.
Межквартильный размах $\mathrm{IQR} = Q_3 - Q_1 = 38 - 26 = 12$.

ПЯТИЧИСЛОВАЯ СВОДКА

$$x_{\min},\quad Q_1,\quad \text{Me},\quad Q_3,\quad x_{\max} \qquad \Rightarrow \qquad 18,\ 26,\ 30,\ 38,\ 96.$$

Средние 50% филиалов зарабатывают от 26 до 38 млн сум, то есть лежат в полосе шириной 12 млн; сравните с размахом 78. Уже по этим числам видно, что одно наблюдение ведёт себя необычно.

КВАРТИЛИ В ПРОГРАММАХ

Существует несколько способов вычисления квартилей, и они дают немного разные числа. Для наших данных: метод половин (в этом курсе) даёт $Q_1 = 26$ и $Q_3 = 38$; функции Excel `QUARTILE.INC` и R по умолчанию дают 26.5 и 37; функция `QUARTILE.EXC` дает 25.5 и 39. При больших n разница мала. На бумаге в этом курсе считаем методом половин, а при работе с программой всегда указываем, какой метод использован.

Процентиль обобщает квартиль: p-й процентиль — значение, левее которого лежит $p\%$ наблюдений. Квартили — это 25-й, 50-й и 75-й процентили.

7 Частотные распределения и гистограммы

Когда наблюдений много, список значений нечитаем, и данные группируют по интервалам.

Алгоритм построения. (1) Выберите ширину интервала. (2) Задайте интервалы, закрытые слева: $[15, 25)$ включает 15, но не 25. (3) Подсчитайте число наблюдений в каждом интервале — *частоту* f. (4) Найдите *относительную частоту* f/n и *накопленную частоту*.

Интервал, млн сум	Частота f	Отн. частота	Накопленная
[15, 25)	2	16.7%	2
[25, 35)	6	50.0%	8
[35, 45)	3	25.0%	11
[45, 55)	0	0.0%	11
[55, 65)	0	0.0%	11
[65, 75)	0	0.0%	11
[75, 85)	0	0.0%	11
[85, 95)	0	0.0%	11
[95, 105)	1	8.3%	12
Сумма	**12**	**100%**	

Контроль: частоты в сумме дают $n = 12$, относительные частоты дают 100%.

Гистограмма — график этой таблицы: по горизонтали интервалы, по вертикали частоты. Столбцы касаются друг друга, потому что выручка непрерывна. Главное решение при построении — ширина интервала.

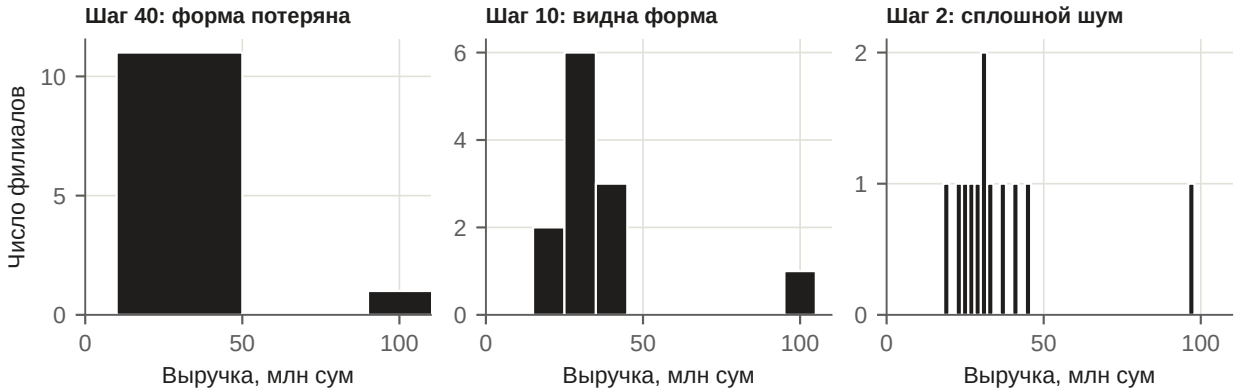


Рис. 1. Одни и те же 12 значений при разной ширине интервала. Слишком широкие интервалы стирают форму, слишком узкие оставляют шум.

Практическое правило: начинайте с числа интервалов, близкого к $\sqrt{n}$ или к $1 + \log_2 n$ (правило Стёрджеса), и корректируйте, пока форма не перестанет меняться; ширину интервала всегда указывайте в подписи. Для $n = 12$ любая гистограмма грубая, правило хорошо работает начиная с $n \approx 50$. На рисунке при шаге 10 хорошо видны ядро (25–45 млн), длинный правый хвост и пустой разрыв перед одиноким столбцом 96.

8 Форма распределения

Форма описывает симметрию и хвосты. Три основные ситуации:

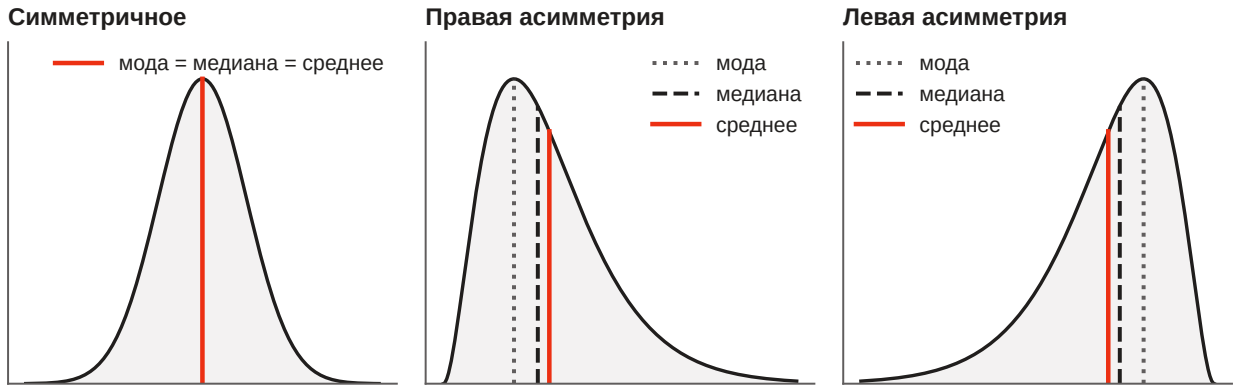


Рис. 2. Положение моды, медианы и среднего для трёх форм распределения.

- **Симметричное**: среднее = медиана = мода. Рост людей, ошибки измерения, хорошо составленный экзамен.
- **Правая асимметрия** (длинный хвост вправо): мода < медиана < среднее. Доходы, цены на жильё, время ожидания, наша сеть кофеен.
- **Левая асимметрия** (длинный хвост влево): среднее < медиана < мода. Возраст смерти, баллы за лёгкий тест.

Среднее «тянется» за хвостом, медиана почти не двигается — так порядок моды, медианы и среднего подсказывает форму.

Асимметрию можно измерить числом. Простейший коэффициент (второй коэффициент Пирсона):

$$Sk = \frac{3(\bar{x} - \text{Me})}{s}. \tag{8.1}$$

Для кофеен: $Sk = \dfrac{3(35.75 - 30)}{20.33} = \dfrac{17.25}{20.33} = +0.85$. Ориентиры: $Sk \approx 0$ — симметрия; от 0.5 до 1 — умеренная правая асимметрия; больше 1 — сильная; отрицательное значение — хвост влево. Программы обычно выдают другой коэффициент (через третий момент); знак у них тот же.

9 Диаграмма размаха и выбросы

Диаграмма размаха («ящик с усами», box plot) рисует пятичисловую сводку: ящик от Q_1 до Q_3, линия внутри ящика — медиана (не среднее), «усы» тянутся до самых далёких наблюдений, не выходящих за границы выбросов, а наблюдения за границами отмечаются отдельными точками.

ПРАВИЛО $1.5 \times$ IQR

$$\text{нижняя граница} = Q_1 - 1.5 \cdot \text{IQR}, \tag{9.1}$$

$$\text{верхняя граница} = Q_3 + 1.5 \cdot \text{IQR}. \tag{9.2}$$

Наблюдение за границами называется **выбросом**.

ПРИМЕР 8. ЯВЛЯЕТСЯ ЛИ ФИЛИАЛ 12 ВЫБРОСОМ?

IQR $= 12$, поэтому $1.5 \cdot 12 = 18$. Границы: $26 - 18 =$ **8** и $38 + 18 =$ **56**. Так как $96 > 56$, филиал 12 — выброс. Усы идут до 18 и 44 — самых крайних значений внутри границ.

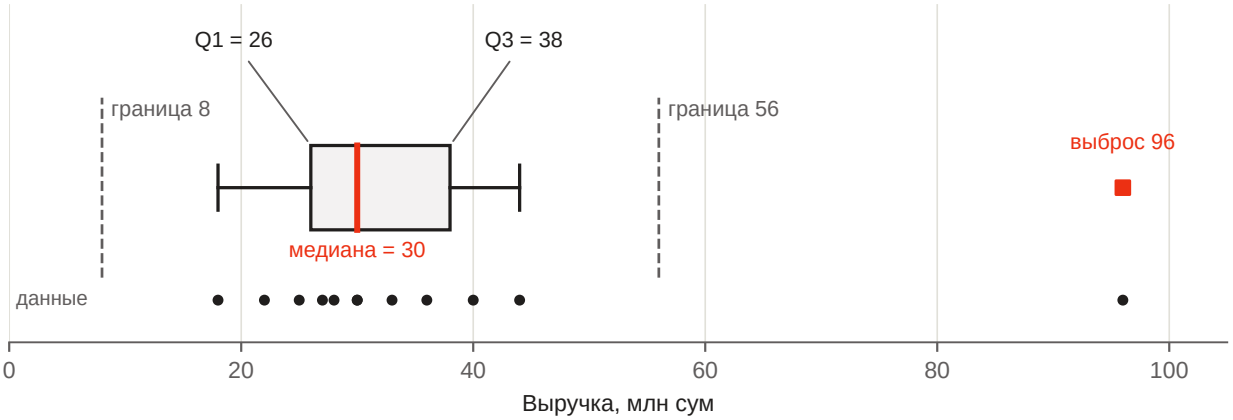


Рис. 3. Диаграмма размаха выручки двенадцати филиалов. Ниже ящика показаны сами данные.

Выброс — это определение, а не мнение. Правило даёт одинаковый ответ любому аналитику.

9.1 Что делать с выбросом

Правило лишь *помечает* наблюдение для проверки; оно не говорит, что наблюдение ошибочно. Есть четыре допустимых действия:

1. **Проверить**: не опечатка ли (96 вместо 9.6)? Не другая ли единица измерения?
2. **Объяснить**: филиал в торговом центре — другая бизнес-модель.
3. **Сообщить оба результата**: «среднее 35.75 млн по всем филиалам; 30.27 млн без филиала в торговом центре».
4. **Сменить статистику**: использовать медиану и IQR.

> **НЕДОПУСТИМОЕ ДЕЙСТВИЕ**
>
> Тихо удалить выброс, чтобы данные «выглядели лучше». Любое исключение наблюдений обязательно фиксируется в тексте отчёта.

9.2 Пропущенные значения

Выброс — не единственная проблема данных. Если у 3 из 40 кофеен выручка не указана, нужно сообщить, сколько наблюдений действительно использовано, и подумать, *почему* значения пропали. Если пропуски случайны, потеря небольшая. Если же пропущены в основном убыточные точки, потому что они не сдали отчёт, то среднее по оставшимся систематически завышено. Правило то же, что для выбросов: ничего не скрывать и описывать, как обработаны пропуски.

10 Диаграмма рассеяния

Когда у каждой единицы две числовые переменные, их связь показывает **диаграмма рассеяния** (scatter plot): одна точка на единицу. Объясняющую переменную откладывают по горизонтали, объясняемую по вертикали. Добавим к нашим данным расходы филиалов на рекламу x (млн сум) и выручку y (млн сум):

Филиал	1	2	3	4	5	6	7	8	9	10	11	12
Реклама x	1.0	1.4	1.6	1.9	2.0	2.3	2.4	2.8	3.1	3.5	3.9	5.6
Выручка y	18	22	25	27	28	30	30	33	36	40	44	96

(Данные учебные.)

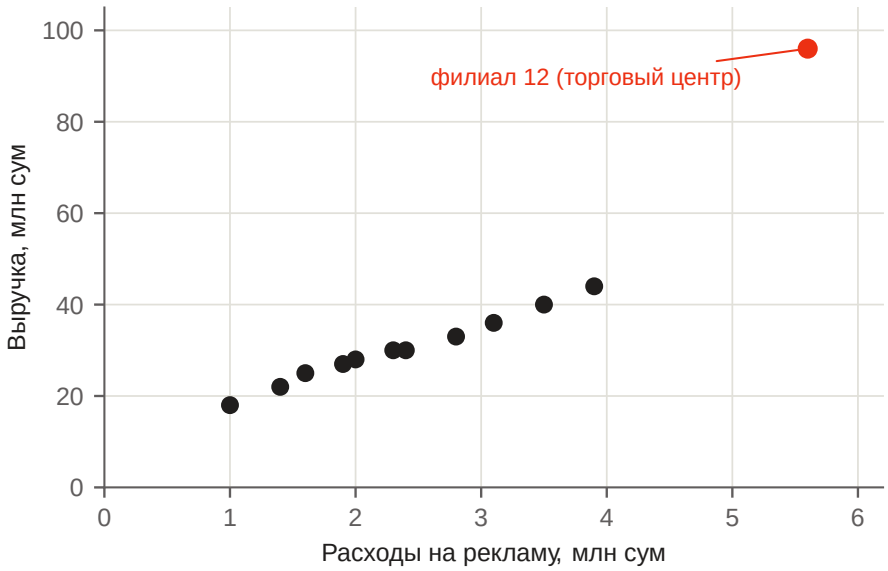


Рис. 4. Расходы на рекламу и выручка двенадцати филиалов.

Описывая диаграмму рассеяния, говорят о четырёх вещах:

- **Направление**: положительное (с ростом рекламы растёт выручка).
- **Форма**: примерно линейная. Линейная модель оправдана только для прямолинейной полосы точек.
- **Сила**: сильная. В неделе 6 мы научимся измерять её числом — коэффициентом корреляции r (для этих данных $r = 0.93$, а без филиала 12 — $r = 0.996$).
- **Необычные точки**: филиал 12.

> **ТИПИЧНАЯ ОШИБКА**
>
> Совместный рост рекламы и выручки не доказывает, что реклама *вызывает* рост выручки: возможно, просто крупные филиалы больше тратят на рекламу. Различие корреляции и причинности мы разберём в неделе 13.

11 Как выбрать график и не обмануть читателя

Что у вас есть	Какой график	Почему
Одна категориальная переменная	Столбчатая диаграмма	Длину сравнивать легче всего.
Одна числовая переменная	Гистограмма или ящик с усами	Форма и выбросы видны сразу.
Одна числовая, несколько групп	Ящики с усами рядом	Центр, разброс и форма групп в одном кадре.
Две числовые переменные	Диаграмма рассеяния	Видна совместная картина, а не две отдельные сводки.
Числовая переменная во времени	Линейный график	Порядок важен, линия его передаёт.
Части целого	Всё равно столбчатая диаграмма	Углы читаются плохо; круговая диаграмма непригодна при числе долей больше трёх.

11.1 Честные числа, нечестная картинка

- **Обрезанная ось.** Если ось y начинается не с нуля, небольшой рост выглядит обрывом. Столбчатые диаграммы обязаны начинаться с нуля.
- **Площадь вместо длины.** Удвоение высоты и ширины даёт четырёхкратную «краску» при удвоенном значении.
- **Круговая диаграмма с семью долями.** Никто не сможет упорядочить доли по размеру; отсортированная столбчатая диаграмма отвечает на этот вопрос сразу.
- **Две оси на одном графике.** Подбирая масштабы, можно заставить линии пересечься и создать несуществующую связь.

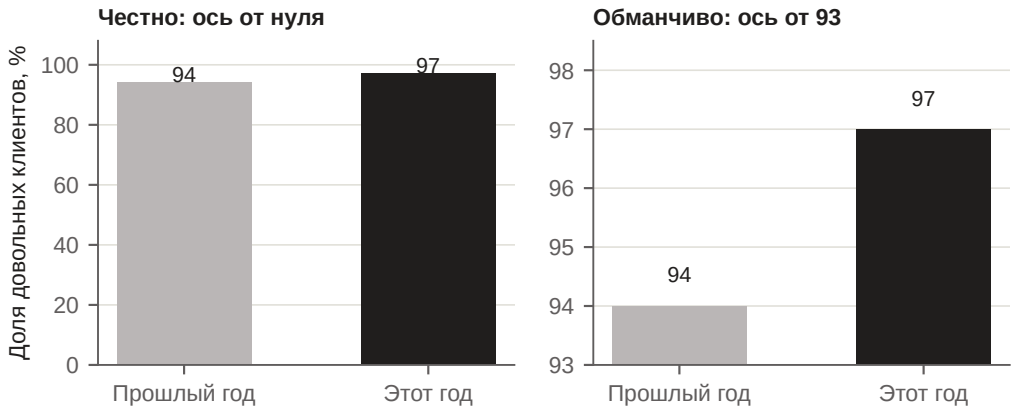


Рис. 5. Одни и те же данные: доля довольных клиентов выросла с 94% до 97%, то есть на 3.2%. На правом графике столбец этого года выглядит в четыре раза выше прошлогоднего.

Подпись к графику сообщает вывод, а не тип графика. Плохо: «Диаграмма размаха выручки». Хорошо: «Один филиал в торговом центре зарабатывает в три раза больше медианы».

12 Ключевые термины

Термин	*English*	Смысл
Генеральная совокупность	*Population*	все единицы, о которых делается вывод (N, μ, σ)
Выборка	*Sample*	измеренная часть совокупности (n, $\bar{x}$, s)
Шкала измерения	*Scale of measurement*	номинальная, порядковая, интервальная, отношений
Среднее	*Mean*	сумма, делённая на число значений; точка равновесия
Медиана	*Median*	середина упорядоченного ряда
Мода	*Mode*	самое частое значение
Устойчивый	*Robust*	почти не зависящий от экстремальных значений
Размах	*Range*	$x_{\max} - x_{\min}$
Дисперсия	*Variance*	сумма квадратов отклонений, делённая на $n-1$
Стандартное (среднеквадратическое) отклонение, СКО	*Standard deviation*	корень из дисперсии, в единицах данных
Коэффициент вариации	*Coefficient of variation*	$s/\bar{x}$, безразмерная относительная мера разброса
Квартиль	*Quartile*	точки, делящие данные на четверти
Межквартильный размах	*IQR*	$Q_3 - Q_1$
Асимметрия	*Skewness*	несимметричность распределения
Ящик с усами	*Box plot*	график пятичисловой сводки
Выброс, граница выброса	*Outlier, fence*	значение за границами $Q_1 - 1.5\text{IQR}$, $Q_3 + 1.5\text{IQR}$
Диаграмма рассеяния	*Scatter plot*	точки (x_i, y_i) для двух переменных
Гистограмма	*Histogram*	график частот по интервалам

Формулы лекции 1

$$\bar{x} = \frac{1}{n}\sum x_i, \qquad \bar{x}_w = \frac{\sum w_i x_i}{\sum w_i}, \qquad \sum (x_i - \bar{x}) = 0,$$

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1} = \frac{\sum x_i^2 - n\bar{x}^2}{n-1}, \qquad s = \sqrt{s^2}, \qquad CV = \frac{s}{\bar{x}} \cdot 100\%,$$

$$R = x_{\max} - x_{\min}, \qquad \text{IQR} = Q_3 - Q_1, \qquad Sk = \frac{3(\bar{x} - \text{Me})}{s},$$

границы выбросов: $Q_1 - 1.5\,\text{IQR}$, $Q_3 + 1.5\,\text{IQR}$,

$y = a + bx \;\Rightarrow\; \bar{y} = a + b\bar{x}, \;\; s_y = |b|\, s_x.$

13 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Для каждой переменной укажите шкалу измерения и какие из мер центра (мода, медиана, среднее) допустимы:

(а) номер сотрудника;
(б) число лет образования;
(в) удовлетворённость сервисом по шкале 1–5;
(г) месячная зарплата в сумах;
(д) регион проживания;
(е) год рождения;
(ж) температура воздуха в °C;
(з) место, занятое в соревновании (1-е, 2-е, …).

Задача 2 [A] Верно или неверно? Кратко обоснуйте.

(а) Медиана не зависит от величины экстремальных значений.
(б) Если среднее больше медианы, распределение, как правило, имеет правую асимметрию.
(в) Сумма отклонений от медианы всегда равна нулю.
(г) Дисперсия может быть отрицательной.
(д) Если все значения умножить на 2, стандартное отклонение удвоится, а коэффициент вариации не изменится.
(е) Линия внутри ящика на диаграмме размаха показывает среднее.

Задача 3 [B] Число доставок курьера за семь дней: 12, 15, 15, 18, 22, 25, 61. Найдите среднее, медиану, моду, размах, дисперсию, стандартное отклонение и коэффициент вариации. Проверьте правилом $1.5 \times \text{IQR}$, есть ли выбросы. Какую меру центра вы опубликовали бы и почему? Ответьте одним предложением.

Задача 4 [B]

(а) Банк выдал три кредита: 50 млн сум под 18%, 30 млн под 22% и 20 млн под 24%. Найдите среднюю процентную ставку по портфелю (простую и взвешенную) и объясните разницу.
(б) Студент получил 85 баллов по курсу в 5 кредитов, 70 баллов по курсу в 4 кредита и 90 баллов по курсу в 3 кредита. Найдите средневзвешенный балл.

Задача 5 [B] Месячная аренда 15 квартир (млн сум): 2.4, 2.6, 2.8, 3.0, 3.1, 3.2, 3.5, 3.6, 3.8, 4.0, 4.2, 4.5, 4.8, 5.0, 9.5.

(а) Найдите пятичисловую сводку и IQR.
(б) Найдите границы выбросов и укажите выбросы.
(в) Опишите диаграмму размаха: где проходят усы?

(г) Сравните среднее и медиану. Что они говорят о форме распределения? Какую меру вы сообщите?

Задача 6 [B] Число заказов в кофейне за 30 дней: 14, 18, 19, 21, 22, 23, 24, 24, 25, 26, 27, 27, 28, 29, 29, 30, 31, 31, 32, 33, 34, 35, 36, 37, 38, 40, 42, 45, 49, 58.

(а) Постройте частотную таблицу с интервалами $[10, 20), [20, 30), \ldots, [50, 60)$: частота, относительная частота, накопленная частота.
(б) В какой доле дней было меньше 30 заказов?
(в) Укажите модальный интервал.
(г) Найдите среднее и медиану по исходным данным и сравните. Что это говорит о форме?

Задача 7 [B]

(а) Средняя зарплата в фирме A равна 2.4 млн сум при стандартном отклонении 0.6 млн, в фирме B — 5.0 млн при стандартном отклонении 1.0 млн. Где зарплаты более однородны?
(б) Доходность акции X: среднее 8%, стандартное отклонение 12%; акции Y: среднее 5%, стандартное отклонение 6%. У какой акции риск на единицу доходности меньше?

Задача 8 [C]

(а) Докажите, что $\sum(x_i - \bar{x}) = 0$.
(б) Зарплаты пяти сотрудников (млн сум): 2.0, 2.5, 3.0, 3.5, 4.0. Найдите $\bar{x}$, s и CV. Затем каждая зарплата повышается на 10% и добавляется надбавка 0.2 млн: $y = 1.1x + 0.2$. Найдите $\bar{y}$, s_y, CV_y и объясните, почему CV изменился.

Задача 9 [C] Месячные доходы 10 домохозяйств (млн сум): 2.1, 2.4, 2.6, 2.8, 3.0, 3.1, 3.4, 3.9, 4.5, 18.2. Министерство сообщает «средний доход 4.6 млн», профсоюз — «типичный доход 3.05 млн». Оба используют одни и те же данные честно.

(а) Проверьте оба числа.
(б) Сколько домохозяйств из десяти имеют доход ниже «среднего»?
(в) Проверьте наличие выбросов.
(г) Каким числом должна пользоваться семья, планирующая бюджет, и почему?

Задача 10 [C] Компания сообщает, что доля довольных клиентов выросла с 94% до 97%. На столбчатой диаграмме ось y начинается с 93%.

(а) На сколько процентных пунктов и на сколько процентов относительно выросла доля?
(б) Во сколько раз столбец этого года визуально выше прошлогоднего?
(в) Как исправить график? Сформулируйте подпись к исправленному графику.

Задача 11 [C] Часы подготовки x и балл y у восьми студентов:
$(1, 45), (2, 52), (3, 58), (4, 61), (5, 70), (6, 74), (7, 79), (8, 60)$.

(а) Нарисуйте диаграмму рассеяния.
(б) Опишите её четырьмя словами: направление, форма, сила, необычные точки.
(в) Что вы сделаете с точкой $(8, 60)$ прежде чем делать выводы?
(г) Можно ли утверждать, что больше часов подготовки *вызывает* более высокий балл?

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 2

Основы теории вероятностей

События, аксиомы Колмогорова, правила сложения и умножения, независимость и комбинаторика

Тема 2 по силлабусу · неделя 2 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- записывать пространство исходов и выражать события как его подмножества;
- формулировать три аксиомы Колмогорова и с их помощью отвергать невозможные утверждения;
- применять правила дополнения, сложения и умножения к деловым данным;
- читать совместные, маргинальные и условные вероятности из таблицы сопряжённости и проверять независимость;
- различать несовместные и независимые события;
- считать число способов с помощью факториалов, перестановок, размещений и сочетаний и применять их для вычисления вероятностей.

1 От описания к вероятности

На прошлой неделе мы описывали данные, которые уже есть: что произошло. Теперь мы переходим к вопросу о том, что *может произойти*. Вероятность — язык, на котором статистика говорит о неопределённости, и от неё зависят все выводы последних недель курса: доверительные интервалы и p-значения (недели 9–13) являются утверждениями о вероятности.

Теория вероятностей строится так же, как геометрия: сначала несколько простых определений и аксиом, затем правила, которые из них вытекают. Освоив эту лекцию, вы сможете проверять любые вычисления вероятностей на согласованность.

2 Случайный эксперимент, пространство исходов, события

ОСНОВНЫЕ ПОНЯТИЯ

Случайный эксперимент — процедура, результат которой заранее неизвестен. **Пространство элементарных исходов** S — множество всех возможных результатов, каждый записан один раз. **Событие** A — любое подмножество S (набор исходов, о которых мы спрашиваем).

ПРИМЕР 1. ОДИН И ДВА КУБИКА

Один кубик: $S = \{1, 2, 3, 4, 5, 6\}$; событие «выпало чётное число» — это подмножество $A = \{2, 4, 6\}$. Два кубика: S состоит из 36 упорядоченных пар (i, j). Событие «сумма равна 7» состоит из шести пар: $(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)$.

1-й \ 2-й	1	2	3	4	5	6
1	2	3	4	5	6	**7**
2	3	4	5	6	**7**	8
3	4	5	6	**7**	8	9
4	5	6	**7**	8	9	10
5	6	**7**	8	9	10	11
6	**7**	8	9	10	11	12

Если все исходы равновозможны, вероятность события равна доле благоприятных исходов:

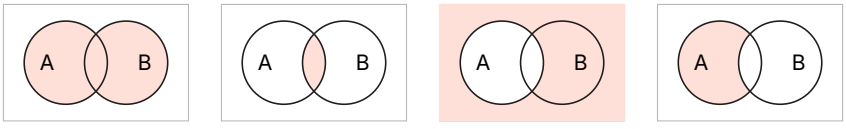
$$P(A) = \frac{\text{число благоприятных исходов}}{\text{общее число исходов}}. \tag{2.1}$$

По таблице: $P(\text{сумма} = 7) = 6/36 = 0.167$; $P(\text{сумма} = 12) = 1/36 = 0.028$; $P(\text{сумма} > 9) = 6/36 = 0.167$; $P(\text{оба чётные}) = 9/36 = 0.250$.

ТИПИЧНАЯ ОШИБКА

Равновозможны 36 упорядоченных пар, но не 11 возможных сумм. Сумма 7 выпадает в шесть раз чаще суммы 12 (рис. 1). Формулу (2.1) можно применять только после проверки, что исходы действительно равновозможны.

2.1 Операции над событиями



$A \cup B$ — A или B (или оба)

$A \cap B$ — A и B вместе

A' — не A

$A \cap B'$ — A, но не B

- **Объединение** $A \cup B$ — произошло A, или B, или оба.
- **Пересечение** $A \cap B$ (пишут также AB) — произошли и A, и B.
- **Дополнение** A' — произошло всё, что не входит в A.
- События **несовместны**, если не могут произойти одновременно: $A \cap B = \emptyset$. Решение по одной заявке на кредит не может быть и «одобрено», и «отклонено».

«Ни A, ни B» записывается как $(A \cup B)' = A' \cap B'$.

3 Аксиомы Колмогорова и источники вероятности

АКСИОМЫ КОЛМОГОРОВА, 1933

1. $0 \le P(A) \le 1$ для любого события A.
2. $P(S) = 1$: достоверное событие имеет вероятность 1.
3. Если A и B несовместны, то $P(A \cup B) = P(A) + P(B)$.

Из этих трёх аксиом вытекает всё остальное. Например, $P(\emptyset) = 0$, а если A является частью B, то $P(A) \le P(B)$. Главное практическое следствие: любое утверждение о вероятностях, нарушающее аксиомы, невозможно. Например, нельзя иметь $P(A) = 0.20$ и $P(A \cap B) = 0.35$, потому что пересечение является частью A и не может быть вероятнее неё.

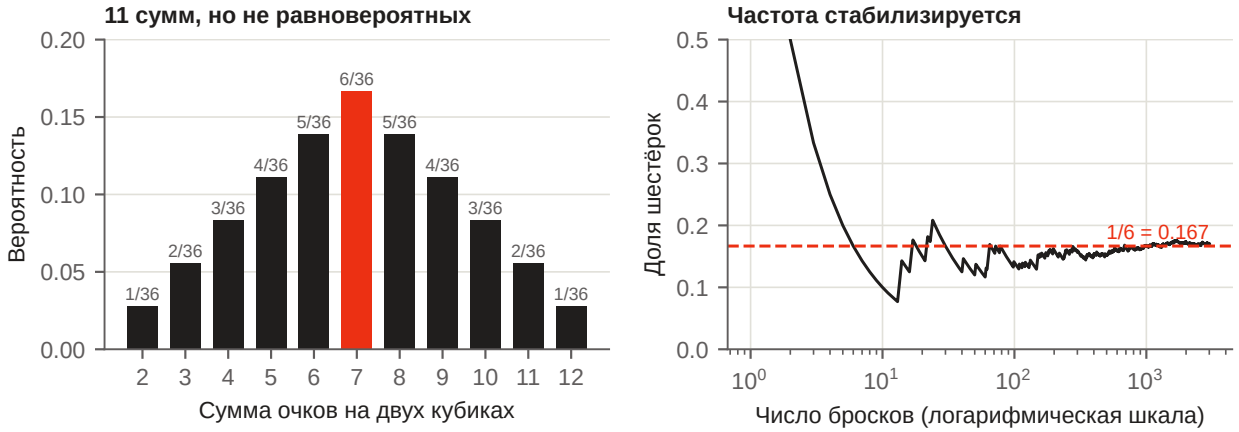


Рис. 1. Слева: сумма двух кубиков, 11 значений неравновероятны. Справа: доля шестёрок при последовательных бросках одного кубика колеблется в начале, но со временем приближается к $1/6$.

3.1 Три источника вероятности

- **Классическая**: $P(A) =$ благоприятные/все; требует равновозможных исходов (кубики, карты, жребий).
- **Частотная**: $P(A) \approx$ число появлений/число испытаний. Пример: из 400 заявок банк одобрил 260, значит $P(\text{одобрение}) \approx 0.65$. Правая часть рис. 1 показывает, почему это работает: чем больше испытаний, тем ближе частота к «истинной» вероятности (закон больших чисел, неделя 7).
- **Субъективная**: взвешенная степень уверенности («70% вероятность снижения ставки»). Она тоже обязана подчиняться аксиомам.

4 Правила дополнения и сложения

ПРАВИЛО ДОПОЛНЕНИЯ

$$P(A') = 1 - P(A). \tag{4.1}$$

Особенно полезно для вопросов «хотя бы один»: проще найти вероятность того, что *не произойдёт ни одного*, и вычесть из 1.

ПРИМЕР 2. КОЛЛ-ЦЕНТР

8% звонков теряются (абонент вешает трубку). Звонки независимы; поступило четыре. Вероятность того, что ни один не потерян, равна $0.92^4 = 0.716$, поэтому

$$P(\text{хотя бы один потерян}) = 1 - 0.92^4 = 1 - 0.716 = \mathbf{0.284}.$$

ПРАВИЛО СЛОЖЕНИЯ

$$P(A \cup B) = P(A) + P(B) - P(A \cap B). \tag{4.2}$$

Вычитание нужно, чтобы не посчитать пересечение дважды. Для несовместных событий $P(A \cap B) = 0$ и остаётся $P(A \cup B) = P(A) + P(B)$.

ПРИМЕР 3. КЛИЕНТЫ БАНКА

Из 200 клиентов банка 120 имеют дебетовую карту (D), 60 — кредитную (C), 30 — обе. Тогда $P(D) = 0.60$, $P(C) = 0.30$, $P(D \cap C) = 0.15$ и

$$P(D \cup C) = 0.60 + 0.30 - 0.15 = \mathbf{0.75}, \qquad P(\text{нет карт}) = 1 - 0.75 = \mathbf{0.25}\ (50 \text{ клиентов}).$$

Если бы мы просто сложили $0.60 + 0.30 = 0.90$, клиентов с двумя картами посчитали бы дважды.

ТИПИЧНАЯ ОШИБКА

Складывать вероятности без вычитания пересечения можно только для несовместных событий. Типичная ошибка: «вероятность дефолта каждого из трёх заёмщиков 5%, значит вероятность, что хотя бы один обанкротится, равна 15%». Это неверно: события не несовместны (дефолтов может быть сразу несколько), и сумма завышает ответ.

5 Таблица сопряжённости: совместные, маргинальные и условные вероятности

Данные о двух категориальных признаках удобно записывать в таблицу сопряжённости. Вот 400 заявок на кредит: T — заявитель из Ташкента, A — заявка одобрена.

	Одобрена (A)	Отклонена (A')	Всего
Ташкент (T)	168	72	240
Другие регионы (T')	92	68	160
Всего	**260**	**140**	**400**

Из одной таблицы читаются три вида вероятностей:

- **Маргинальные** (по итоговым строкам и столбцам): $P(A) = 260/400 = 0.65$; $P(T) = 240/400 = 0.60$.
- **Совместные** (по ячейкам): $P(A \cap T) = 168/400 = 0.42$; $P(A' \cap T') = 68/400 = 0.17$.
- **Условные** (внутри строки или столбца): $P(A \mid T) = 168/240 = 0.70$; $P(A \mid T') = 92/160 = 0.575$.

УСЛОВНАЯ ВЕРОЯТНОСТЬ

$P(A \mid B)$ читается «вероятность A при условии B» и вычисляется внутри B:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(B) > 0. \tag{5.1}$$

В таблице: $P(A \mid T) = \dfrac{168/400}{240/400} = \dfrac{168}{240} = 0.70$. Знаменатель сузился с 400 заявок до 240 ташкентских. Подробно условную вероятность мы изучим на следующей неделе.

6 Правило умножения и независимость

Перепишем (5.1) в виде, удобном для вычислений:

$$P(A \cap B) = P(A) \cdot P(B \mid A). \tag{6.1}$$

«Чтобы произошли оба события, должно произойти первое, а затем второе при условии, что первое произошло».

НЕЗАВИСИМЫЕ СОБЫТИЯ

События A и B **независимы**, если наступление одного не меняет вероятность другого:

$$P(A \cap B) = P(A)\,P(B), \qquad \text{равносильно} \quad P(A \mid B) = P(A). \tag{6.2}$$

ПРИМЕР 4. НЕЗАВИСИМЫ ЛИ РЕГИОН И ОДОБРЕНИЕ?

По таблице $P(A) \cdot P(T) = 0.65 \times 0.60 = 0.39$, а реально $P(A \cap T) = 0.42$. Так как $0.42 \neq 0.39$, события *зависимы*: у ташкентских заявителей одобрение вероятнее (0.70 против общих 0.65).

НЕСОВМЕСТНЫЕ $\neq$ НЕЗАВИСИМЫЕ

Несовместные события не могут произойти вместе: $P(A \cap B) = 0$. Это вопрос «возможно ли оба сразу?». **Независимые** события не несут информации друг о друге: $P(A \cap B) = P(A)P(B)$. Это вопрос «меняет ли одно вероятность другого?». Если $P(A) > 0$, $P(B) > 0$ и события несовместны, они *обязательно зависимы*: узнав, что произошло A, мы точно знаем, что B не произошло.

Для нескольких независимых событий вероятности просто перемножаются: $P(A_1 \cap \cdots \cap A_k) = P(A_1) \cdots P(A_k)$.

ПРИМЕР 5. ТРИ ЗАЁМЩИКА

Вероятность дефолта каждого из трёх независимых заёмщиков равна 0.05. Вероятность того, что никто не обанкротится, $0.95^3 = 0.857$. Поэтому

$$P(\text{хотя бы один дефолт}) = 1 - 0.95^3 = \mathbf{0.143} \quad (\text{а не } 0.15).$$

Наивная сумма $3 \times 0.05 = 0.15$ слегка завышает ответ: вероятность двух и трёх дефолтов сразу посчитана лишний раз. Чем больше заёмщиков или вероятность, тем больше ошибка.

ОШИБКА ИГРОКА

Монета выпала орлом пять раз подряд. Вероятность орла в шестой раз по-прежнему 0.5: монета не помнит прошлых бросков (броски независимы). А вот вероятность шести орлов подряд заранее равна $0.5^6 = 1/64 = 0.0156$. Это два разных вопроса.

7 Комбинаторика: как считать число способов

Формула (2.1) требует уметь считать благоприятные и все исходы. Для этого служит комбинаторика.

7.1 Принцип умножения

ПРИНЦИП УМНОЖЕНИЯ

Если первый выбор можно сделать n_1 способами, после него второй n_2 способами и так далее, то всего способов $n_1 \cdot n_2 \cdots n_k$.

ПРИМЕР 6

Меню из 3 закусок, 4 основных блюд и 2 десертов даёт $3 \cdot 4 \cdot 2 = 24$ различных обеда. Четырёхзначный ПИН-код (цифры могут повторяться): $10^4 = 10\,000$ вариантов; с различными цифрами: $10 \cdot 9 \cdot 8 \cdot 7 = 5\,040$.

7.2 Факториал и перестановки

Факториал: $n! = n \cdot (n-1) \cdots 2 \cdot 1$, по определению $0! = 1$. Число способов выстроить n различных объектов в ряд равно $n!$ (*перестановки*). Пять заявок можно рассмотреть в $5! = 120$ различных порядках.

7.3 Размещения и сочетания

Выбираем r объектов из n различных. Два вопроса: важен ли порядок выбора? Если да, это *размещения*; если нет, *сочетания*.

Размещения и сочетания

Размещения (порядок важен): $$P(n,r) = A_n^r = \frac{n!}{(n-r)!},$$

Сочетания (порядок не важен): $$C(n,r) = \binom{n}{r} = C_n^r = \frac{n!}{r!\,(n-r)!}.$$

Связь: $\binom{n}{r} = P(n,r)/r!$, и $\binom{n}{r} = \binom{n}{n-r}$. Обозначения A_n^r и C_n^r принято использовать в русскоязычных учебниках, $P(n,r)$ и $\binom{n}{r}$ — в английских (Newbold, OpenStax).

ПРИМЕР 7. РАЗМЕЩЕНИЕ ИЛИ СОЧЕТАНИЕ?

Из 10 аналитиков выбираем **президента, вице-президента и казначея**: должности различны, порядок важен, $P(10,3) = 10 \cdot 9 \cdot 8 = 720$. Из 12 сотрудников выбираем **комитет из 4 человек**: порядок не важен, $\binom{12}{4} = \dfrac{12 \cdot 11 \cdot 10 \cdot 9}{4!} = 495$.

7.4 Перестановки с повторяющимися элементами

Если среди n объектов n_1 одного вида, n_2 другого и т. д., число различимых расстановок равно $\dfrac{n!}{n_1!\,n_2! \cdots n_k!}$. Слово «СТАТИСТИКА» (10 букв: С×2, Т×3, А×2, И×2, К×1) можно составить $\dfrac{10!}{2!\,3!\,2!\,2!\,1!} = \dfrac{3\,628\,800}{48} = 75\,600$ способами.

7.5 Вероятность через комбинаторику

ПРИМЕР 8. КОНТРОЛЬ КАЧЕСТВА

В партии 20 изделий, из них 3 бракованных. Контролёр наугад берёт 4 изделия (без возвращения). Все $\binom{20}{4} = 4\,845$ наборов равновозможны.

- Нет брака: выбираем все четыре из 17 годных, $\binom{17}{4} = 2\,380$, поэтому $P = 2\,380/4\,845 = \mathbf{0.491}$.
- Ровно один бракованный: $\binom{3}{1}\binom{17}{3} = 3 \cdot 680 = 2\,040$, $P = 2\,040/4\,845 = \mathbf{0.421}$.
- Хотя бы один бракованный: $1 - 0.491 = \mathbf{0.509}$.

Общая формула: $P = \dfrac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}}$, где N — размер партии, K — число бракованных, n — размер выборки, k — число бракованных в выборке.

ПРИМЕР 9. ЛОТЕРЕЯ «6 ИЗ 45»

Выигрышная комбинация — один из $\binom{45}{6} = 8\,145\,060$ равновозможных наборов. Вероятность выиграть с одним билетом $1/8\,145\,060 \approx 1.2 \cdot 10^{-7}$.

ПРИМЕР 10. ПАРАДОКС ДНЕЙ РОЖДЕНИЯ

Какова вероятность, что в группе из n человек хотя бы у двоих день рождения совпадает? Считаем через дополнение:

$$P = 1 - \frac{365 \cdot 364 \cdots (365 - n + 1)}{365^n}.$$

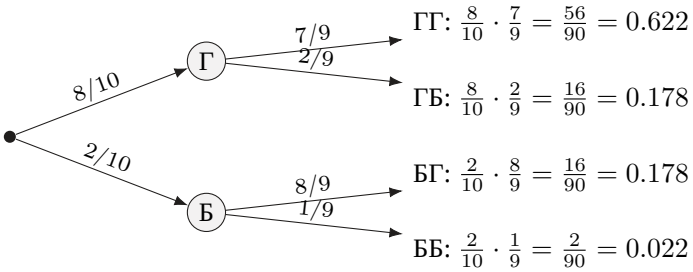
Для $n = 23$ получаем 0.507, для $n = 30$ получаем 0.706. Уже в группе из 23 человек совпадение вероятнее, чем отсутствие, хотя интуиция подсказывает цифры гораздо выше.

8 Дерево вероятностей

Когда события происходят последовательно, вероятности удобно записывать на дереве: вдоль ветви вероятности *перемножаются* (правило (6.1)), вероятности разных листьев *складываются*.

ПРИМЕР 11. ВЫБОР БЕЗ ВОЗВРАЩЕНИЯ

В партии 10 изделий, 2 бракованных (Б), 8 годных (Г). Берём два изделия подряд без возвращения.



Проверка: $56+16+16+2=90$, то есть вероятности листьев в сумме дают 1. Вероятность ровно одного бракованного $=\frac{16}{90}+\frac{16}{90}=\frac{32}{90}=0.356$. Ту же вероятность ББ даёт комбинаторика: $\binom{2}{2}/\binom{10}{2}=1/45=0.022$.

9 Ключевые термины

Термин	*English*	Смысл
Случайный эксперимент	*Random experiment*	процедура с неопределённым результатом
Пространство исходов	*Sample space*	множество всех возможных исходов, S
Событие	*Event*	подмножество S
Объединение	*Union*	$A \cup B$: A или B
Пересечение	*Intersection*	$A \cap B$: A и B вместе
Дополнение	*Complement*	A': не A
Несовместные	*Mutually exclusive*	не могут произойти вместе
Независимые	*Independent*	$P(A \cap B) = P(A)P(B)$
Совместная вероятность	*Joint probability*	$P(A \cap B)$
Маргинальная вероятность	*Marginal probability*	$P(A)$, по итогам таблицы
Условная вероятность	*Conditional probability*	$P(A \mid B)$, «A при условии B»
Факториал	*Factorial*	$n!$
Размещение	*Permutation*	упорядоченный выбор r из n
Сочетание	*Combination*	неупорядоченный выбор r из n

Формулы лекции 2

$$0 \le P(A) \le 1, \quad P(S) = 1, \quad P(A \cup B) = P(A) + P(B) \text{ (несовместные)},$$
$$P(A') = 1 - P(A), \qquad P(A \cup B) = P(A) + P(B) - P(A \cap B),$$
$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(A \cap B) = P(A)P(B \mid A),$$
$$\text{независимость: } P(A \cap B) = P(A)P(B) \iff P(A \mid B) = P(A),$$
$$n!, \qquad P(n,r) = \frac{n!}{(n-r)!}, \qquad C(n,r) = \frac{n!}{r!(n-r)!}, \qquad \frac{n!}{n_1! \cdots n_k!}.$$

10 Задачи для самостоятельного решения

Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] В анкете два вопроса, на каждый можно ответить «да» (Д) или «нет» (Н).

(а) Запишите пространство исходов S.
(б) Запишите событие «хотя бы один ответ «да»». Сколько исходов оно содержит?
(в) Найдите его вероятность, считая все исходы равновозможными.

Задача 2 [A]

(а) $P(\text{опоздание}) = 0.30$. Найдите $P(\text{без опоздания})$.
(б) $P(A) = 0.40$, $P(B) = 0.30$, $P(A \cap B) = 0.15$. Найдите $P(A \cup B)$.
(в) Известно, что $P(A) = 0.20$ и $P(A \cap B) = 0.35$. Что вы можете сказать об этих числах?
(г) Бросают два кубика. Найдите вероятность того, что выпала хотя бы одна шестёрка (двумя способами).

Задача 3 [B] Из 500 фирм 300 экспортируют, 200 импортируют, 120 занимаются и тем и другим. Найдите вероятности того, что случайно выбранная фирма: (а) экспортирует или импортирует; (б) не занимается ни тем ни другим; (в) только экспортирует; (г) только импортирует.

Задача 4 [B] Из 300 студентов 180 учатся по направлению «Финансы» и 120 по направлению «Маркетинг». Пересдачу сдали 90 финансистов и 40 маркетологов.

(а) Составьте таблицу сопряжённости.
(б) Найдите $P(\text{сдал})$, $P(\text{сдал} \mid \text{финансы})$, $P(\text{сдал} \mid \text{маркетинг})$.
(в) Проверьте, независимы ли направление и успешная сдача.

Задача 5 [B] Аналитик утверждает: «вероятность дефолта каждого из трёх заёмщиков равна 0.05, значит вероятность того, что хотя бы один из них обанкротится, равна $3 \times 0.05 = 0.15$». Укажите

две ошибки в этом рассуждении и найдите правильное значение при независимости заёмщиков.

Задача 6 [В] Сколько существует способов:

(а) составить четырёхзначный ПИН-код из различных цифр;
(б) выбрать комитет из 4 человек среди 12 сотрудников;
(в) выбрать президента, вице-президента и казначея среди 10 аналитиков;
(г) переставить буквы слова «ЭКОНОМИКА»?

Задача 7 [В] В партии 30 телефонов, из них 5 неисправных. Для проверки случайно выбирают 3 (без возвращения). Найдите вероятности того, что среди проверенных: (а) нет неисправных; (б) ровно один неисправный; (в) хотя бы один неисправный.

Задача 8 [В] (а) Найдите вероятность того, что среди 25 человек есть хотя бы двое с общим днём рождения (считайте, что в году 365 дней, все даты равновероятны). (б) Выведите формулу и объясните, почему удобнее считать через дополнение. (в) Найдите ответ для группы из 40 человек.

Задача 9 [С] Банк выдал 600 кредитов: 360 наёмным работникам, из которых 18 перестали платить, и 240 предпринимателям, из которых 36 перестали платить.

(а) Составьте таблицу сопряжённости «категория заёмщика $\times$ дефолт».
(б) Найдите $P(\text{дефолт})$, $P(\text{дефолт} \mid \text{предприниматель})$, $P(\text{дефолт} \mid \text{наёмный})$.
(в) Независимы ли категория заёмщика и дефолт?
(г) Найдите $P(\text{предприниматель} \mid \text{дефолт})$ и объясните, чем эта вероятность отличается от $P(\text{дефолт} \mid \text{предприниматель})$.

Задача 10 [С] Для трёх событий $P(A) = 0.50$, $P(B) = 0.40$, $P(C) = 0.30$, $P(A \cap B) = 0.20$, $P(A \cap C) = 0.15$, $P(B \cap C) = 0.10$, $P(A \cap B \cap C) = 0.05$.

(а) Найдите $P(A \cup B \cup C)$ по формуле включений-исключений

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) \\ - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C).$$

(б) Найдите вероятность того, что не произойдёт ни одно из трёх событий.
(в) Объясните, почему тройное пересечение прибавляется в конце.

Задача 11 [С] Известно, что $P(A) = 0.30$ и $P(B) = 0.50$.

(а) Пусть A и B несовместны. Найдите $P(A \cup B)$. Могут ли они быть независимы?
(б) Пусть A и B независимы. Найдите $P(A \cap B)$ и $P(A \cup B)$.
(в) Могут ли события быть одновременно несовместными и независимыми?

Задача 12 [С] Шевалье де Мере в XVII веке считал две ставки равноценными. (а) Какова вероятность выбросить хотя бы одну шестёрку при 4 бросках одного кубика? (б) Какова вероятность хотя бы одной «двойной шестёрки» при 24 бросках двух кубиков? Какая ставка выгоднее? (в) Монета упала орлом 5 раз подряд. Какова вероятность орла при следующем броске и почему не > 0.5?

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 3

Условная вероятность и теорема Байеса

Как обновлять вероятности по новым данным и почему «точный» тест может ошибаться в большинстве случаев

Тема 3 по силлабусу · неделя 3 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- вычислять условную вероятность по определению и по таблице сопряжённости;
- применять формулу полной вероятности и строить дерево вероятностей;
- выводить и применять теорему Байеса, выражая результат через естественные частоты;
- объяснять, почему базовая частота (доля редкого события) определяет результат, и не путать $P(A \mid B)$ с $P(B \mid A)$;
- последовательно обновлять вероятность по нескольким сигналам и понимать, когда сигналы можно считать независимыми;
- принимать решение по порогу, сравнивая ожидаемые потери.

1 Условная вероятность

В лекции 2 мы определили условную вероятность через пересечение. Напомним определение и разберёмся, что оно означает.

УСЛОВНАЯ ВЕРОЯТНОСТЬ

Вероятность события A при условии, что событие B произошло:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(B) > 0. \tag{1.1}$$

Смысл формулы: узнав, что B произошло, мы *сужаем* пространство исходов до B. Знаменателем становится $P(B)$, а в числителе остаются только исходы, лежащие и в A, и в B. Событие, которое стоит после черты, определяет новый знаменатель.

ПРИМЕР 1. МОБИЛЬНОЕ ПРИЛОЖЕНИЕ И ДЕПОЗИТЫ

Из 1 000 клиентов банка 400 пользуются мобильным приложением (M); 250 из них открыли депозит (D). Среди 600 остальных депозит открыли 120.

	Депозит (D)	Нет депозита (D')	Всего
Приложение (M)	250	150	400
Без приложения (M')	120	480	600
Всего	**370**	**630**	**1 000**

$P(D) = 370/1000 = 0.37$. $P(D \mid M) = 250/400 = 0.625$. $P(D \mid M') = 120/600 = 0.20$.

Пользователи приложения открывают депозит втрое чаще. А теперь обратная вероятность: $P(M \mid D) = 250/370 = 0.676$ — это доля пользователей приложения *среди открывших депозит*. Это другое число с другим знаменателем.

$P(A \mid B) \neq P(B \mid A)$

В общем случае $P(A \mid B) \neq P(B \mid A)$. Вероятность того, что у человека с лихорадкой грипп, и вероятность того, что у больного гриппом лихорадка, — разные числа. Перепутать их — самая частая ошибка в работе с вероятностями; вся эта лекция посвящена тому, как переходить от одной вероятности к другой правильно.

Из определения сразу следует правило умножения $P(A \cap B) = P(A)\,P(B \mid A) = P(B)\,P(A \mid B)$ (лекция 2). Два события независимы тогда и только тогда, когда $P(A \mid B) = P(A)$.

2 Формула полной вероятности

Часто событие B можно реализовать несколькими взаимно исключающими путями. Говорят, что события $A_1, \dots, A_k$ образуют *разбиение* пространства исходов, если они попарно несовместны и вместе дают все S ($A_1 \cup \dots \cup A_k = S$).

ФОРМУЛА ПОЛНОЙ ВЕРОЯТНОСТИ

$$P(B) = \sum_{i=1}^{k} P(B \mid A_i)\,P(A_i) = P(B \mid A_1)P(A_1) + \dots + P(B \mid A_k)P(A_k). \qquad (2.1)$$

Вероятность B — это взвешенное среднее условных вероятностей, а весами служат вероятности путей.

ПРИМЕР 2. ТРИ СТАНКА

Деталь произведена на станке A_1 (50% продукции, брак 2%), на A_2 (30%, брак 3%) или на A_3 (20%, брак 5%). Вероятность того, что случайная деталь бракованная (B):

$$P(B) = 0.50 \cdot 0.02 + 0.30 \cdot 0.03 + 0.20 \cdot 0.05 = 0.010 + 0.009 + 0.010 = \mathbf{0.029}.$$

Общий уровень брака 2.9% лежит между 2% и 5%, как и должно быть у взвешенного среднего.

3 Теорема Байеса

Формула полной вероятности идёт «от причин к следствиям»: зная долю брака каждого станка, она даёт общую долю брака. Теорема Байеса решает обратную задачу: *нашли бракованную деталь; какова вероятность, что её произвёл станок A_3?*

ТЕОРЕМА БАЙЕСА

Из двух выражений для $P(A_i \cap B)$ получаем

$$P(A_i \mid B) = \frac{P(B \mid A_i)\,P(A_i)}{P(B)} = \frac{P(B \mid A_i)\,P(A_i)}{\sum_j P(B \mid A_j)\,P(A_j)}. \tag{3.1}$$

Априорная вероятность $P(A_i)$ — до наблюдения B; **апостериорная** $P(A_i \mid B)$ — после. Множитель $P(B \mid A_i)$ называется *правдоподобием*.

Вывод в одну строку: $P(A_i \mid B)\,P(B) = P(A_i \cap B) = P(B \mid A_i)\,P(A_i)$; разделим на $P(B)$ и подставим (2.1).

ПРИМЕР 3. КАКОЙ СТАНОК ВИНОВАТ?

Деталь бракованная. Вероятность того, что она с третьего станка:

$$P(A_3 \mid B) = \frac{0.20 \cdot 0.05}{0.029} = \frac{0.010}{0.029} = \mathbf{0.345}.$$

Аналогично $P(A_1 \mid B) = 0.010/0.029 = 0.345$ и $P(A_2 \mid B) = 0.009/0.029 = 0.310$. Сумма $0.345 + 0.310 + 0.345 = 1$. Хотя станок A_3 даёт всего 20% деталей, из-за высокого брака он ответственен за 34.5% всего брака.

3.1 Главный пример: оповещение системы мониторинга мошенничества

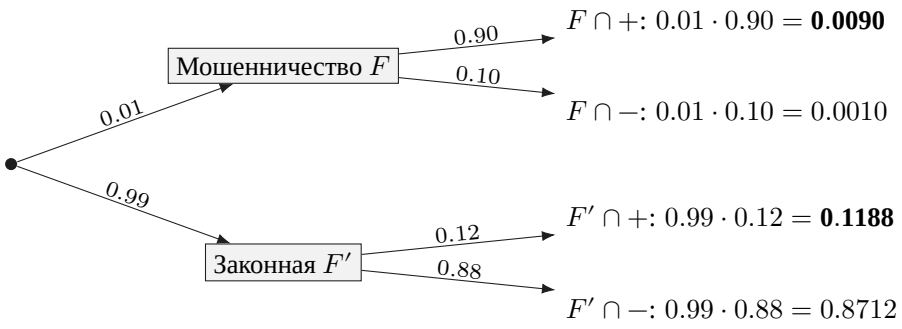
Банк использует систему, которая помечает подозрительные операции. Известно:

- **базовая частота**: 1% операций мошеннические, $P(F) = 0.01$;
- **чувствительность**: система замечает 90% мошеннических операций, $P(+ \mid F) = 0.90$;
- **доля ложных срабатываний**: система ошибочно помечает 12% законных операций, $P(+ \mid F') = 0.12$.

Операция помечена. Какова вероятность, что она действительно мошенническая, $P(F \mid +)$?

Прежде чем считать, оцените на глаз: ближе ли ответ к 7%, 50% или 90%? Большинство людей называет 90%.

Дерево вероятностей.



Оповещение происходит в двух листьях: $P(+) = 0.0090 + 0.1188 = 0.1278$. Тогда

$$P(F \mid +) = \frac{0.0090}{0.0090 + 0.1188} = \frac{0.0090}{0.1278} = \mathbf{0.0704} \approx 7.0\%.$$

Естественные частоты (тот же расчёт без вероятностей, обычно он нагляднее). Возьмём 10 000 операций.

	Помечено	Не помечено	Всего
Мошеннические (1%)	$100 \cdot 0.90 = 90$	10	100
Законные (99%)	$9\,900 \cdot 0.12 = 1\,188$	8 712	9 900
Всего	**1 278**	**8 722**	**10 000**

Из 1 278 помеченных операций реально мошеннические только 90, то есть $90/1\,278 = 7.04\%$. Система ловит 90% мошенников, но почти 93% её сигналов ложные.

БАЗОВАЯ ЧАСТОТА РЕШАЕТ ВСЁ

Мошенничество редко (1%), поэтому законных операций в сто раз больше. Даже небольшая доля ложных срабатываний (12%), применённая к огромной массе законных операций, даёт больше сигналов, чем чувствительность 90%, применённая к малой массе мошенников. Пренебрежение базовой частотой называется *ошибкой базовой частоты* (base rate fallacy).

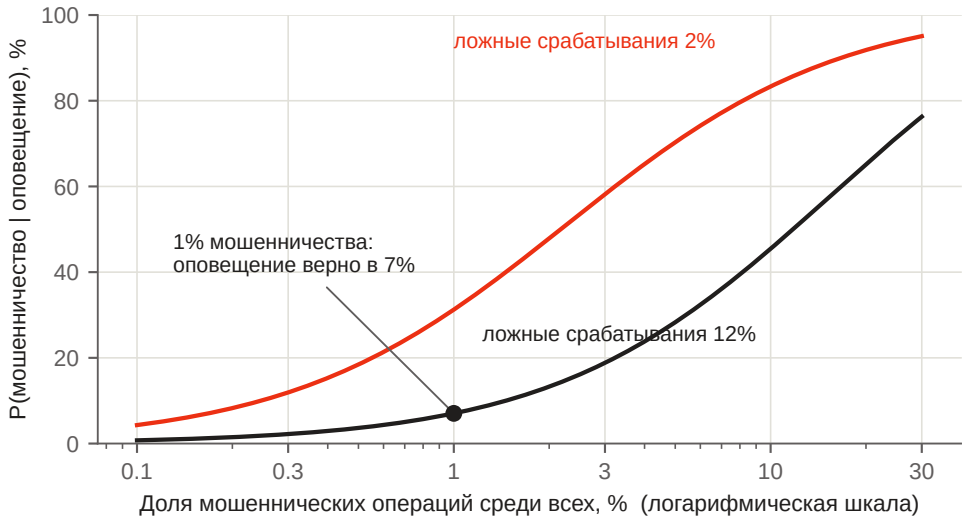


Рис. 1. Вероятность мошенничества после оповещения как функция базовой частоты (чувствительность 90%). При 1% мошенничества и 12% ложных срабатываний оповещение верно лишь в 7% случаев; снижение ложных срабатываний до 2% поднимает ответ до 31%.

Термин	Запись	Смысл
Чувствительность (sensitivity)	$P(+ \mid F)$	доля настоящих случаев, которые тест находит
Специфичность (specificity)	$P(- \mid F') = 1 - P(+ \mid F')$	доля законных операций, которые тест пропускает (здесь 0.88)
Положительная прогностическая ценность	$P(F \mid +)$	доля верных сигналов среди всех сигналов (здесь 0.0704)

3.2 Алгоритм решения задач на формулу Байеса

1. Назовите события и выпишите, *какая именно* условная вероятность запрашивается.
2. Выпишите известные: априорные вероятности и правдоподобия.
3. Постройте дерево (или таблицу из 10 000 объектов) и найдите вероятности листьев.
4. Сложите листья, в которых наступило условие, и разделите нужный лист на эту сумму.
5. Проверьте: апостериорные вероятности по всем гипотезам в сумме дают 1; сравните ответ с априорной вероятностью.

4 Последовательное обновление и форма с шансами

Сегодняшняя апостериорная вероятность становится завтрашней априорной: приходит новое свидетельство, мы снова применяем теорему Байеса. Для таких цепочек удобна запись через *шансы*.

ФОРМА БАЙЕСА ЧЕРЕЗ ШАНСЫ

Шансы события F: $\text{odds}(F) = \dfrac{P(F)}{1-P(F)}$; обратно, $P(F) = \dfrac{\text{odds}}{1+\text{odds}}$. Тогда

$$\underbrace{\frac{P(F \mid +)}{P(F' \mid +)}}_{\text{апостериорные шансы}} = \underbrace{\frac{P(F)}{P(F')}}_{\text{априорные шансы}} \times \underbrace{\frac{P(+ \mid F)}{P(+ \mid F')}}_{LR_+}, \qquad LR_+ = \frac{\text{чувствительность}}{\text{доля ложных срабатываний}}. \tag{4.1}$$

Отношение правдоподобия LR_+ показывает, во сколько раз положительный результат вероятнее при мошенничестве, чем без него.

ПРИМЕР 4. ОДНО И ДВА ОПОВЕЩЕНИЯ

Здесь $LR_+ = 0.90/0.12 = 7.5$. Априорные шансы $0.01/0.99 = 0.0101$.
После одного оповещения: $0.0101 \cdot 7.5 = 0.0758$, откуда $P = 0.0758/1.0758 = 0.0704$.
Ответ совпадает с расчётом выше.
После второго независимого оповещения: $0.0101 \cdot 7.5^2 = 0.568$, откуда $P = 0.568/1.568 =$ **0.362**.
Вывод: два независимых сигнала поднимают вероятность с 7% до 36%, но не до 90%.

ДВОЙНОЙ СЧЁТ

Перемножать отношения правдоподобия можно только если сигналы *условно независимы* при данном состоянии (при мошенничестве и без него). Две модели, обученные на одних и тех же данных клиента, часто выдают одно и то же, и второе оповещение почти не несёт новой информации. Автоматическая модель и последующая проверка документов гораздо ближе к независимым. В предельном случае, если второе оповещение просто повторяет первое, вероятность остаётся 7.04%, а не 36.2%.

5 Решение по порогу

Вероятность сама по себе решения не принимает. Нужно сравнить стоимость ошибок. Пусть возможный убыток от мошенничества $L = 10$ млн сум, а стоимость расследования $c = 0.5$ млн сум. Расследовать выгодно, если *ожидаемый предотвращённый убыток* больше стоимости расследования:

$$p \cdot L > c \quad \Longleftrightarrow \quad p > \frac{c}{L} = \frac{0.5}{10} = \mathbf{5}\%. \tag{5.1}$$

Обе вероятности, 7.04% после одного оповещения и 36.2% после двух, превышают порог 5%, поэтому расследование оправдано уже после первого сигнала. Обратите внимание: порог 5% намного ниже, чем «интуитивные» 50%: если ошибка пропуска дорога, а проверка дёшева, расследовать стоит даже при малой вероятности.

6 Мост к следующей лекции: от событий к случайным величинам

Событие говорит, *что произошло*. Случайная величина говорит, *сколько*. Один и тот же исход можно оценить разными числами. Для одного кредита исходы «погашен», «просрочен», «дефолт» дают прибыль банка X (млн сум):

Исход	x, млн сум	$P(X = x)$
Погашен	$+1.2$	0.80
Просрочен	$+0.4$	0.15
Дефолт	-8.0	0.05

Среднее, которого мы ожидаем в долгосрочном периоде, $\mathrm{E}[X] = 1.2 \cdot 0.80 + 0.4 \cdot 0.15 - 8 \cdot 0.05 =$ **0.62** млн сум. Это *не* прибыль по конкретному кредиту, а среднее по множеству однотипных кредитов. Этот аппарат — предмет лекции 4.

7 Ключевые термины

Термин	*English*	Смысл
Условная вероятность	*Conditional probability*	$P(A \mid B) = P(A \cap B)/P(B)$
Разбиение	*Partition*	попарно несовместные события, дающие все S
Формула полной вероятности	*Law of total probability*	$P(B) = \sum P(B \mid A_i)P(A_i)$
Теорема Байеса	*Bayes' theorem*	$P(A_i \mid B) = \dfrac{P(B \mid A_i)P(A_i)}{P(B)}$
Априорная вероятность	*Prior*	до наблюдения свидетельства
Апостериорная вероятность	*Posterior*	после наблюдения свидетельства
Правдоподобие	*Likelihood*	$P(\text{данные} \mid \text{гипотеза})$
Базовая частота	*Base rate*	доля события в исходной совокупности
Чувствительность	*Sensitivity*	$P(+ \mid \text{есть})$
Специфичность	*Specificity*	$P(- \mid \text{нет})$
Шансы	*Odds*	$p/(1-p)$
Отношение правдоподобия	*Likelihood ratio*	$LR_+ =$ чувств./ложн. срабат.

Формулы лекции 3

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(B) = \sum_i P(B \mid A_i) P(A_i),$$

$$P(A_i \mid B) = \frac{P(B \mid A_i) P(A_i)}{\sum_j P(B \mid A_j) P(A_j)},$$

шансы: $\text{odds} = \dfrac{p}{1-p}$, $p = \dfrac{\text{odds}}{1+\text{odds}}$, $\text{odds}_{\text{post}} = \text{odds}_{\text{prior}} \times LR$, $LR_+ = \dfrac{\text{чувств.}}{\text{ложн. срабат.}}$,

расследовать, если $p > \dfrac{c}{L}$.

8 Задачи для самостоятельного решения

Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Известно, что $P(A \cap B) = 0.10$, $P(A) = 0.40$, $P(B) = 0.50$.

(а) Найдите $P(A \mid B)$ и $P(B \mid A)$.
(б) Студент утверждает: «Раз $P(A \mid B) = 0.8$, то и $P(B \mid A) = 0.8$». Прав ли он?

Задача 2 [A] Из 1000 клиентов банка 400 пользуются мобильным приложением (М). Из них 250 имеют депозит (Д); среди остальных 600 клиентов депозит есть у 120.

(а) Найдите $P(\text{Д})$.
(б) Найдите $P(\text{Д} \mid \text{М})$ и $P(\text{Д} \mid \overline{\text{М}})$.
(в) Найдите $P(\text{М} \mid \text{Д})$.

Задача 3 [B] Завод выпускает детали на трёх станках A, B, C с долями выпуска 50%, 30%, 20%. Доли брака: 2%, 3%, 5% соответственно.

(а) Найдите вероятность того, что случайная деталь бракованная.
(б) Деталь оказалась бракованной. Найдите вероятность того, что она сделана на станке C; на A; на B.
(в) Проверьте, что три апостериорные вероятности в сумме дают 1.

Задача 4 [B] Банк ловит мошеннические операции. Доля мошеннических операций 2%. Система помечает 85% мошеннических операций и ошибочно помечает 10% нормальных.

(а) Найдите вероятность того, что помеченная операция действительно мошенническая.
(б) Решите ту же задачу методом естественных частот на 10 000 операциях.
(в) Объясните, почему результат намного меньше чувствительности 85%.

Задача 5 [B] Заболевание встречается у 0.5% населения. Тест выявляет его у 98% больных и даёт ложноположительный результат у 5% здоровых.

(а) Какова вероятность болезни при положительном результате?
(б) Тест повторили независимо (при условии состояния здоровья), и он снова положительный. Какова вероятность болезни теперь?

Задача 6 [B] Продолжите задачу о мошенничестве (доля 2%, чувствительность 85%, ложные срабатывания 10%). Предположим, что k независимых (при условии мошенничества / его отсутствия) систем подали сигнал по одной и той же операции.

(а) Найдите априорные шансы и отношение правдоподобия LR^{+}.
(б) Найдите вероятность мошенничества при $k = 1,\ 2,\ 3$ сигналах.
(в) Что произойдёт с результатом, если сигналы не независимы, а полностью дублируют друг друга?

Задача 7 [B] Для операции из задачи о мошенничестве потеря от пропущенного мошенничества составляет 8 млн сумов, расследование стоит 0.4 млн сумов (и полностью устраняет потерю).

(а) Найдите пороговую вероятность, начиная с которой расследование выгодно.
(б) Выгодно ли расследовать операцию, получившую один сигнал (вероятность мошенничества 14.8%)?
(в) При какой минимальной априорной вероятности одного сигнала достаточно для расследования?

Задача 8 [B] Для операции с апостериорной вероятностью мошенничества $p = 0.148$ рассматриваются три действия: (1) пропустить (ожидаемая потеря: $8p$ млн); (2) расследовать (затраты 0.4 млн, потери нет); (3) заблокировать (если операция нормальная, ущерб клиенту 1 млн; если мошенническая — потери нет). Какое действие минимизирует ожидаемые потери?

Задача 9 [C]

(а) Выведите формулу Байеса для события A_i из определения условной вероятности и формулы полной вероятности (события $A_1, \dots, A_n$ образуют разбиение).
(б) Докажите форму в шансах: $\dfrac{P(A \mid B)}{P(\overline{A} \mid B)} = \dfrac{P(A)}{P(\overline{A})} \cdot \dfrac{P(B \mid A)}{P(B \mid \overline{A})}$.

Задача 10 [C] У семьи двое детей.

(а) Известно, что хотя бы один ребёнок — мальчик. Какова вероятность того, что оба — мальчики?
(б) Известно, что старший ребёнок — мальчик. Какова вероятность того, что оба — мальчики?

Задача 11 [C] Задача Монти Холла. За одной из трёх дверей автомобиль, за двумя другими — козы. Вы выбрали дверь 1. Ведущий, знающий, где автомобиль, открывает дверь с козой (из двух оставшихся; если обе с козами, то выбирает случайно) и предлагает поменять выбор. Найдите вероятность выигрыша при смене двери.

Задача 12 [C] Две системы оповещения о мошенничестве (чувствительность 90%, ложные срабатывания 12%, доля мошенничества 1%) подали сигналы. Аналитик перемножил отношения

правдоподобия и получил 36.2%. Затем выяснилось, что вторая система просто копирует решение первой. Какой должна быть оценка вероятности?

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 4

Случайные величины и дискретные распределения

Как описать неопределённый числовой исход одним законом распределения, ожиданием и дисперсией

Тема 4 по силлабусу · неделя 4 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- отличать дискретную случайную величину от непрерывной и задавать закон распределения (PMF) и функцию распределения (CDF);
- вычислять математическое ожидание, дисперсию и стандартное отклонение дискретной величины;
- применять свойства $\mathrm{E}[aX+b]$ и $\mathrm{Var}(aX+b)$ и правило сложения для независимых величин;
- узнавать ситуации, описываемые биномиальным, геометрическим и пуассоновским распределениями, и считать их вероятности;
- использовать ожидаемое значение и риск (стандартное отклонение) для сравнения решений.

1 Случайная величина и закон распределения

В лекциях 2–3 мы работали с событиями. Чаще всего исход выражается числом: прибыль по кредиту, число звонков за час, число бракованных деталей в партии. Это удобно описывать функцией, которая каждому исходу ставит в соответствие число.

СЛУЧАЙНАЯ ВЕЛИЧИНА

Случайная величина X — числовая функция исхода случайного эксперимента. Значения обозначают строчной буквой: $\{X = x\}$ — событие «величина X приняла значение x».

Случайная величина *дискретна*, если принимает конечное или счётное число значений (число клиентов, число дефектов). Она *непрерывна*, если принимает любые значения на промежутке (рост, время ожидания, курс валюты). Эта лекция посвящена дискретным величинам, непрерывные разбираются в лекции 5.

ЗАКОН РАСПРЕДЕЛЕНИЯ (PMF)

Для дискретной величины функция $p(x) = P(X = x)$ называется функцией вероятностей (probability mass function, PMF). Она обладает свойствами

$$p(x) \geq 0, \qquad \sum_{x} p(x) = 1. \tag{1.1}$$

ФУНКЦИЯ РАСПРЕДЕЛЕНИЯ (CDF)

$F(x) = P(X \leq x) = \sum_{t \leq x} p(t)$. Это неубывающая «ступенчатая» функция от 0 до 1. Для целых значений $P(a < X \leq b) = F(b) - F(a)$.

ПРИМЕР 1. ЗВОНКИ В СЛУЖБУ ПОДДЕРЖКИ

Число обращений X за 10 минут имеет распределение

x	0	1	2	3	4
$P(X = x)$	0.10	0.25	0.35	0.20	0.10
$F(x)$	0.10	0.35	0.70	0.90	1.00

Сумма вероятностей равна 1, значит, закон корректен. $P(X \geq 3) = 0.20 + 0.10 = 0.30$; $P(1 \leq X \leq 3) = F(3) - F(0) = 0.90 - 0.10 = 0.80$.

2 Ожидание, дисперсия, стандартное отклонение

МАТЕМАТИЧЕСКОЕ ОЖИДАНИЕ

$$\mu = \mathrm{E}[X] = \sum_{x} x\, p(x). \tag{2.1}$$

Это среднее значение, которое мы получили бы при очень большом числе повторений (взвешенное вероятностями среднее).

ДИСПЕРСИЯ И СТАНДАРТНОЕ ОТКЛОНЕНИЕ

$$\sigma^2 = \mathrm{Var}(X) = \mathrm{E}\big[(X - \mu)^2\big] = \sum_{x} (x - \mu)^2 p(x) = \mathrm{E}\big[X^2\big] - \mu^2, \qquad \sigma = \sqrt{\mathrm{Var}(X)}. \tag{2.2}$$

Вторая запись в (2.2) (вычислительная формула) обычно удобнее: $\mathrm{E}\big[X^2\big] = \sum x^2 p(x)$.

ПРИМЕР 2. ЗВОНКИ: ОЖИДАНИЕ И РАЗБРОС

$\mu = 0 \cdot 0.10 + 1 \cdot 0.25 + 2 \cdot 0.35 + 3 \cdot 0.20 + 4 \cdot 0.10 = 1.95$. $\mathrm{E}\big[X^2\big] = 0.25 + 4 \cdot 0.35 + 9 \cdot 0.20 + 16 \cdot 0.10 = 0.25 + 1.40 + 1.80 + 1.60 = 5.05$. Отсюда $\mathrm{Var}(X) = 5.05 - 1.95^2 = 1.2475$, $\sigma = 1.117$.

ПРИМЕР 3. КРЕДИТ ИЗ ЛЕКЦИИ 3

Прибыль X (млн сум) принимает значения $+1.2$, $+0.4$, -8.0 с вероятностями 0.80, 0.15, 0.05. Тогда $\mathrm{E}[X] = 0.62$, $\mathrm{E}[X^2] = 1.44 \cdot 0.8 + 0.16 \cdot 0.15 + 64 \cdot 0.05 = 1.152 + 0.024 + 3.2 = 4.376$, $\mathrm{Var}(X) = 4.376 - 0.62^2 = 3.9916$, $\sigma = 1.998$.
Ожидаемая прибыль положительна (0.62), но стандартное отклонение (2.0) более чем втрое больше. Причина — редкий, но тяжёлый дефолт: «средний» результат ни разу не наблюдается у отдельного кредита (ни 0.62, ни близкого значения среди исходов нет).

ТИПИЧНАЯ ОШИБКА

Ожидаемое значение не обязано быть возможным значением величины и не гарантирует результат в одном испытании. Это долгосрочное среднее; в одном кредите можно потерять 8.

3 Свойства ожидания и дисперсии

Линейные преобразования и суммы

$$\mathrm{E}[aX + b] = a\mathrm{E}[X] + b, \qquad \mathrm{Var}(aX + b) = a^2\,\mathrm{Var}(X), \qquad \mathrm{SD}(aX + b) = |a|\,\mathrm{SD}(X),$$

$$\mathrm{E}[X + Y] = \mathrm{E}[X] + \mathrm{E}[Y] \text{ (всегда)},$$

$$\mathrm{Var}(X \pm Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) \text{ (если } X, Y \text{ независимы)}.$$

Сдвиг b меняет центр, но не разброс; умножение на a масштабирует разброс в $|a|$ раз, дисперсию в a^2 раз. Ожидание суммы равно сумме ожиданий даже для зависимых величин, а для дисперсии независимость существенна (общий случай в лекции 6).

ПРИМЕР 4. ПОРТФЕЛЬ ИЗ 100 КРЕДИТОВ

Пусть прибыли 100 кредитов независимы и одинаково распределены, как выше. Общая прибыль $T = X_1 + \cdots + X_{100}$:

$$\mathrm{E}[T] = 100 \cdot 0.62 = 62, \qquad \mathrm{Var}(T) = 100 \cdot 3.9916 = 399.16, \qquad \mathrm{SD}(T) = 19.98.$$

Средняя прибыль на кредит $\bar{X} = T/100$ имеет $\mathrm{E}\left[\bar{X}\right] = 0.62$ и $\mathrm{SD}(\bar{X}) = 19.98/100 = 0.20$, то есть разброс среднего в $\sqrt{100} = 10$ раз меньше, чем у отдельного кредита. Это зерно закона больших чисел и ЦПТ (лекция 7). Заметьте: стандартные отклонения не складываются, складываются дисперсии.

ТИПИЧНАЯ ОШИБКА

$\mathrm{SD}(X + Y) \neq \mathrm{SD}(X) + \mathrm{SD}(Y)$ и $\mathrm{Var}(X - Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$ (а не разность): вычитание независимых величин разброс не уменьшает.

4 Биномиальное распределение

Схема Бернулли: проводится n независимых испытаний, в каждом «успех» с вероятностью p (одинаковой). Число успехов X имеет биномиальное распределение, $X \sim \text{Bin}(n, p)$.

Биномиальное распределение

$$P(X = k) = C_n^k\, p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n; \qquad \text{E}[X] = np, \quad \text{Var}(X) = np(1-p).$$

Условия применимости (проверяйте всегда): (1) фиксированное число испытаний n; (2) два исхода; (3) одинаковая вероятность успеха; (4) независимость. Множитель C_n^k — число способов выбрать, в каких k испытаниях произошёл успех (лекция 2).

ПРИМЕР 5. КОНТРОЛЬ КАЧЕСТВА

Вероятность брака детали 5%, партия из 10 деталей, $X \sim \text{Bin}(10, 0.05)$.

$$P(X = 0) = 0.95^{10} = 0.599,$$
$$P(X \geq 1) = 1 - 0.599 = 0.401,$$
$$P(X = 2) = C_{10}^2 \cdot 0.05^2 \cdot 0.95^8 = 45 \cdot 0.0025 \cdot 0.6634 = 0.0746.$$

$\text{E}[X] = 0.5$, $\sigma = \sqrt{10 \cdot 0.05 \cdot 0.95} = 0.69$. В 40% партий по 10 деталей найдётся хотя бы одна бракованная, хотя «в среднем» брака всего 0.5 детали.

ПРИМЕР 6. КЛИЕНТЫ, СОГЛАСИВШИЕСЯ НА ПРЕДЛОЖЕНИЕ

Банк звонит 20 клиентам, каждый соглашается с вероятностью 0.3 независимо, $X \sim \text{Bin}(20, 0.3)$: $\text{E}[X] = 6$, $\text{Var}(X) = 4.2$, $\sigma = 2.05$. $P(X = 6) = C_{20}^6\, 0.3^6\, 0.7^{14} = 0.1916$; $P(X \leq 4) = 0.2375$; $P(X \geq 8) = 0.2277$. Такая расчётная схема использует таблицу или функцию `BINOM.DIST` в Excel.

5 Геометрическое распределение

Если испытания повторяют до первого успеха, число испытаний X имеет геометрическое распределение:

$$P(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, \dots; \qquad \text{E}[X] = \frac{1}{p}, \quad P(X \leq k) = 1 - (1-p)^k. \tag{5.1}$$

Пример: вероятность оформить сделку с одним звонком $p = 0.2$. Тогда сделка потребует ровно 3 звонков с вероятностью $0.8^2 \cdot 0.2 = 0.128$, не более 3 звонков — с вероятностью $1 - 0.8^3 = 0.488$, а в среднем потребуется $1/0.2 = 5$ звонков.

6 Распределение Пуассона

Если события происходят независимо друг от друга в непрерывном времени (или пространстве) с постоянной средней интенсивностью, то число событий X за фиксированный интервал, в среднем

λ раз, имеет распределение Пуассона:

$$P(X=k)=\frac{e^{-\lambda}\lambda^{k}}{k!},\quad k=0,1,2,\dots;\qquad \mathrm{E}[X]=\mathrm{Var}(X)=\lambda. \tag{6.1}$$

ПРИМЕР 7. КЛИЕНТЫ В ОТДЕЛЕНИИ

В отделении в среднем $\lambda=3$ клиента за 10 минут. Тогда

$$P(X=0)=e^{-3}=0.0498,\quad P(X=2)=\frac{e^{-3}3^{2}}{2}=0.2240,$$
$$P(X\ge 4)=1-P(X\le 3)=0.3528.$$

Интенсивность пересчитывается пропорционально интервалу: за 20 минут в среднем 6 клиентов, и, например, $P(X\le 3)=0.1512$.

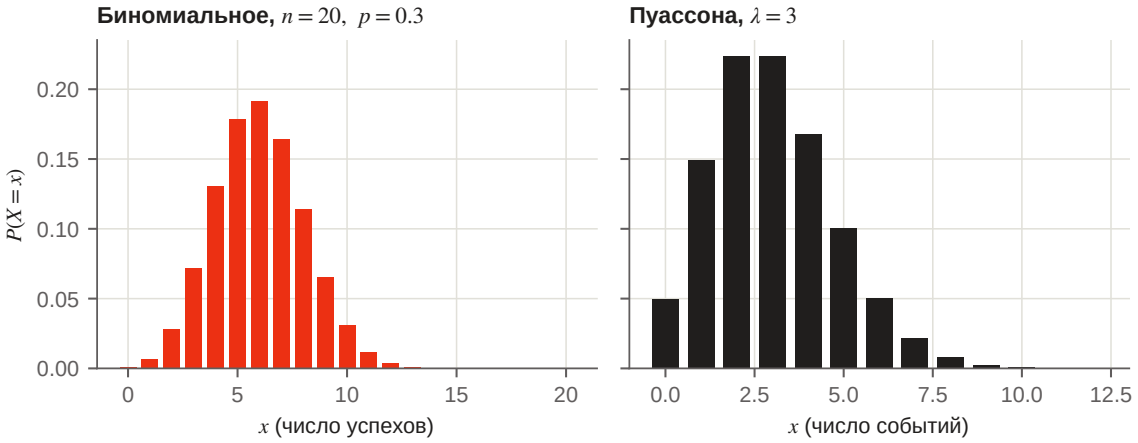


Рис. 1. Закон распределения: биномиальное $\mathrm{Bin}(20,0.3)$ почти симметрично и имеет колоколообразную форму с центром $\mu=6$; пуассоновское с $\lambda=3$ скошено вправо.

Пуассон как приближение биномиального. При большом n и малом p распределение $\mathrm{Bin}(n,p)$ близко к $\mathrm{Pois}(\lambda=np)$. Например, 200 операций, вероятность ошибки 0.01: $P(X\ge 3)=0.3233$ по биномиальной формуле и 0.3233 по Пуассону с $\lambda=2$.

ЗАПОМНИТЕ

Как выбрать модель: фиксированное число n испытаний с долей успеха p — биномиальное; число испытаний до первого успеха — геометрическое; число событий в интервале без верхней границы — Пуассона. У Пуассона дисперсия равна ожиданию; если разброс данных заметно больше среднего, модель неадекватна.

7 Ключевые термины

Термин	*English*	Смысл
Случайная величина	*Random variable*	числовая функция исхода
Закон распределения (PMF)	*Probability mass function*	$p(x) = P(X = x)$, $\sum p = 1$
Функция распределения (CDF)	*Cumulative distribution function*	$F(x) = P(X \le x)$
Математическое ожидание	*Expected value*	$\mu = \sum x\, p(x)$
Дисперсия	*Variance*	$\mathrm{E}[X^2] - \mu^2$
Биномиальное	*Binomial*	$\mathrm{Bin}(n, p)$: np, $np(1-p)$
Геометрическое	*Geometric*	число испытаний до успеха, $1/p$
Пуассона	*Poisson*	события в интервале, λ

Формулы лекции 4

$$\mu = \sum x\, p(x), \qquad \sigma^2 = \sum x^2 p(x) - \mu^2,$$

$$\mathrm{E}[aX + b] = a\mu + b, \quad \mathrm{Var}(aX + b) = a^2\sigma^2, \quad \mathrm{Var}(X \pm Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) \text{ (независ.)},$$

$$\mathrm{Bin}(n, p):\ P(k) = C_n^k p^k (1-p)^{n-k},\ \mu = np,\ \sigma^2 = np(1-p);$$

$$\mathrm{Geom}(p):\ P(k) = (1-p)^{k-1} p,\ \mu = 1/p; \qquad \mathrm{Pois}(\lambda):\ P(k) = e^{-\lambda}\lambda^k / k!,\ \mu = \sigma^2 = \lambda.$$

8 Задачи для самостоятельного решения

Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Закон распределения величины X: $P(1) = 0.2$, $P(2) = 0.3$, $P(3) = k$, $P(4) = 0.1$.

(а) Найдите k.
(б) Найдите $\mathrm{E}[X]$, $\mathrm{Var}(X)$, $\mathrm{SD}(X)$.
(в) Найдите $P(X \ge 3)$.

Задача 2 [A] Для величины X: $\mathrm{E}[X] = 40$, $\mathrm{SD}(X) = 6$. Величина X_2 не зависит от X: $\mathrm{E}[X_2] = 25$, $\mathrm{SD}(X_2) = 8$.

(а) Найдите ожидание, дисперсию и стандартное отклонение $Y = 3X - 10$.
(б) Найдите ожидание и стандартное отклонение $X + X_2$ и $X - X_2$.

Задача 3 [A] $X \sim \text{Bin}(5, 0.4)$.

(а) Составьте таблицу $P(X = k)$, $k = 0, \ldots, 5$.
(б) Найдите $\text{E}[X]$ и $\text{Var}(X)$ по формулам.
(в) Найдите $P(X \geq 4)$.

Задача 4 [B] Заёмщик возвращает кредит с вероятностью 0.9 независимо от остальных. Банк выдал 12 кредитов.

(а) Найдите ожидаемое число возвращённых кредитов и стандартное отклонение.
(б) Найдите вероятность того, что вернут все 12.
(в) Найдите вероятность того, что не вернут не более одного кредита.

Задача 5 [B] Среднее число жалоб в службу поддержки — 1.5 в час (пуассоновский поток).

(а) Найдите вероятность того, что за час не будет жалоб.
(б) Найдите вероятность не менее двух жалоб за час.
(в) Найдите вероятность того, что за два часа поступит не более одной жалобы.

Задача 6 [B] Рассматриваются два проекта. Проект A: прибыль $+10$ млн с вероятностью 0.6 и -5 млн с вероятностью 0.4. Проект B: $+6$ млн с вероятностью 0.7 и -1 млн с вероятностью 0.3.

(а) Найдите ожидаемую прибыль и стандартное отклонение каждого проекта.
(б) Какой проект вы бы выбрали, если цель — максимум ожидаемой прибыли? А если важна устойчивость? Обоснуйте.

Задача 7 [B] Страховая компания продаёт полис за 80 тыс. сум. Годовые выплаты по полису: 0 с вероятностью 0.94, 400 тыс. с вероятностью 0.05, 3000 тыс. с вероятностью 0.01.

(а) Найдите ожидаемую выплату и стандартное отклонение выплаты по одному полису.
(б) Найдите ожидаемую прибыль и стандартное отклонение прибыли по одному полису.
(в) Компания продала 1000 независимых полисов. Найдите ожидаемую суммарную прибыль и её стандартное отклонение.

Задача 8 [B] Прибыль одного кредита имеет $\mu = 0.62$ млн, $\sigma = 2.0$ млн (лекция 4, пример с кредитом). Банк выдаёт 25 независимых кредитов. Найдите ожидание и стандартное отклонение суммарной прибыли и средней прибыли на кредит. Во сколько раз среднее менее изменчиво, чем один кредит?

Задача 9 [B] Банк проводит 300 транзакций в минуту, каждая ошибочна с вероятностью 0.006 независимо.

(а) Найдите вероятность отсутствия ошибок по точной биномиальной формуле и по приближению Пуассона.
(б) Найдите вероятность не менее трёх ошибок обоими способами.

Задача 10 [B] Вероятность заключить сделку за один звонок равна 0.25 (звонки независимы). Менеджер звонит до первой сделки.

(а) Какова вероятность, что первая сделка будет на четвёртом звонке?

(б) Какова вероятность, что хватит не более четырёх звонков?

(в) Сколько звонков в среднем потребуется?

Задача 11 [C] Докажите: (а) $\operatorname{Var}(X) = \mathrm{E}[X^2] - \mu^2$; (б) $\operatorname{Var}(aX + b) = a^2 \operatorname{Var}(X)$.

Задача 12 [C] Пусть $X \sim \mathrm{Bin}(n, p)$ — число успехов, $X = I_1 + \cdots + I_n$, где I_i — индикатор успеха в i-м испытании ($I_i = 1$ с вероятностью p, иначе 0, независимые).

(а) Найдите $\mathrm{E}[I_i]$ и $\operatorname{Var}(I_i)$.

(б) Выведите $\mathrm{E}[X] = np$ и $\operatorname{Var}(X) = np(1-p)$.

(в) При каком p дисперсия одного испытания максимальна? Чему равна?

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 5

Непрерывные распределения и нормальное распределение

Плотность, площадь под кривой, стандартизация и работа с таблицей нормального распределения

Тема 5 по силлабусу · неделя 5 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- объяснять, почему для непрерывной величины вероятность — это площадь под плотностью, а $P(X = x) = 0$;
- работать с равномерным и экспоненциальным распределениями;
- стандартизировать нормальную величину (z-оценка) и находить вероятности и квантили по таблице;
- применять правило 68–95–99.7 и находить неизвестные параметры по заданной вероятности;
- использовать нормальность суммы независимых нормальных величин и нормальное приближение биномиального распределения.

1 Плотность распределения

У непрерывной величины (время, масса, сумма) нельзя перечислить значения и приписать им вероятности: значений бесконечно много, и вероятность любого отдельного значения равна нулю. Вместо этого задают *плотность* $f(x)$.

ПЛОТНОСТЬ РАСПРЕДЕЛЕНИЯ

Функция $f(x) \geq 0$ с полной площадью под кривой, равной 1, называется плотностью. Вероятность попадания в интервал — это площадь под кривой над ним:

$$P(a \leq X \leq b) = \int_a^b f(x)\,dx, \qquad P(X = x) = 0. \tag{1.1}$$

Поэтому для непрерывной величины неважно, строгие или нестрогие неравенства: $P(X < b) = P(X \leq b)$. Функция распределения определяется так же, как и раньше: $F(x) = P(X \leq x)$ (площадь слева от x), и $P(a < X < b) = F(b) - F(a)$. Ожидание и дисперсия задаются интегралами $\mu = \int x f(x) dx$, $\sigma^2 = \int (x - \mu)^2 f(x) dx$, но для стандартных семейств мы будем пользоваться готовыми формулами.

ТИПИЧНАЯ ОШИБКА

Значение плотности $f(x)$ — не вероятность и может превышать 1 (например, плотность равномерного распределения на $[0, 0.5]$ равна 2). Вероятность — только площадь.



Рис. 1. Три плотности: равномерная (время доставки, мин), экспоненциальная (ожидание, мин), нормальная (баллы).

2 Равномерное распределение

Если все значения на отрезке $[a, b]$ равновозможны, $X \sim U(a, b)$:

$$f(x) = \frac{1}{b-a}\ (a \le x \le b), \qquad P(c \le X \le d) = \frac{d-c}{b-a}, \qquad \mu = \frac{a+b}{2}, \quad \sigma^2 = \frac{(b-a)^2}{12}. \tag{2.1}$$

ПРИМЕР 1. ВРЕМЯ ДОСТАВКИ

Курьер доставляет заказ за время $X \sim U(20, 40)$ минут. $\mu = 30$, $\sigma = 20/\sqrt{12} = 5.77$. $P(25 \le X \le 35) = 10/20 = 0.5$; $P(X > 36) = 4/20 = 0.2$.

3 Экспоненциальное распределение

Время ожидания следующего события пуассоновского потока (лекция 4) с интенсивностью λ распределено экспоненциально:

$$f(x) = \lambda e^{-\lambda x}, \quad P(X > x) = e^{-\lambda x}, \quad F(x) = 1 - e^{-\lambda x}\ (x \ge 0); \qquad \mu = \sigma = \frac{1}{\lambda}. \tag{3.1}$$

ПРИМЕР 2. ОЖИДАНИЕ В ОЧЕРЕДИ

Среднее ожидание обслуживания 4 минуты, $\lambda = 1/4$. $P(X > 6) = e^{-1.5} = 0.2231$; $P(X < 2) = 1 - e^{-0.5} = 0.3935$; $P(3 < X < 5) = e^{-0.75} - e^{-1.25} = 0.4724 - 0.2865 = 0.1859$. Медиана $= 4 \ln 2 = 2.77$ минуты, меньше среднего 4: распределение скошено вправо.

ЗАПОМНИТЕ

У экспоненциального распределения нет «памяти»: $P(X > s + t \mid X > s) = P(X > t)$. Если вы уже ждёте 5 минут, оставшееся время ожидания распределено так же, как для только что пришедшего клиента.

4 Нормальное распределение

НОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ

$X \sim N(\mu, \sigma^2)$, если плотность имеет колоколообразный вид

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}. \tag{4.1}$$

Кривая симметрична относительно μ; параметр σ определяет ширину.

Нормальным (приближённо) бывают величины, формируемые суммой множества малых независимых влияний: ошибки измерения, рост, баллы больших тестов, а также, как мы увидим в лекции 7, выборочные средние при любом исходном распределении.

4.1 Стандартизация

Площадь под $N(\mu, \sigma^2)$ нельзя взять «в лоб», поэтому все вероятности приводят к стандартной нормальной $Z \sim N(0, 1)$ с помощью z-оценки:

$$z = \frac{x - \mu}{\sigma}, \qquad P(X \le x) = \Phi(z), \tag{4.2}$$

где $\Phi(z)$ — функция распределения Z (таблица в приложении «Статистические таблицы», Excel: `NORM.S.DIST(z,TRUE)`). z показывает, на сколько стандартных отклонений значение отстоит от среднего.

Полезные свойства: $\Phi(-z) = 1 - \Phi(z)$; $P(Z > z) = 1 - \Phi(z)$; $P(a < Z < b) = \Phi(b) - \Phi(a)$.

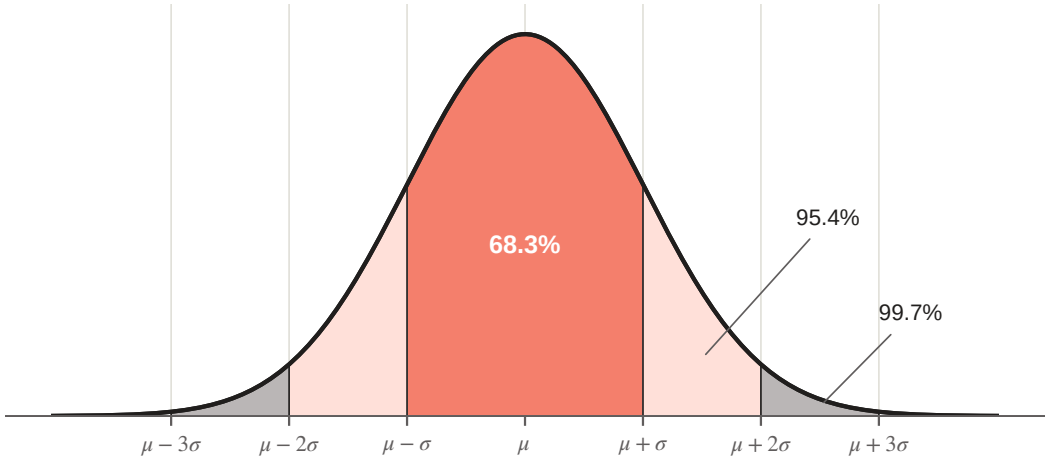


Рис. 2. Правило 68–95–99.7: для нормальной величины в пределах $\pm 1\sigma$ находится 68.3% значений, $\pm 2\sigma$ — 95.4%, $\pm 3\sigma$ — 99.7%.

ПРИМЕР 3. БАЛЛЫ ЭКЗАМЕНА

Баллы $X \sim N(70, 10^2)$.

- $P(X > 85)$: $z = 1.5$, $P = 1 - \Phi(1.5) = 1 - 0.9332 = 0.0668$.
- $P(60 < X < 80)$: $z = \pm 1$, $P = 0.8413 - 0.1587 = 0.6827$.
- $P(65 < X < 90)$: $z = -0.5$ и 2: $P = 0.9772 - 0.3085 = 0.6687$.

4.2 Обратная задача: квантили

Чтобы найти значение x, выше (ниже) которого лежит заданная доля, находим z по таблице «в обратную сторону» и возвращаемся: $x = \mu + z\sigma$. Часто используемые значения: $z_{0.90} = 1.2816$, $z_{0.95} = 1.6449$, $z_{0.975} = 1.9600$, $z_{0.99} = 2.3263$, $z_{0.995} = 2.5758$.

ПРИМЕР 4. ЛУЧШИЕ 10% И КВАРТИЛИ

Порог лучших 10% по экзамену: $x = 70 + 1.2816 \cdot 10 = 82.8$. Нижний квартиль $Q_1 = 70 - 0.6745 \cdot 10 = 63.3$, верхний $Q_3 = 76.7$; поэтому $IQR = 13.5 = 1.349\,\sigma$ (полезный ориентир в лекции 1: для нормальных данных $IQR \approx 1.35\sigma$).

ПРИМЕР 5. ДОХОДЫ

Месячный доход $X \sim N(5.5;\ 1.2^2)$ млн сум. $P(X > 7) = P(Z > 1.25) = 0.1056$; $P(X < 4) = 0.1056$ (симметрия: $z = -1.25$); $P(4 < X < 7) = 0.7887$. Центральные 95% значений: $5.5 \pm 1.96 \cdot 1.2$, то есть от 3.15 до 7.85 млн.

4.3 Неизвестные параметры

Если известна вероятность, но не параметр, то записываем стандартизацию и решаем уравнение. Например, $X \sim N(90, \sigma^2)$ и $P(X > 100) = 0.10$. Тогда $z = 1.2816 = \dfrac{100 - 90}{\sigma}$, $\sigma = 10/1.2816 = 7.80$. Другой пример: $X \sim N(\mu, 8^2)$ и $P(X < 50) = 0.20$: $z_{0.20} = -0.8416$, $50 = \mu - 0.8416 \cdot 8$, $\mu = 56.73$.

4.4 Сравнение через z-оценки

z-оценка позволяет сравнить результаты на разных шкалах. Студент набрал 78 баллов на тесте $N(70, 8^2)$ и 640 на тесте $N(580, 60^2)$: $z_1 = 1.0$, $z_2 = 1.0$. Относительные результаты одинаковы.

4.5 Суммы нормальных величин

Линейная комбинация независимых нормальных величин нормальна, а параметры считаются по правилам лекции 4. Пусть $X \sim N(40, 6^2)$, $Y \sim N(25, 8^2)$ независимы. Тогда $X + Y \sim N(65, 10^2)$ и $X - Y \sim N(15, 10^2)$; $P(X + Y > 80) = P(Z > 1.5) = 0.0668$, $P(X < Y) = P(X - Y < 0) = P(Z < -1.5) = 0.0668$.

5 Нормальное приближение биномиального

При большом n распределение $\mathrm{Bin}(n,p)$ хорошо приближается нормальным $N(np,\ np(1-p))$ (условие: $np \geq 10$ и $n(1-p) \geq 10$). Так как биномиальное распределение дискретно, вводят *поправку на непрерывность*: $P(X \leq k) \approx \Phi\left(\dfrac{k+0.5-np}{\sqrt{np(1-p)}}\right)$.

ПРИМЕР 6. 100 КЛИЕНТОВ

$X \sim \mathrm{Bin}(100, 0.3)$: $\mu = 30$, $\sigma = \sqrt{21} = 4.58$. Точно $P(X \leq 35) = 0.8839$. Без поправки $\Phi(1.09) = 0.8624$, с поправкой $\Phi\left(\frac{35.5-30}{4.58}\right) = \Phi(1.20) = 0.8849$. Поправка заметно улучшает точность приближения.

6 Ключевые термины

Термин	*English*	Смысл
Плотность	*Probability density function (pdf)*	$P(a \leq X \leq b) = \int_a^b f$
Равномерное	*Uniform*	$\mu = \frac{a+b}{2}$, $\sigma^2 = \frac{(b-a)^2}{12}$
Экспоненциальное	*Exponential*	$P(X > x) = e^{-\lambda x}$, $\mu = 1/\lambda$
Нормальное	*Normal*	колоколообразное, $N(\mu, \sigma^2)$
z-оценка	*z-score*	$z = (x-\mu)/\sigma$
Стандартное нормальное	*Standard normal*	$Z \sim N(0,1)$, функция Φ
Квантиль	*Quantile*	значение, левее которого заданная доля
Поправка на непрерывность	*Continuity correction*	± 0.5 при приближении дискретной величины

Формулы лекции 5

$$U(a,b):\ \mu = \tfrac{a+b}{2},\ \sigma^2 = \tfrac{(b-a)^2}{12}; \qquad \mathrm{Exp}(\lambda):\ P(X>x) = e^{-\lambda x},\ \mu = \sigma = \tfrac{1}{\lambda};$$

$$X \sim N(\mu,\sigma^2):\ z = \frac{x-\mu}{\sigma},\ \ P(X \leq x) = \Phi(z),\ \ x = \mu + z\sigma;$$

$$\mathrm{Bin}(n,p) \approx N(np,\ np(1-p)),\ \ P(X \leq k) \approx \Phi\left(\tfrac{k+0.5-np}{\sqrt{np(1-p)}}\right).$$

7 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Автобус ходит с интервалом 15 минут. Пассажир приходит в случайный момент, время ожидания $X \sim U(0, 15)$.

(а) Найдите μ и σ.
(б) Найдите $P(X > 10)$ и $P(5 < X < 8)$.

Задача 2 [A] Время обслуживания клиента в банке экспоненциально со средним 5 минут.

(а) Чему равен параметр λ?
(б) Найдите вероятность того, что обслуживание длится более 3 минут, и вероятность того, что менее 10 минут.
(в) Найдите медиану.

Задача 3 [A] $X \sim N(200, 20^2)$. Найдите $P(X < 230)$, $P(X > 170)$, $P(190 < X < 215)$.

Задача 4 [B] Автомат фасует кофе, масса пачки $X \sim N(500, 4^2)$ г.

(а) Найдите долю пачек массой менее 495 г.
(б) Найдите долю пачек массой более 510 г.
(в) На какое среднее нужно настроить автомат, чтобы менее 495 г было лишь у 1% пачек (стандартное отклонение прежнее)?

Задача 5 [B] Размер потребительского кредита $X \sim N(40, 12^2)$ млн сум.

(а) Найдите долю кредитов больше 60 млн.
(б) Найдите долю кредитов меньше 30 млн.
(в) Найдите границу крупнейших 5% кредитов и интервал, содержащий центральные 90% кредитов.

Задача 6 [B] Для $X \sim N(90, \sigma^2)$ известно $P(X > 100) = 0.10$. Для $Y \sim N(\mu, 8^2)$ известно $P(Y < 50) = 0.20$. Найдите σ и μ.

Задача 7 [B] Студент A набрал 82 балла на экзамене $N(70, 8^2)$, студент B — 640 баллов на экзамене $N(580, 60^2)$. Кто показал лучший относительный результат? Какая доля сдававших набрала меньше каждого?

Задача 8 [B] Доходности двух независимых активов (%): $R_1 \sim N(8, 4^2)$, $R_2 \sim N(5, 3^2)$. Портфель — сумма $R_1 + R_2$.

(а) Найдите распределение $R_1 + R_2$.
(б) Найдите вероятность отрицательной суммарной доходности.
(в) Найдите вероятность того, что $R_1 < R_2$.

Задача 9 [B] Покупку совершают 40% посетителей магазина независимо. За день пришло 200 посетителей.

(а) Проверьте применимость нормального приближения и найдите μ и σ числа покупателей.
(б) Найдите вероятность того, что покупателей не менее 90 (с поправкой на непрерывность).

Задача 10 [B] Время между приходами клиентов экспоненциально со средним 2 минуты.

(а) Найдите вероятность ожидания следующего клиента дольше 3 минут.
(б) Прошло уже 2 минуты без клиентов. Какова вероятность, что придётся ждать ещё не менее 3 минут?
(в) Каково распределение числа клиентов за 10 минут? Найдите вероятность того, что за 10 минут не придёт никто.

Задача 11 [C] Докажите отсутствие памяти у экспоненциального распределения: $P(X > s + t \mid X > s) = P(X > t)$.

Задача 12 [C] Для $X \sim U(a, b)$ выведите $\mathrm{E}[X]$ и $\mathrm{Var}(X)$ интегрированием.

Задача 13 [C] Пусть $X \sim N(\mu, \sigma^2)$. Покажите, что z-оценка $Z = (X - \mu)/\sigma$ имеет $\mathrm{E}[Z] = 0$ и $\mathrm{Var}(Z) = 1$. Объясните, почему из $IQR \approx 1.349\sigma$ следует, что при $IQR = 27$ для нормальных данных $\sigma \approx 20$.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 6

Совместные распределения, ковариация и корреляция

Как описать две случайные величины сразу и почему связь между активами определяет риск портфеля

Тема 6 по силлабусу · неделя 6 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- читать и строить таблицу совместного распределения, находить маргинальные и условные распределения;
- проверять независимость двух дискретных величин;
- вычислять ковариацию и коэффициент корреляции (по распределению и по выборке) и интерпретировать их;
- находить дисперсию суммы и разности зависимых величин;
- считать риск портфеля из двух активов и объяснять эффект диверсификации.

1 Совместное распределение

До сих пор мы изучали одну величину. В экономике интересны пары: цена и спрос, доходности двух активов, продажи двух магазинов. *Совместное распределение* задаёт вероятности $p(x, y) = P(X = x,\ Y = y)$ всех пар значений.

ПРИМЕР 1. ПРОДАЖИ ДВУХ МАГАЗИНОВ

X — число проданных за час единиц товара в магазине A, Y — в магазине B (значения $0, 1, 2$).

	$X = 0$	$X = 1$	$X = 2$	$P(Y = y)$
$Y = 0$	0.10	0.10	0.05	**0.25**
$Y = 1$	0.10	0.30	0.10	**0.50**
$Y = 2$	0.05	0.05	0.15	**0.25**
$P(X = x)$	**0.25**	**0.45**	**0.30**	1

Сумма всех девяти вероятностей равна 1. Суммы по строкам и столбцам (поля таблицы) дают *маргинальные* распределения X и Y.

Маргинальное распределение получают суммированием: $p_X(x) = \sum_y p(x, y)$. По нему считаются обычные характеристики: $\mathrm{E}[X] = 0 \cdot 0.25 + 1 \cdot 0.45 + 2 \cdot 0.30 = 1.05$, $\mathrm{Var}(X) = 1.65 - 1.05^2 = 0.5475$; для Y: $\mathrm{E}[Y] = 1$, $\mathrm{Var}(Y) = 0.5$.

1.1 Условные распределения и независимость

Условное распределение получается как в лекции 3: $p(y \mid x) = p(x,y)/p_X(x)$. Для $X = 2$ (столбец делится на 0.30): $P(Y=0 \mid X=2) = 0.1\overline{6}$, $P(Y=1 \mid X=2) = 0.\overline{3}$, $P(Y=2 \mid X=2) = 0.5$. Условное ожидание $\mathrm{E}[Y \mid X=2] = 0.333 + 1.0 = 1.33$, тогда как $\mathrm{E}[Y] = 1$: когда магазин A продаёт много, магазин B в среднем тоже.

НЕЗАВИСИМОСТЬ

Дискретные величины независимы, если $p(x,y) = p_X(x)\,p_Y(y)$ для *всех* пар (x,y).

В нашем примере $p(0,0) = 0.10 \neq 0.25 \cdot 0.25 = 0.0625$, значит, X и Y зависимы. Достаточно одного нарушения.

2 Ковариация и корреляция

КОВАРИАЦИЯ

$$\mathrm{Cov}(X,Y) = \mathrm{E}[(X-\mu_X)(Y-\mu_Y)] = \mathrm{E}[XY] - \mu_X\mu_Y, \qquad \mathrm{E}[XY] = \sum_{x,y} xy\,p(x,y). \tag{2.1}$$

Положительная ковариация означает, что большие значения X в среднем сопровождаются большими значениями Y; отрицательная — наоборот. Её значение зависит от единиц измерения, поэтому для оценки силы связи используют безразмерный коэффициент.

КОРРЕЛЯЦИЯ

$$\rho = \mathrm{Corr}(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y}, \qquad -1 \le \rho \le 1. \tag{2.2}$$

ПРИМЕР 2. ПРОДОЛЖЕНИЕ: ПРОДАЖИ ДВУХ МАГАЗИНОВ

Ненулевые слагаемые в $\mathrm{E}[XY]$ даёт только $x, y \ge 1$: $1\cdot 1\cdot 0.30 + 2\cdot 1\cdot 0.10 + 1\cdot 2\cdot 0.05 + 2\cdot 2\cdot 0.15 = 0.30 + 0.20 + 0.10 + 0.60 = 1.20$. Поэтому $\mathrm{Cov}(X,Y) = 1.20 - 1.05\cdot 1 = 0.15$, $\rho = \dfrac{0.15}{\sqrt{0.5475\cdot 0.5}} = 0.287$ — связь положительная и слабая.

Свойства: $\mathrm{Cov}(X,X) = \mathrm{Var}(X)$; $\mathrm{Cov}(aX+b,\,cY+d) = ac\;\mathrm{Cov}(X,Y)$; $\mathrm{Corr}(aX+b,\,cY+d) = \mathrm{sign}(ac)\;\mathrm{Corr}(X,Y)$ (корреляция не зависит от единиц). Если X и Y независимы, то $\mathrm{Cov} = 0$ и $\rho = 0$.

ТИПИЧНАЯ ОШИБКА

Обратное неверно: $\rho = 0$ не означает независимости. Корреляция измеряет только *линейную* связь. Пример: X равновероятно принимает значения $-2, -1, 0, 1, 2$, а $Y = X^2$; Y полностью определяется X, но $\mathrm{Cov}(X,Y) = 0$.

2.1 Выборочные ковариация и корреляция

По наблюдениям (x_i, y_i), $i = 1..n$:

$$s_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n-1}, \qquad r = \frac{s_{xy}}{s_x s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}. \tag{2.3}$$

ПРИМЕР 3. РЕКЛАМА И ПРОДАЖИ

Шесть месяцев: расходы на рекламу x (млн сум) $= 2, 3, 5, 6, 8, 10$; продажи y (млн сум) $= 15, 17, 22, 31, 33, 40$. $\bar{x} = 5.667$, $\bar{y} = 26.333$. $\sum (x_i - \bar{x})^2 = 45.33$, $\sum (y_i - \bar{y})^2 = 487.33$, $\sum (x_i - \bar{x})(y_i - \bar{y}) = 145.67$ (слагаемые $41.56;\ 24.89;\ 2.89;\ 1.56;\ 15.56;\ 59.22$). Отсюда $s_{xy} = 145.67/5 = 29.13$, $s_x = 3.01$, $s_y = 9.87$, $r = \dfrac{145.67}{\sqrt{45.33 \cdot 487.33}} = 0.980$.

ЗАПОМНИТЕ

Корреляция — не причинность. Высокая r может возникать из-за третьего фактора, из-за обратной причинности или случайно. Об этом мы подробно говорим в лекциях 12–13.

3 Сумма и разность зависимых величин

Дисперсия суммы

$$\operatorname{Var}(X \pm Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) \pm 2\operatorname{Cov}(X, Y).$$

Для независимых величин остаётся прежнее правило (лекция 4). В примере с магазинами: $\operatorname{Var}(X + Y) = 0.5475 + 0.5 + 2 \cdot 0.15 = 1.3475$, а $\operatorname{Var}(X - Y) = 1.0475 - 0.30 = 0.7475$. Ожидание всегда $\mathrm{E}[X + Y] = 2.05$. Положительная связь делает сумму более изменчивой, а разность — менее.

4 Портфель из двух активов

Доходности активов: R_1, R_2 с ожиданиями μ_1, μ_2, стандартными отклонениями σ_1, σ_2 и корреляцией ρ. Доля капитала w вложена в первый актив, $1 - w$ — во второй. Доходность портфеля $R_p = wR_1 + (1-w)R_2$:

$$\mathrm{E}[R_p] = w\mu_1 + (1-w)\mu_2, \qquad \sigma_p^2 = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\,\sigma_1\sigma_2. \tag{4.1}$$

ПРИМЕР 4. ДИВЕРСИФИКАЦИЯ

$\sigma_1 = 10\%$, $\sigma_2 = 15\%$, $w = 0.5$. Стандартное отклонение портфеля:

ρ	1	0.5	0	-0.5	-1
σ_p, %	12.50	10.90	9.01	6.61	2.50

Лишь при $\rho = 1$ риск портфеля равен среднему риску активов (12.5%). Чем ниже корреляция, тем сильнее эффект диверсификации; ожидаемая доходность от ρ не зависит.

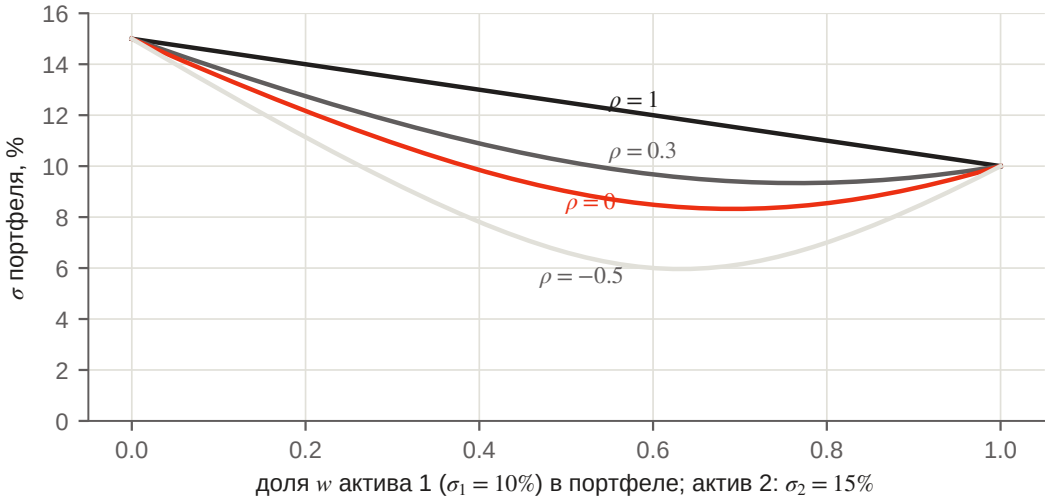


Рис. 1. Риск портфеля в зависимости от доли актива 1 при разных корреляциях. Чем ниже ρ, тем глубже «провал» кривой.

ПРИМЕР 5. МИНИМУМ РИСКА

При $\rho = 0.3$ доля актива 1, минимизирующая дисперсию, равна $w^* = \dfrac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2} = \dfrac{0.0225 - 0.0045}{0.01 + 0.0225 - 0.009} = 0.766$, $\sigma_p = 9.33\%$ — меньше, чем у обоих активов по отдельности (10% и 15%).

То же рассуждение объясняет, почему риск портфеля из n одинаково рискованных кредитов с попарной корреляцией ρ не падает до нуля: $\sigma_{\bar{X}} = \sigma\sqrt{\frac{1+(n-1)\rho}{n}}$. Для $\sigma = 2.0$, $n = 100$: при $\rho = 0$ получаем 0.20, при $\rho = 0.1$ уже 0.66. Системный (общий) риск диверсификацией не устраняется.

5 Ключевые термины

Термин	*English*	Смысл
Совместное распределение	*Joint distribution*	$p(x,y) = P(X=x, Y=y)$
Маргинальное распределение	*Marginal distribution*	$p_X(x) = \sum_y p(x,y)$
Условное распределение	*Conditional distribution*	$p(y \mid x) = p(x,y)/p_X(x)$
Ковариация	*Covariance*	$\mathrm{E}[XY] - \mu_X\mu_Y$
Корреляция	*Correlation*	$\rho = \mathrm{Cov}\,/(\sigma_X\sigma_Y)$
Диверсификация	*Diversification*	снижение риска за счёт несовершенной корреляции

Формулы лекции 6

$$\mathrm{Cov}(X,Y) = \mathrm{E}[XY] - \mu_X\mu_Y, \qquad \rho = \frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y},$$

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}},$$

$$\mathrm{Var}(X \pm Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) \pm 2\,\mathrm{Cov}(X,Y),$$

$$\mathrm{Cov}(aX + b, cY + d) = ac\,\mathrm{Cov}(X,Y),$$

$$\sigma_p^2 = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\sigma_1\sigma_2.$$

6 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Совместное распределение двух индикаторов: $P(X=0,Y=0)=0.3$, $P(X=0,Y=1)=0.2$, $P(X=1,Y=0)=0.1$, $P(X=1,Y=1)=0.4$.

(а) Найдите маргинальные распределения X и Y.
(б) Найдите $\mathrm{Cov}(X,Y)$ и ρ.
(в) Найдите $P(Y=1 \mid X=1)$. Независимы ли X и Y?

Задача 2 [A] $\mathrm{Var}(X)=9$, $\mathrm{Var}(Y)=16$, $\mathrm{Cov}(X,Y)=6$. Найдите ρ, $\mathrm{Var}(X+Y)$, $\mathrm{Var}(X-Y)$, $\mathrm{Var}(2X-3Y)$.

Задача 3 [A] Проверьте независимость в двух таблицах (строки $Y=0,1$; столбцы $X=0,1$):

(1) $p(0,0)=0.2$, $p(1,0)=0.3$, $p(0,1)=0.2$, $p(1,1)=0.3$;
(2) $p(0,0)=0.1$, $p(1,0)=0.4$, $p(0,1)=0.3$, $p(1,1)=0.2$.
(Первый индекс — значение X, второй — значение Y.)

Задача 4 [B] Пять студентов: время подготовки x (ч) $=1,2,3,4,5$ и балл $y=50,55,65,70,85$.

(а) Найдите $\bar{x}$, $\bar{y}$ и $\sum(x_i-\bar{x})(y_i-\bar{y})$.
(б) Найдите выборочную ковариацию и корреляцию.

Задача 5 [B] Активы: $\mu_1=9\%$, $\sigma_1=12\%$; $\mu_2=14\%$, $\sigma_2=20\%$; $\rho=0.2$. Портфель: 40% в актив 1 и 60% в актив 2.

(а) Найдите ожидаемую доходность и стандартное отклонение портфеля.
(б) Сравните σ_p со средневзвешенным стандартных отклонений. Что показывает разница?

Задача 6 [B] $\sigma_1=10\%$, $\sigma_2=15\%$, активы некоррелированы ($\rho=0$). При какой доле w актива 1 дисперсия портфеля минимальна? Чему равно σ_p?

Задача 7 [B] Для данных из задачи 4 расходы измерили не в часах, а в минутах ($x'=60x$), а баллы — в долях от максимума (допустим, максимум 100, $y'=y/100$). Как изменятся s_{xy} и r? Вычислите.

Задача 8 [B] $X\in\{0,1,2\}$ — число рекламаций за неделю, $Y\in\{1,2\}$ — смена. Совместные вероятности $p(x,y)$: $p(0,1)=0.1$, $p(1,1)=0.2$, $p(2,1)=0.1$, $p(0,2)=0.2$, $p(1,2)=0.3$, $p(2,2)=0.1$.

(а) Найдите маргинальные распределения и $\mathrm{E}[X]$, $\mathrm{E}[Y]$.
(б) Найдите $\mathrm{Cov}(X,Y)$ и ρ.
(в) Найдите условное распределение X при $Y=2$ и $\mathrm{E}[X\mid Y=2]$.

Задача 9 [B] Стоимость двух комплектующих: $\sigma_1=4$, $\sigma_2=6$. Найдите стандартное отклонение суммарной стоимости при $\rho=0.5$, $\rho=0$ и $\rho=-0.5$.

Задача 10 [B] Банк выдал 50 кредитов, у каждого $\sigma=2.0$ млн. Найдите стандартное отклонение средней прибыли при попарной корреляции $\rho=0$ и $\rho=0.2$; найдите предел при $n\to\infty$ для $\rho=0.2$.

Задача 11 [C] Докажите, что (а) $\mathrm{Cov}(X,Y)=\mathrm{E}[XY]-\mu_X\mu_Y$; (б) $\mathrm{Var}(X+Y)=\mathrm{Var}(X)+\mathrm{Var}(Y)+2\,\mathrm{Cov}(X,Y)$.

Задача 12 [C] Пусть $Y=aX+b$, $a\neq 0$. Покажите, что $\rho_{XY}=+1$ при $a>0$ и -1 при $a<0$.

Задача 13 [C] X принимает значения $-1,0,1$ с вероятностями $\frac14,\frac12,\frac14$, а $Y=X^2$. Найдите $\mathrm{Cov}(X,Y)$ и докажите, что X и Y зависимы.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 7

Выборочные распределения и центральная предельная теорема

Почему выборочное среднее колеблется, как измерить эту колеблемость и почему она почти всегда нормальна

Тема 7 по силлабусу · неделя 7 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- различать генеральную совокупность и выборку, параметр и статистику;
- объяснять, что выборочное среднее — случайная величина, и описывать его распределение (ожидание и стандартную ошибку);
- формулировать центральную предельную теорему (ЦПТ) и условия её применения;
- находить вероятности для $\bar{X}$ и $\hat{p}$ с помощью нормального распределения;
- определять объём выборки по требуемой точности и понимать, почему используют $n-1$ в выборочной дисперсии.

1 Генеральная совокупность, выборка, статистика

Генеральная совокупность — все объекты, о которых мы хотим узнать (все клиенты банка, все детали партии). *Выборка* — её часть, которую мы реально наблюдаем. *Параметр* — число, характеризующее совокупность (μ, σ, p); он фиксирован и обычно неизвестен. *Статистика* — число, вычисленное по выборке ($\bar{x}$, s, $\hat{p}$); оно известно, но *меняется от выборки к выборке*.

Чтобы выводы были надёжны, выборка должна быть случайной (каждый объект имеет известный ненулевой шанс попасть в неё). Простая случайная выборка из n независимых наблюдений обозначается $X_1, \dots, X_n$. Нерепрезентативная выборка (например, опрос только по телефону в рабочее время) даёт смещённые оценки, которые не исправить ростом n.

ВЫБОРОЧНОЕ РАСПРЕДЕЛЕНИЕ

Выборочное распределение статистики — это распределение значений, которые она принимает по всем возможным выборкам объёма n.

2 Выборочное среднее

Пусть $X_1, \dots, X_n$ независимы, $\mathrm{E}[X_i] = \mu$, $\mathrm{Var}(X_i) = \sigma^2$. Среднее $\bar{X} = \frac{1}{n}\sum X_i$. Из свойств лекции 4:

$$\mathrm{E}\left[\bar{X}\right] = \mu, \qquad \mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}, \qquad \mathrm{SE}(\bar{X}) = \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}. \tag{2.1}$$

Первое равенство означает, что $\bar{X}$ *несмещённая* оценка μ: в среднем по всем выборкам она попадает в цель. Второе: разброс уменьшается с ростом n, но медленно — чтобы уменьшить ошибку вдвое, нужна выборка вчетверо больше. Стандартное отклонение статистики называют *стандартной ошибкой* (standard error, SE).

ТИПИЧНАЯ ОШИБКА

σ — разброс отдельных наблюдений, $\text{SE} = \sigma/\sqrt{n}$ — разброс среднего. Это разные числа: в задачах про «среднее по выборке» делите на $\sqrt{n}$, в задачах про «одно наблюдение» — нет.

ПРИМЕР 1. ВЫБОРОЧНОЕ РАСПРЕДЕЛЕНИЕ НА МАЛОМ ПРИМЕРЕ

Совокупность $\{1, 2, 3\}$, $\mu = 2$, $\sigma^2 = 2/3$. Берём выборки по 2 элемента с возвращением (9 равновероятных пар). Среднее $\bar{x}$ принимает значения $1; 1.5; 2; 2.5; 3$ с вероятностями $\frac{1}{9}, \frac{2}{9}, \frac{3}{9}, \frac{2}{9}, \frac{1}{9}$. Ожидание $\text{E}\big[\bar{X}\big] = 2 = \mu$, дисперсия $\text{Var}(\bar{X}) = \frac{1}{3} = \frac{\sigma^2}{n} = \frac{2/3}{2}$ — формула (2.1) подтверждается прямым перебором.

Если выборка берётся без возвращения из конечной совокупности размера N и составляет заметную долю ($n/N > 5\%$), стандартную ошибку умножают на поправку $\sqrt{\frac{N-n}{N-1}}$. Например, $N = 500$, $n = 100$, $\sigma = 4$: $\text{SE} = 0.4 \cdot 0.895 = 0.358$ вместо 0.4.

3 Центральная предельная теорема

ЦПТ

Пусть $X_1, \dots, X_n$ — независимые одинаково распределённые величины с конечными μ и σ^2. Тогда при больших n распределение $\bar{X}$ приближённо нормально:

$$\bar{X} \;\approx\; N\!\left(\mu,\, \frac{\sigma^2}{n}\right), \qquad Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \approx N(0,1), \tag{3.1}$$

каким бы ни было исходное распределение. Аналогично для суммы: $\sum X_i \approx N(n\mu,\, n\sigma^2)$.

Практическое правило: $n \geq 30$ достаточно для умеренно скошенных распределений; для сильно скошенных или с выбросами нужно больше; если исходное распределение нормально, $\bar{X}$ нормально при любом n.

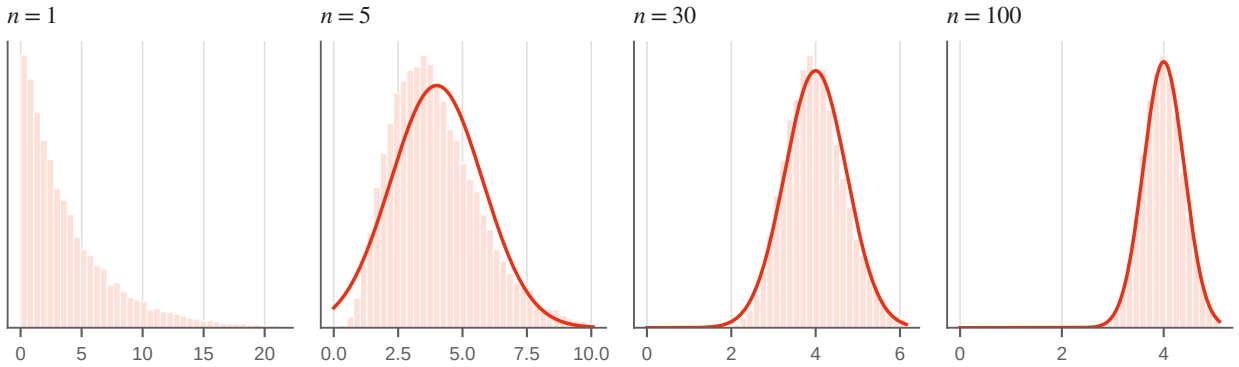


Рис. 1. Симуляция: распределение выборочного среднего из экспоненциальной совокупности ($\mu = \sigma = 4$) по 20 000 выборок. При $n = 1$ — сильно скошенное; при $n = 30$ почти колоколообразное; красная линия — нормальное приближение $N(4, (4/\sqrt{n})^2)$.

ПРИМЕР 2. СРОК ОБРАБОТКИ ЗАЯВКИ

Срок обработки кредитной заявки: $\mu = 12$ дней, $\sigma = 4$. Выборка $n = 36$ заявок. SE $= 4/6 = 0.667$. $P(\bar{X} > 13) = P(Z > 1.5) = 0.0668$. $P(11 < \bar{X} < 13) = P(-1.5 < Z < 1.5) = 0.8664$. Среднее по 36 заявкам в 95% случаев лежит в пределах $12 \pm 1.96 \cdot 0.667$, то есть от 10.69 до 13.31 дня. Заметьте: для одной заявки $P(X > 13)$ существенно больше (около 40% при нормальном X).

ПРИМЕР 3. АСИММЕТРИЧНАЯ СОВОКУПНОСТЬ

Время ожидания экспоненциально со средним 4 минуты. $n = 40$, SE $= 4/\sqrt{40} = 0.632$. $P(\bar{X} > 5) \approx P(Z > 1.58) = 0.0569$. Точное значение (сумма экспоненциальных величин имеет гамма-распределение) 0.0646; расхождение остаётся из-за заметной асимметрии, но порядок величины верен.

4 Выборочная доля

Для доли $\hat{p} = X/n$, где $X \sim \text{Bin}(n, p)$ — число «успехов» в выборке, по ЦПТ (нормальное приближение биномиального, лекция 5):

$$\text{E}[\hat{p}] = p, \qquad \text{SE}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}, \qquad \hat{p} \approx N\left(p,\ \frac{p(1-p)}{n}\right) \text{ при } np \geq 10,\ n(1-p) \geq 10. \tag{4.1}$$

ПРИМЕР 4. УДОВЛЕТВОРЁННОСТЬ КЛИЕНТОВ

Среди клиентов банка 40% удовлетворены сервисом. Опрошено $n = 100$. SE $= \sqrt{0.4 \cdot 0.6/100} = 0.049$. $P(\hat{p} > 0.50) = P(Z > 2.04) = 0.0206$. $P(0.35 < \hat{p} < 0.45) = P(|Z| < 1.02) = 0.6926$: две трети выборок дают долю в пределах ± 5 п.п. от истинной.

5 Объём выборки и точность

Допустим, нужно, чтобы выборочное среднее отличалось от μ не более чем на E с вероятностью 95%. Условие $1.96\,\sigma/\sqrt{n} \le E$ даёт

$$n \ge \left(\frac{1.96\,\sigma}{E}\right)^2. \tag{5.1}$$

Для $\sigma = 4$ дня и $E = 1$ день: $n \ge (7.84)^2 = 61.5$, то есть $n = 62$. Для долей используют $n \ge \dfrac{1.96^2\,p(1-p)}{E^2}$, при неизвестном p берут наихудший случай $p = 0.5$: для $E = 0.03$ (3 п.п.) получаем $n \ge 1067.1$, то есть 1068 респондентов. Это число объясняет, почему социологические опросы обычно содержат около тысячи человек.

6 Выборочная дисперсия и деление на $n - 1$

Выборочная дисперсия $s^2 = \dfrac{\sum (X_i - \bar{X})^2}{n-1}$ — несмещённая оценка σ^2: $\mathrm{E}[s^2] = \sigma^2$. Если делить на n, оценка систематически занижена, так как отклонения считаются от $\bar{X}$, а не от неизвестного μ: выборка «ближе к своему среднему», чем к μ.

ПРИМЕР 5. ПРОВЕРКА НА МАЛОЙ СОВОКУПНОСТИ

В примере выше ($\{1, 2, 3\}$, выборки по 2 с возвращением) $\sigma^2 = 0.667$. Среднее значение s^2 с делителем $n - 1 = 1$ равно $0.667 = \sigma^2$, а с делителем $n = 2$ — 0.333, вдвое меньше.

ЗАПОМНИТЕ

Выборочное распределение s^2 (точнее, $(n-1)s^2/\sigma^2$) для нормальной совокупности — хи-квадрат с $n - 1$ степенями свободы. Оно потребуется в лекции 11.

7 Ключевые термины

Термин	*English*	Смысл
Генеральная совокупность	*Population*	все объекты исследования
Выборка	*Sample*	наблюдаемая часть совокупности
Параметр / статистика	*Parameter / statistic*	μ, σ, p / $\bar{x}, s, \hat{p}$
Выборочное распределение	*Sampling distribution*	распределение статистики по всем выборкам
Стандартная ошибка	*Standard error*	$\sigma/\sqrt{n}$; $\sqrt{p(1-p)/n}$
Несмещённость	*Unbiasedness*	$\mathrm{E}[\text{оценка}] = \text{параметр}$
ЦПТ	*Central limit theorem*	$\bar{X} \approx N(\mu, \sigma^2/n)$

Формулы лекции 7

$$\mathrm{E}\big[\bar{X}\big] = \mu, \quad \mathrm{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}, \quad Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \approx N(0,1);$$

$$\mathrm{E}[\hat{p}] = p, \quad \mathrm{SE}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}};$$

$$n \geq \Big(\frac{1.96\sigma}{E}\Big)^2, \qquad n \geq \frac{1.96^2 p(1-p)}{E^2}; \qquad s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}.$$

8 Задачи для самостоятельного решения

Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Средний чек в сети кафе $\mu = 50$ тыс. сум, $\sigma = 12$. Из чеков берут выборку $n = 36$.

(а) Найдите ожидание и стандартную ошибку $\bar{X}$.
(б) Найдите $P(\bar{X} > 53)$ и $P(48 < \bar{X} < 52)$.

Задача 2 [A] $\sigma = 20$. Найдите стандартную ошибку среднего при $n = 25$ и $n = 100$. Какой нужен объём выборки, чтобы SE $= 1$?

Задача 3 [A] Доля клиентов с мобильным приложением $p = 0.30$. Опрошено $n = 200$. Найдите $\mathrm{SE}(\hat{p})$, $P(\hat{p} > 0.35)$ и $P(0.28 < \hat{p} < 0.32)$.

Задача 4 [B] Размер депозита сильно скошен вправо: $\mu = 8$ млн, $\sigma = 5$ млн. Выборка $n = 50$ депозитов.

(а) Можно ли пользоваться нормальным распределением для $\bar{X}$? Обоснуйте.
(б) Найдите $P(\bar{X} < 7)$ и $P(\bar{X} > 9.5)$.
(в) Можно ли так же найти $P(X < 7)$ для одного депозита?

Задача 5 [B] Каждая из 100 транзакций имеет $\mu = 2$ млн сум и $\sigma = 1.5$ млн, транзакции независимы. Найдите приближённую вероятность того, что суммарный объём превысит 230 млн.

Задача 6 [B] Нужно оценить среднее время решения обращения ($\sigma \approx 15$ минут) с точностью $E = 2$ минуты при уверенности 95%; затем оценить долю довольных клиентов с точностью ± 0.04.

(а) Найдите необходимый n для среднего.
(б) Как изменится n, если требуемая точность $E = 1$ минута?
(в) Найдите n для доли при неизвестном p и при $p \approx 0.2$.

Задача 7 [B] Доля брака на линии $p = 0.05$. Проверяют партию $n = 400$ деталей.

(а) Проверьте условия нормального приближения и найдите $\mathrm{SE}(\hat{p})$.
(б) Найдите вероятность того, что доля брака в выборке превысит 7%.
(в) Найдите вероятность того, что доля брака в выборке окажется ниже 3%.

Задача 8 [B] Совокупность $\{2, 4, 6\}$; берутся выборки по 2 с возвращением (9 равновероятных).

(а) Найдите μ и σ^2.
(б) Запишите распределение $\bar{X}$ и проверьте $\mathrm{E}\left[\bar{X}\right] = \mu$, $\mathrm{Var}(\bar{X}) = \sigma^2/2$.
(в) Найдите среднее значение s^2 (с делителем $n-1$).

Задача 9 [B] Из совокупности $N = 400$ клиентов с $\sigma = 20$ без возвращения берут выборку $n = 100$. Найдите стандартную ошибку среднего с учётом поправки на конечную совокупность и без неё.

Задача 10 [C] Выведите $\mathrm{Var}(\bar{X}) = \sigma^2/n$ и покажите, что $\mathrm{E}[s^2] = \sigma^2$, если $s^2 = \frac{1}{n-1}\sum(X_i - \bar{X})^2$.

Задача 11 [C] Закон больших чисел. Для $\sigma = 4$ и $\varepsilon = 1$ неравенство Чебышёва даёт $P(|\bar{X} - \mu| \geq \varepsilon) \leq \sigma^2/(n\varepsilon^2)$. Оцените вероятность при $n = 100$ и сравните с нормальным приближением. К чему стремится вероятность при $n \to \infty$?

Задача 12 [C] Интернет-опрос в Telegram-канале банка показал 80% довольных клиентов при $n = 5000$. Допустим, $\mathrm{SE} \approx 0.006$. Означает ли это, что доля довольных среди всех клиентов лежит в $0.80 \pm 2 \cdot 0.006$? Объясните.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 8

ЦПТ в применении и повторение перед midterm

Приложения центральной предельной теоремы, карта курса (недели 1–7), типичные ошибки и пробный вариант

Тема 8 по силлабусу · неделя 8 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- применять ЦПТ для сумм, средних и долей в практических задачах (риск портфеля, запасы, контроль качества);
- выбирать нужную модель и формулу по формулировке задачи;
- находить и исправлять типичные ошибки в расчётах;
- решить пробный вариант midterm в формате экзамена, укладываясь во время.

1 Приложения ЦПТ

Напомним главный результат лекции 7: для независимых одинаково распределённых величин с μ и σ

$$\bar{X} \approx N\Big(\mu, \frac{\sigma^2}{n}\Big), \qquad \sum_{i=1}^{n} X_i \approx N(n\mu,\ n\sigma^2), \qquad \hat{p} \approx N\Big(p, \frac{p(1-p)}{n}\Big).$$

Три шага решения любой такой задачи: (1) выписать μ, σ, n и решить, о чём вопрос (о сумме, среднем или доле); (2) найти параметры приближающего нормального распределения (для суммы $n\mu$ и $\sigma\sqrt{n}$; для среднего μ и $\sigma/\sqrt{n}$); (3) стандартизировать и найти вероятность по таблице.

ПРИМЕР 1. ЛИМИТ НАЛИЧНЫХ В БАНКОМАТЕ

Ежедневное снятие наличных одним клиентом: $\mu = 300$ тыс. сум, $\sigma = 200$ тыс. В банкомат приходит $n = 100$ независимых клиентов. Суммарное снятие $T \approx N(30\,000,\ 2000^2)$ (так как $\sigma\sqrt{n} = 200 \cdot 10 = 2000$). Банкомат содержит 33 000 тыс. Вероятность нехватки: $P(T > 33\,000) = P(Z > 1.5) = 0.0668$. Чтобы вероятность нехватки составила не более 1%, нужен запас $30\,000 + 2.326 \cdot 2000 = 34\,653$ тыс. сум.

ПРИМЕР 2. КОНТРОЛЬ КАЧЕСТВА ПО ДОЛЕ

Доля брака в производственном процессе — 8% при нормальной работе. Из партии берут 200 изделий и останавливают линию, если доля брака в выборке превышает 12%. $\text{SE} = \sqrt{0.08 \cdot 0.92/200} = 0.0192$. Ложная остановка (при нормальной работе): $P(\hat{p} > 0.12) = P(Z > 2.09) = 0.0183$.

ТИПИЧНАЯ ОШИБКА

Для суммы стандартное отклонение равно $\sigma\sqrt{n}$, для среднего — $\sigma/\sqrt{n}$. Самая частая ошибка на экзамене — перепутать их. Проверка здравого смысла: среднее колеблется *меньше* отдельного значения, сумма — *больше*.

2 Карта курса: недели 1–7

Неделя	Задача	Инструмент
1	описать данные	$\bar{x},\ s,$ Me, $Q_1, Q_3,\ IQR$; границы выбросов $Q_1 - 1.5IQR$, $Q_3 + 1.5IQR$; $CV = s/\bar{x}$; r
2	вероятность события	$P(A \cup B)$, независимость, C_n^k, A_n^k, деревья
3	обновление по данным	$P(A \mid B)$, полная вероятность, Байес, шансы
4	дискретная случайная величина	$\mathrm{E}[X]$, Var, Bin, Geom, Pois
5	непрерывная величина	$z = (x-\mu)/\sigma$, Φ, U, Exp, приближение Bin нормальным
6	две величины сразу	Cov, ρ, $\mathrm{Var}(X \pm Y)$, портфель
7	выборка $\to$ совокупность	$\mathrm{SE} = \sigma/\sqrt{n}$, ЦПТ, $\hat{p}$, объём выборки

2.1 Как выбрать модель

- «Сколько успехов в n независимых испытаниях» — $\mathrm{Bin}(n, p)$; при $np, n(1-p) \geq 10$ — нормальное приближение.
- «Сколько событий за час/день без верхнего предела» — Пуассон; «сколько ждать следующего» — экспоненциальное.
- «Измеряется на непрерывной шкале, симметричен, колоколообразен» — нормальное; вопрос о *среднем* большой выборки — всегда нормальное по ЦПТ.
- «Известно что-то, найдите вероятность причины» — Байес.
- «Две величины, найдите риск суммы» — $\mathrm{Var}(X+Y)$ с ковариацией.

2.2 Типичные ошибки

1. Путают $P(A \mid B)$ и $P(B \mid A)$ (лекция 3).
2. Применяют биномиальную модель без независимости или без постоянной p.
3. Складывают стандартные отклонения вместо дисперсий; забывают, что $\mathrm{Var}(X-Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$ для независимых.
4. Используют σ вместо $\sigma/\sqrt{n}$ для среднего.
5. Делят на n вместо $n-1$ при вычислении s^2 по выборке.
6. Считают, что $\rho = 0$ означает независимость, а высокая корреляция — причинность.
7. При z-оценках путают знак: $P(Z > z) = 1 - \Phi(z)$.
8. Не проверяют условия применимости (нормальное приближение, независимость наблюдений, репрезентативность).

3 Формат пробного варианта

В конце раздела — пробный midterm из 12 задач разной сложности. Рекомендации: решайте на время (90 минут), пользуясь только калькулятором и таблицами из приложения; сначала выписывайте «дано» и «найти», затем формулу и подстановку, и лишь потом число; записывайте ответ с единицами и интерпретацией (словом, что он означает). Решения (в общем файле для преподавателя) проверяйте после попытки, а не до.

Что нужно помнить к midterm

$$s^2 = \tfrac{1}{n-1}\sum (x_i - \bar{x})^2; \quad IQR = Q_3 - Q_1; \quad P(A \cup B) = P(A) + P(B) - P(A \cap B);$$

$$P(A \mid B) = \tfrac{P(A \cap B)}{P(B)}; \quad P(A_i \mid B) = \tfrac{P(B \mid A_i)P(A_i)}{\sum_j P(B \mid A_j)P(A_j)};$$

$$\mathrm{E}[X] = \sum xp(x); \quad \mathrm{Var}(X) = \mathrm{E}[X^2] - \mu^2;$$

$$\text{Bin}: \ C_n^k p^k (1-p)^{n-k}; \quad \text{Pois}: \ e^{-\lambda}\lambda^k / k!;$$

$$z = \tfrac{x-\mu}{\sigma}; \quad \mathrm{Var}(X \pm Y) = \mathrm{Var}\, X + \mathrm{Var}\, Y \pm 2\,\mathrm{Cov};$$

$$\mathrm{SE}(\bar{X}) = \tfrac{\sigma}{\sqrt{n}}; \quad \mathrm{SE}(\hat{p}) = \sqrt{\tfrac{p(1-p)}{n}}.$$

4 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [B] Время (минуты), потраченное десятью клиентами на оформление услуги: $12,\ 15,\ 15,\ 18,\ 20,\ 22,\ 25,\ 28,\ 30,\ 45$.

(а) Найдите среднее, медиану, дисперсию и стандартное отклонение.
(б) Найдите Q_1, Q_3, IQR и границы выбросов. Есть ли выбросы?
(в) Найдите коэффициент асимметрии $Sk = 3(\bar{x} - \mathrm{Me})/s$ и объясните знак. Как изменятся среднее и медиана без значения 45?

Задача 2 [A] $P(A) = 0.5$, $P(B) = 0.4$, $P(A \cap B) = 0.2$. Найдите $P(A \cup B)$, $P(\overline{A} \cap \overline{B})$, $P(A \mid B)$ и проверьте независимость.

Задача 3 [B] Интернет-магазин: 60% заказов через сайт (возвращают 5%), 40% через приложение (возвращают 10%).

(а) Какова вероятность того, что заказ будет возвращён?
(б) Заказ возвращён. Какова вероятность того, что он сделан через приложение?

Задача 4 [A] В группе 10 студентов (5 юношей и 5 девушек). Случайно выбирают комиссию из 3

человек. Какова вероятность того, что в ней есть хотя бы одна девушка?

Задача 5 [B] Клиент оформляет подписку с вероятностью 0.2, независимо. Предложение сделано 15 клиентам. Найдите $\mathrm{E}[X]$, $\mathrm{Var}(X)$, вероятность того, что подписок нет, и вероятность не менее четырёх подписок.

Задача 6 [B] В среднем 2.5 обращения в минуту (Пуассон). Найдите вероятность не более одного обращения в минуту и не менее трёх.

Задача 7 [B] Балл теста $X \sim N(500, 50^2)$.

(а) Найдите долю набравших более 580.
(б) Найдите долю набравших от 450 до 550.
(в) Найдите 90-й процентиль.

Задача 8 [B] Игра: выигрыш $+50$ с вероятностью 0.3 и проигрыш -10 с вероятностью 0.7. Найдите ожидаемый результат и стандартное отклонение. Стоит ли играть многократно?

Задача 9 [B] Две доходности с корреляцией $\rho = -0.2$ имеют $\sigma_1 = 8\%$, $\sigma_2 = 12\%$. Найдите риск портфеля 50/50.

Задача 10 [B] Среднее число покупок на клиента $\mu = 100$, $\sigma = 24$; выборка $n = 64$. Найдите SE, $P(\bar{X} < 95)$ и $P(97 < \bar{X} < 103)$.

Задача 11 [B] Доля клиентов, отказавшихся от услуги за год, $p = 0.25$. Выборка $n = 300$. Найдите $\mathrm{SE}(\hat{p})$ и $P(\hat{p} > 0.30)$.

Задача 12 [C] Для условий задачи 10 ($\sigma = 24$) найдите объём выборки, при котором с вероятностью 95% выборочное среднее отличается от μ не более чем на 4. Затем покажите, как изменится n при желании уменьшить допустимую ошибку вдвое, и объясните это в терминах SE.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 9

Оценивание и доверительные интервалы

Как вместо одного числа сообщить диапазон правдоподобных значений параметра и честно измерить неопределённость

Тема 9 по силлабусу · неделя 9 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- различать точечную и интервальную оценки и объяснять свойства хорошей оценки;
- строить доверительные интервалы для среднего (при известной и неизвестной σ) и для доли;
- использовать t-распределение, находить число степеней свободы и критические значения;
- правильно интерпретировать уровень доверия и не допускать типичных ошибок формулировки;
- оценивать, как ширина интервала зависит от n, σ и уровня доверия; определять нужный объём выборки.

1 Точечная и интервальная оценка

Точечная оценка — одно число, вычисленное по выборке: $\bar{x}$ для μ, $\hat{p}$ для p, s^2 для σ^2. Хорошая оценка:

- *несмещённая* — её среднее по всем выборкам равно параметру (лекция 7);
- *состоятельная* — при росте n приближается к параметру;
- *эффективная* — имеет наименьшую дисперсию среди несмещённых.

Но одно число ничего не говорит о точности. Выборочное среднее 35.75 может быть близко к μ или далеко — это зависит от SE. *Доверительный интервал* (ДИ) даёт диапазон правдоподобных значений параметра вместе с мерой надёжности метода.

ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ

Интервал с уровнем доверия $1-\alpha$ строится по выборке так, что в долгосрочном периоде (при многократном повторении выборки) доля интервалов, накрывающих истинный параметр, равна $1-\alpha$. Общий вид:

$$\text{оценка} \;\pm\; \underbrace{\text{критическое значение} \times \text{SE}}_{\text{предельная ошибка } E}. \tag{1.1}$$

2 ДИ для среднего при известной σ

Если σ известна (редко, но это удобная отправная точка) и либо совокупность нормальна, либо $n \geq 30$, то по ЦПТ

$$\bar{x} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \qquad z_{0.05} = 1.645\ (90\%), \quad z_{0.025} = 1.960\ (95\%), \quad z_{0.005} = 2.576\ (99\%). \tag{2.1}$$

ПРИМЕР 1. СРОК ОБРАБОТКИ ЗАЯВКИ

Выборка $n = 36$ заявок, $\bar{x} = 12.4$ дня, $\sigma = 4$. SE $= 4/6 = 0.667$. 95% ДИ: $12.4 \pm 1.96 \cdot 0.667 = 12.4 \pm 1.31$, то есть $(11.09;\ 13.71)$. 99% ДИ: $12.4 \pm 2.576 \cdot 0.667 = (10.68;\ 14.12)$ — шире.

3 Как правильно понимать уровень доверия

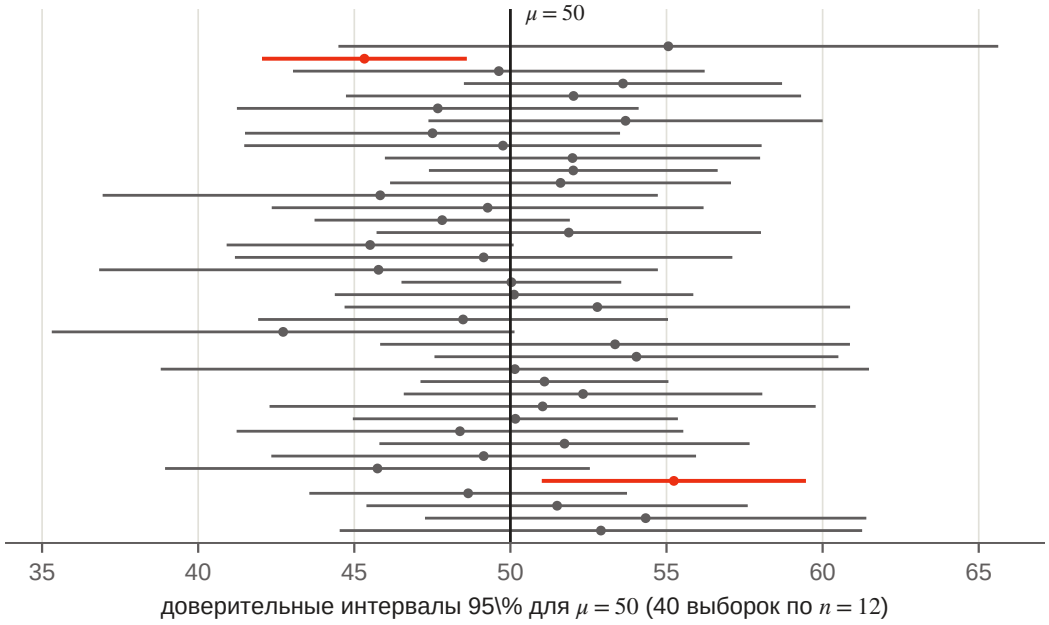


Рис. 1. 40 независимых выборок из $N(50, 10^2)$ по 12 наблюдений; каждая даёт свой 95%-й интервал. Два из сорока (красные) не накрыли $\mu = 50$ — ровно то, что допускает 95% доверия.

Параметр μ фиксирован, случайны границы интервала. «95% доверия» — свойство *метода*: 95% построенных этим способом интервалов накрывают μ. Для конкретного вычисленного интервала $(11.09; 13.71)$ неверно говорить «с вероятностью 95% μ лежит в этом интервале» (он либо содержит μ, либо нет), но допустимо: «мы на 95% уверены, что интервал накрывает μ» или «значения μ от 11.1 до 13.7 согласуются с данными».

ТИПИЧНАЯ ОШИБКА

Неверно: «95% наблюдений лежат в доверительном интервале». ДИ — для *среднего*, а не для отдельных наблюдений; границы для 95% наблюдений (интервал предсказания) намного шире.

4 Неизвестная σ: t-распределение

Обычно σ неизвестна, и её заменяют выборочным s. Но s само случайно, и особенно при малых n. Статистика

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}} \tag{4.1}$$

имеет не нормальное, а *распределение Стьюдента* с $\nu = n - 1$ степенями свободы (если совокупность нормальна). Оно симметрично, как нормальное, но имеет более «тяжёлые хвосты»; при росте ν приближается к $N(0, 1)$.

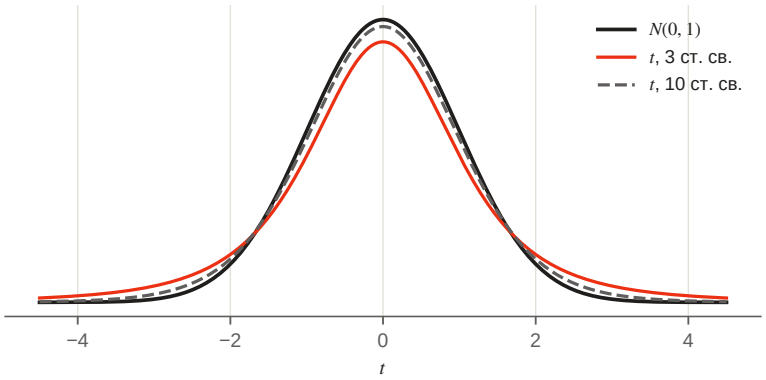


Рис. 2. Распределение Стьюдента при малом числе степеней свободы шире нормального; при 10 степенях свободы уже почти не отличается.

ДИ для среднего при неизвестной σ

$$\bar{x} \pm t_{\alpha/2,\, n-1} \frac{s}{\sqrt{n}}.$$

Критические значения $t_{0.025,\nu}$ (для 95%): $\nu = 4$: 2.776; 9: 2.262; 11: 2.201; 14: 2.145; 24: 2.064; 29: 2.045; 59: 2.001; 99: 1.984; ∞: 1.960 (полная таблица в приложении).

ПРИМЕР 2. КОФЕЙНИ: МЕСЯЧНАЯ ВЫРУЧКА

Из лекции 1: 12 филиалов сети кофеен, $\bar{x} = 35.75$, $s = 20.33$ (месячная выручка филиала, млн сум). SE $= 20.33/\sqrt{12} = 5.869$, $t_{0.025,11} = 2.201$, $E = 2.201 \cdot 5.869 = 12.92$. 95% ДИ: $35.75 \pm 12.92 = (22.83;\ 48.67)$. 99% ДИ ($t_{0.005,11} = 3.106$): $35.75 \pm 18.23 = (17.52;\ 53.98)$. Если бы по ошибке использовали $z = 1.96$, предельная ошибка составила бы 11.50 вместо 12.92 — интервал был бы слишком узким и «обещал» бы больше, чем есть на самом деле.

ЗАПОМНИТЕ

Условия: (1) выборка случайная, наблюдения независимы; (2) совокупность примерно нормальна *или* n достаточно велико ($\gtrsim 30$). При $n < 30$ и явной асимметрии или выбросах t-интервал ненадёжен: в примере с кофейнями выброс (филиал 12) сильно влияет на $\bar{x}$ и s, и результат стоит дополнить интервалом без него.

5 От чего зависит ширина интервала

Предельная ошибка $E = t \cdot s/\sqrt{n}$ уменьшается, когда: растёт n (в $\sqrt{n}$ раз — вчетверо больше данных для вдвое более узкого интервала); уменьшается разброс s; уменьшается уровень доверия (90% уже, 99% шире). Выбор уровня доверия — компромисс между уверенностью и точностью; по умолчанию 95%.

6 ДИ для доли

ДИ для доли

$$\hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \qquad (\text{при } n\hat{p} \geq 10,\ n(1-\hat{p}) \geq 10).$$

ПРИМЕР 3. ДОЛЯ ДОВОЛЬНЫХ КЛИЕНТОВ

Из 400 опрошенных довольны 240: $\hat{p} = 0.60$, SE $= \sqrt{0.6 \cdot 0.4/400} = 0.0245$. 95% ДИ: $0.60 \pm 1.96 \cdot 0.0245 = 0.60 \pm 0.048 = (0.552;\ 0.648)$. 90% ДИ: $(0.560;\ 0.640)$.

Для малых выборок и крайних долей простой интервал ненадёжен. Для $n = 20$, $x = 2$ ($\hat{p} = 0.10$) он даёт $(-0.031;\ 0.231)$ — с отрицательной нижней границей; интервал Уилсона $(0.028;\ 0.301)$ корректнее. Правило: если не выполнены условия $n\hat{p} \geq 10$ и $n(1-\hat{p}) \geq 10$, используйте интервал Уилсона или точный.

7 Объём выборки для заданной точности

$$n \geq \left(\frac{z_{\alpha/2}\,\sigma}{E}\right)^2, \qquad n \geq \frac{z_{\alpha/2}^2\,\hat{p}(1-\hat{p})}{E^2} \ \text{(в худшем случае } \hat{p} = 0.5). \tag{7.1}$$

Для среднего с $\sigma \approx 20$, $E = 3$ и 99% доверия: $n \geq (2.576 \cdot 20/3)^2 = 294.9$, то есть 295. Для доли с $E = 0.03$ при предварительной оценке $p \approx 0.6$: $n \geq 1.96^2 \cdot 0.24/0.0009 = 1024.4$, то есть 1025; без предварительной оценки (худший случай) 1068. Значение σ берут из пилотной выборки или прошлых данных; при t-интервале итоговый n чуть больше.

8 ДИ для дисперсии (для информации)

Если совокупность нормальна, то $(n-1)s^2/\sigma^2$ имеет χ^2-распределение с $n-1$ степенями свободы, и

$$\frac{(n-1)s^2}{\chi^2_{\alpha/2,\,n-1}} \ \leq\ \sigma^2 \ \leq\ \frac{(n-1)s^2}{\chi^2_{1-\alpha/2,\,n-1}}. \tag{8.1}$$

Для кофеен: $s^2 = 413.3$, $\chi^2_{0.025,11} = 21.92$, $\chi^2_{0.975,11} = 3.816$: $\sigma^2 \in (207.4;\ 1191.5)$, то есть $\sigma \in (14.4;\ 34.5)$. Интервал очень широк: при $n = 12$ разброс оценивается плохо. Этот интервал чувствителен к отклонениям от нормальности.

9 Ключевые термины

Термин	*English*	Смысл
Точечная оценка	*Point estimate*	одно число по выборке
Доверительный интервал	*Confidence interval*	оценка $\pm$ критическое $\times$ SE
Уровень доверия	*Confidence level*	$1-\alpha$
Предельная ошибка	*Margin of error*	E — половина ширины ДИ
Степени свободы	*Degrees of freedom*	$\nu = n-1$ для среднего
Распределение Стьюдента	*Student's t*	тяжёлые хвосты, $\to N(0,1)$

Формулы лекции 9

$$\bar{x} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \qquad \bar{x} \pm t_{\alpha/2,\,n-1}\frac{s}{\sqrt{n}}, \qquad \hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}};$$

$$n \geq \left(\frac{z\sigma}{E}\right)^2, \qquad n \geq \frac{z^2\hat{p}(1-\hat{p})}{E^2}.$$

10 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Средний балл по выборке из 49 студентов равен 82, $\sigma = 14$. Постройте 95% ДИ для среднего.

Задача 2 [A] Найдите по таблице критическое значение t для: (а) 95% ДИ, $n = 10$; (б) 99% ДИ, $n = 25$; (в) 90% ДИ, $n = 16$.

Задача 3 [A] Выборка из 25 клиентов: $\bar{x} = 82$ тыс. сум, $s = 10$. Постройте 95% ДИ для среднего чека. Почему здесь используется t, а не z?

Задача 4 [B] Стоимость 16 случайно выбранных заказов: $\bar{x} = 250$ тыс., $s = 40$ тыс. Постройте 99% ДИ для средней стоимости заказа и укажите, что произойдёт с шириной при переходе к 95%.

Задача 5 [B] Из 500 проверенных операций 85 помечены как сомнительные. Постройте 95% и 90% ДИ для доли сомнительных операций.

Задача 6 [B] Время доставки 8 заказов (минуты): $18, 22, 25, 21, 30, 24, 27, 23$.

(а) Найдите $\bar{x}$ и s.
(б) Постройте 95% ДИ для среднего времени доставки.
(в) Какое допущение необходимо и как его проверить на таких данных?

Задача 7 [B] Для оценки среднего времени ответа ($\sigma \approx 20$ с) нужна предельная ошибка $E = 3$ с. Найдите n для 95% и 99% доверия. Затем найдите n для оценки доли довольных клиентов с $E = 0.03$ при 95% доверия, если (а) p неизвестна; (б) предварительно $p \approx 0.6$.

Задача 8 [B] Аналитик пишет: «С вероятностью 95% среднее время обработки лежит в интервале $(22.8;\ 48.7)$» и «95% филиалов имеют выручку в этом интервале». Найдите и исправьте ошибки в обоих утверждениях.

Задача 9 [B] Как изменится ширина ДИ для среднего (σ известна), если (а) n вырастет вчетверо; (б) уровень доверия изменится с 95% на 99%; (в) σ уменьшится на 20%?

Задача 10 [B] В выборке из 80 заёмщиков 6 допустили просрочку. Проверьте условия, постройте простой 95% ДИ для доли и интервал Уилсона. Сравните и прокомментируйте.

Задача 11 [C] Выведите ДИ для μ при известной σ из условия $P(-z_{\alpha/2} < Z < z_{\alpha/2}) = 1 - \alpha$, где $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$.

Задача 12 [C] Для выборки из $n = 2$ наблюдений $t_{0.025,1} = 12.706$. Объясните, почему 95% ДИ при $n = 2$ почти бесполезен, а при $n = 100$ ($t = 1.984$) практически совпадает с z-интервалом. Какую роль здесь играет оценка s?

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 10

Проверка гипотез I: логика, p-значение и ошибки

Как формально решить, согласуются ли данные с утверждением о параметре, и чем рискует исследователь

Тема 10 по силлабусу · неделя 10 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- формулировать нулевую и альтернативную гипотезы и выбирать односторонний или двусторонний критерий;
- проводить z- и t-тест для среднего и z-тест для доли по пяти шагам;
- вычислять и правильно интерпретировать p-значение;
- объяснять ошибки I и II рода, уровень значимости и мощность;
- связывать проверку гипотез с доверительными интервалами и отличать статистическую значимость от практической.

1 Логика проверки гипотез

Проверка гипотез — это формализованный ответ на вопрос «согласуются ли данные с утверждением о совокупности?». Схема похожа на судебную презумпцию невиновности: нулевую гипотезу не отвергают, пока данные не дадут достаточно сильных доказательств против неё.

ГИПОТЕЗЫ

Нулевая гипотеза H_0 — утверждение «без эффекта» (знак равенства): $\mu = \mu_0$, $p = p_0$. *Альтернативная гипотеза* H_1 (или H_a) — то, что мы хотим доказать: двусторонняя $\mu \neq \mu_0$; односторонняя $\mu > \mu_0$ или $\mu < \mu_0$. Направление выбирают *до* просмотра данных, исходя из вопроса исследования.

ПРИМЕР 1. ФОРМУЛИРОВКИ

Банк обещает обработку заявки в среднем за 12 дней. Клиенты жалуются, что дольше. $H_0 : \mu = 12$, $H_1 : \mu > 12$ (односторонняя). Если менеджер хочет узнать, изменился ли срок вообще: $H_1 : \mu \neq 12$.

1.1 Пять шагов

1. Сформулировать H_0, H_1 и выбрать уровень значимости α (обычно 0.05).
2. Проверить условия (случайность и независимость, нормальность или большой n).

3. Вычислить статистику критерия.
4. Найти p-значение (или критическое значение).
5. Принять решение и сформулировать вывод на языке задачи.

p-ЗНАЧЕНИЕ

p-значение — вероятность (при условии, что H_0 верна) получить значение статистики такое же или более экстремальное, чем наблюдаемое. Малое p означает: наблюдаемый результат трудно объяснить случайностью при H_0. Решение: если $p \le \alpha$, H_0 отвергается; иначе нет оснований её отвергнуть.

ТИПИЧНАЯ ОШИБКА

p-значение — *не* вероятность того, что H_0 верна, и не вероятность ошибки решения. Это $P(\text{данные} \mid H_0)$, а не $P(H_0 \mid \text{данные})$ — та же перестановка условий, что в лекции 3. Кроме того, «не отвергаем H_0» не означает «доказали H_0»: возможно, данных мало.

2 Критерий для среднего

2.1 z-тест (известная σ)

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}. \tag{2.1}$$

При верной H_0 статистика приближённо $N(0,1)$. p-значение: двустороннее $2P(Z > |z|)$; правостороннее $P(Z > z)$; левостороннее $P(Z < z)$. Критические значения при $\alpha = 0.05$: ± 1.96 (двусторонний), 1.645 (односторонний).

ПРИМЕР 2. СРОК ОБРАБОТКИ ЗАЯВКИ, $\sigma = 4$, $n = 36$

$H_0 : \mu = 12$, $H_1 : \mu \neq 12$, $\alpha = 0.05$. (а) $\bar{x} = 12.4$: $z = \dfrac{0.4}{0.667} = 0.60$, $p = 2 \cdot 0.274 = 0.549 > 0.05$ — оснований отвергнуть H_0 нет. (б) $\bar{x} = 13.6$: $z = \dfrac{1.6}{0.667} = 2.40$, $p = 2 \cdot 0.0082 = 0.0164 < 0.05$ — H_0 отвергается: средний срок отличается от 12 дней.

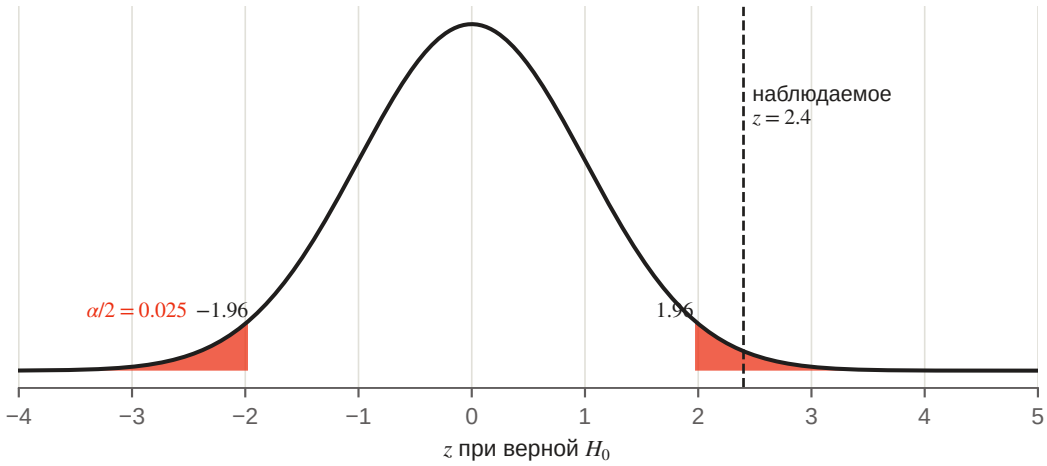


Рис. 1. Двусторонний тест при $\alpha = 0.05$: области отклонения — по 2.5% в каждом хвосте. Наблюдаемое $z = 2.4$ попадает в правую область отклонения; p-значение — площадь за $|z| = 2.4$ в обоих хвостах.

2.2 t-тест (неизвестная σ)

Заменяем σ на s и берём t-распределение с $n - 1$ степенями свободы:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \qquad \nu = n - 1. \tag{2.2}$$

ПРИМЕР 3. ВЫРУЧКА ФИЛИАЛОВ

Сеть считает нормой месячную выручку 30 млн сум на филиал. По 12 филиалам $\bar{x} = 35.75$, $s = 20.33$. $H_0 : \mu = 30$, $H_1 : \mu \neq 30$. $t = \dfrac{5.75}{20.33/\sqrt{12}} = \dfrac{5.75}{5.869} = 0.98$, $\nu = 11$, $p = 0.348$. Критическое значение ± 2.201. Отвергнуть H_0 нельзя: разница в 5.75 млн вполне объясняется случайностью при таком разбросе. Заметим, что 95% ДИ $(22.83;\ 48.67)$ содержит 30.

ПРИМЕР 4. ОДНОСТОРОННИЙ ТЕСТ

Выборка $n = 25$, $\bar{x} = 48.2$, $s = 5$. $H_0 : \mu = 50$, $H_1 : \mu < 50$. $t = -1.8/1 = -1.80$, $\nu = 24$; $p = P(t_{24} < -1.80) = 0.042 < 0.05$ — отвергаем (критическое значение -1.711). Двусторонний тест дал бы $p = 0.084$ и не отверг бы H_0: выбор направления нужно делать заранее и обосновывать, а не подбирать под результат.

3 Критерий для доли

Для $H_0 : p = p_0$ стандартная ошибка вычисляется *по* p_0 (мы считаем H_0 верной):

$$z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}, \qquad \text{условие: } np_0 \geq 10,\ n(1 - p_0) \geq 10. \tag{3.1}$$

ПРИМЕР 5. БРАК НА ЛИНИИ

Допустимый уровень брака $p_0 = 0.10$. В выборке из 200 изделий 30 бракованных, $\hat{p} = 0.15$. $H_1 : p > 0.10$. $z = \dfrac{0.05}{\sqrt{0.09/200}} = \dfrac{0.05}{0.0212} = 2.36$, $p = 0.0092$. Отвергаем H_0: уровень брака превышает допустимый.

ПРИМЕР 6. УДОВЛЕТВОРЁННОСТЬ

Гипотеза «довольны ровно 50%» против $\neq$; 240 из 400 довольны. $z = \dfrac{0.10}{\sqrt{0.25/400}} = 4.00$, $p \approx 6 \cdot 10^{-5}$. Отвергаем H_0. (В ДИ для доли стандартную ошибку считают по $\hat{p}$, в тесте — по p_0.)

4 Ошибки I и II рода, уровень значимости и мощность

	H_0 верна	H_0 неверна
Не отвергаем H_0	верно $(1-\alpha)$	ошибка II рода (β)
Отвергаем H_0	ошибка I рода (α)	верно: **мощность** $1-\beta$

Уровень значимости $\alpha = P(\text{отвергнуть } H_0 \mid H_0 \text{ верна})$ — риск ложной тревоги, мы задаём его сами. *Мощность* $1-\beta$ — вероятность обнаружить эффект, когда он есть. Для двустороннего z-теста при истинном μ и $\delta = (\mu - \mu_0)/(\sigma/\sqrt{n})$ мощность равна $P(Z > 1.96 - \delta) + P(Z < -1.96 - \delta)$.

ПРИМЕР 7. МОЩНОСТЬ

$H_0 : \mu = 12$, $\sigma = 4$, $n = 36$, $\alpha = 0.05$. Если истинное $\mu = 13.5$: $\delta = 2.25$, мощность $= 0.614$ (ошибка II рода $\beta = 0.386$). При $\mu = 14$ мощность 0.851; при $\mu = 12.5$ только 0.117.



Рис. 2. Мощность двустороннего z-теста как функция истинного μ. При $\mu = 12$ (верная H_0) она равна $\alpha = 0.05$; чем больше эффект, тем выше мощность.

Мощность растёт при увеличении n, величины эффекта и α, а также при уменьшении σ. Для

мощности 80% и эффекта $\Delta = \mu - \mu_0$ требуется $n \approx \left(\dfrac{(z_{\alpha/2} + z_\beta)\sigma}{\Delta}\right)^2$, где $z_\beta = 0.8416$. Для $\Delta = 1.5$, $\sigma = 4$: $n = \left(\dfrac{2.80 \cdot 4}{1.5}\right)^2 = 55.8 \approx 56$.

ЗАПОМНИТЕ

Снижать α уменьшает риск ложной тревоги, но снижает мощность. Для одновременного снижения обеих ошибок нужно увеличивать n. Выбор α зависит от цены ошибок: для проверки безопасности лекарств ложное «одобрение» стоит дороже, чем для маркетинговой гипотезы.

5 Связь с доверительными интервалами

Двусторонний тест на уровне α отвергает $H_0 : \mu = \mu_0$ тогда и только тогда, когда μ_0 лежит вне $(1-\alpha)$-ДИ. В примере (б): 95% ДИ при $\bar{x} = 13.6$ равен $(12.29;\ 14.91)$, 12 лежит вне — тест отвергает; для (а) ДИ $(11.09;\ 13.71)$ содержит 12 — нет. ДИ информативнее: он показывает не только «да/нет», но и величину эффекта.

6 Значимость и практическая важность

При огромной выборке ничтожный эффект становится «статистически значимым»: $\bar{x} = 30.3$ против $\mu_0 = 30$ при $\sigma = 4$ и $n = 10\,000$ даёт $z = 7.5$, $p < 10^{-12}$, но разница в 0.3 (1%) может не иметь практического смысла. И наоборот: большой эффект на малой выборке может быть «незначимым» (низкая мощность). Всегда сообщайте размер эффекта и ДИ вместе с p.

Если проверяют много гипотез, то при $\alpha = 0.05$ около 5% из истинных нулевых будут «значимыми» случайно. 20 независимых тестов дают шанс хотя бы одной ложной тревоги $1 - 0.95^{20} = 64\%$. Для таких случаев применяют поправки (например, Бонферрони: α/m).

7 Ключевые термины

Термин	*English*	Смысл
Нулевая гипотеза	*Null hypothesis*	H_0 — «нет эффекта»
Альтернативная	*Alternative*	H_1 — что доказываем
Статистика критерия	*Test statistic*	z или t
p-значение	*p-value*	$P(\text{экстремальнее} \mid H_0)$
Уровень значимости	*Significance level*	$\alpha = P(\text{ош. I рода})$
Ошибка II рода	*Type II error*	β
Мощность	*Power*	$1 - \beta$

Формулы лекции 10

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}, \qquad t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}\ (\nu = n-1), \qquad z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}};$$

p-значение: $2P(Z > |z|)$ или $P(Z > z)$ или $P(Z < z)$;

решение: $p \le \alpha \Rightarrow$ отвергаем H_0;

мощность $= 1 - \beta$; $\qquad n \approx \left(\frac{(z_{\alpha/2} + z_\beta)\sigma}{\Delta}\right)^2$.

8 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Сформулируйте H_0 и H_1 (с указанием типа теста): (а) производитель утверждает, что средняя масса пачки 500 г, инспектор подозревает недовес; (б) банк хочет проверить, изменилась ли доля просрочек по сравнению с прежними 6%; (в) менеджер считает, что новая форма заявки сократила среднее время оформления с 15 минут.

Задача 2 [A] $H_0 : \mu = 50$, $H_1 : \mu \neq 50$, $\sigma = 10$, выборка $n = 100$, $\bar{x} = 52.5$, $\alpha = 0.05$. Выполните тест.

Задача 3 [A] В исследовании получено $p = 0.03$. Какие из утверждений верны? (1) Вероятность того, что H_0 верна, равна 3%. (2) Если бы H_0 была верна, результат не менее экстремальный, чем наблюдаемый, встречался бы в 3% выборок. (3) Эффект большой. (4) При $\alpha = 0.05$ H_0 отвергается; при $\alpha = 0.01$ нет.

Задача 4 [B] $H_0 : \mu = 50$, $H_1 : \mu \neq 50$. Выборка $n = 9$, $\bar{x} = 52$, $s = 6$. Проведите t-тест ($\alpha = 0.05$) и найдите p-значение.

Задача 5 [B] Среднее время доставки должно быть 250 минут. У 16 заказов $\bar{x} = 245$, $s = 20$. Проверьте $H_0 : \mu = 250$ против $H_1 : \mu < 250$.

Задача 6 [B] Компания утверждает, что 30% клиентов пользуются приложением. В случайной выборке из 500 клиентов приложением пользуются 170.

(а) Проверьте $H_0 : p = 0.30$ против $H_1 : p \neq 0.30$ при $\alpha = 0.05$.
(б) Как изменится вывод при $H_1 : p > 0.30$?
(в) Постройте 95% ДИ и сравните с результатом (а).

Задача 7 [B] Опишите ошибки I и II рода на языке задачи: (а) система мониторинга банка проверяет H_0: «операция нормальная»; (б) проверка нового препарата, H_0: «препарат не действует». Какая ошибка дороже в каждом случае и как это влияет на выбор α?

Задача 8 [B] $H_0 : \mu = 100$, $\sigma = 15$, $n = 36$, $\alpha = 0.05$ (двусторонний).

(а) Найдите мощность теста при истинном $\mu = 105$.
(б) Какой n нужен для мощности 80% при $\mu = 105$?

Задача 9 [B] $n = 64$, $\bar{x} = 103$, $\sigma = 16$. (а) Постройте 95% ДИ для μ. (б) Не проводя тест, определите результат двустороннего теста на уровне 0.05 для $H_0 : \mu = 100$ и для $H_0 : \mu = 98$. (в) Проверьте это вычислением z и p.

Задача 10 [B] Аналитик проверил 10 независимых гипотез на уровне $\alpha = 0.05$ и нашёл одну «значимую». (а) Какова вероятность хотя бы одной ложной тревоги, если все 10 нулевых гипотез верны? (б) Какой уровень значимости для каждого теста даёт поправка Бонферрони?

Задача 11 [C] Покажите, что при верной H_0 и непрерывной статистике p-значение (для правостороннего теста) равномерно распределено на $[0, 1]$, то есть $P(p \le \alpha) = \alpha$ для любого α.

Задача 12 [C] Покажите, что двусторонний z-тест на уровне α отвергает $H_0 : \mu = \mu_0$ тогда и только тогда, когда μ_0 не принадлежит $(1-\alpha)$-ДИ $\bar{x} \pm z_{\alpha/2}\sigma/\sqrt{n}$. Затем для $n = 10\,000$, $\bar{x} = 30.3$, $\sigma = 4$, $\mu_0 = 30$ найдите p-значение и ДИ и прокомментируйте практическую значимость.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 11

Проверка гипотез II: сравнение групп, χ^2 и ANOVA

Сравнение двух средних и долей, парные данные, таблицы сопряжённости и сравнение трёх и более групп

Тема 11 по силлабусу · неделя 11 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- выбирать между независимыми и парными выборками и проводить соответствующий t-тест;
- сравнивать две доли с помощью z-теста и строить ДИ для разности;
- проверять независимость двух категориальных признаков и согласие с распределением по критерию χ^2;
- проводить однофакторный дисперсионный анализ (ANOVA) и интерпретировать F-статистику;
- определять практическую значимость различий и избегать типичных ошибок (множественные сравнения, неправильный выбор критерия).

1 Как выбрать критерий

Логика проверки гипотез (лекция 10) остаётся прежней; меняется статистика и её распределение. Выбор зависит от типа данных и плана сбора:

Вопрос	Критерий
Два средних, независимые группы	двухвыборочный t-тест (Уэлча)
Два измерения у одних и тех же объектов (до/после)	парный t-тест по разностям
Две доли	двухвыборочный z-тест для долей
Связь двух категориальных признаков	χ^2-тест независимости
Совпадает ли распределение с заданным	χ^2-тест согласия
Три и более средних	однофакторный ANOVA (F-тест)

2 Два средних: независимые выборки

Пусть из двух независимых совокупностей получены $\bar{x}_1, s_1, n_1$ и $\bar{x}_2, s_2, n_2$. $H_0 : \mu_1 - \mu_2 = 0$. Стандартная ошибка разности (дисперсии независимых величин складываются):

$$\mathrm{SE}(\bar{x}_1 - \bar{x}_2) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}, \qquad t = \frac{\bar{x}_1 - \bar{x}_2}{\mathrm{SE}}, \tag{2.1}$$

число степеней свободы (формула Уэлча—Саттертуэйта)

$$\nu \approx \frac{\left(s_1^2/n_1 + s_2^2/n_2\right)^2}{\dfrac{(s_1^2/n_1)^2}{n_1 - 1} + \dfrac{(s_2^2/n_2)^2}{n_2 - 1}}. \tag{2.2}$$

Это критерий Уэлча: он не требует равенства дисперсий и является настройкой по умолчанию в современных программах. (Если дисперсии считаются равными, можно использовать объединённую оценку $s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$ и $\nu = n_1 + n_2 - 2$.) ДИ для разности: $(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2,\nu}\,\mathrm{SE}$.

ПРИМЕР 1. ВРЕМЯ ОПЕРАЦИИ В ДВУХ ФИЛИАЛАХ

Филиал 1: $n_1 = 12$, $\bar{x}_1 = 14.2$ мин, $s_1 = 3.1$. Филиал 2: $n_2 = 15$, $\bar{x}_2 = 12.1$, $s_2 = 2.6$. $H_0 : \mu_1 = \mu_2$, $H_1 : \mu_1 \neq \mu_2$, $\alpha = 0.05$. $\mathrm{SE} = \sqrt{3.1^2/12 + 2.6^2/15} = \sqrt{0.801 + 0.451} = 1.119$; $t = \dfrac{2.1}{1.119} = 1.88$; $\nu = 21.5$. $p = 0.074 > 0.05$ — на уровне 5% различие не доказано. 95% ДИ разности: $2.1 \pm 2.077 \cdot 1.119 = (-0.22;\ 4.42)$ — содержит 0, согласуется с тестом. С объединённой дисперсией получили бы почти то же ($t = 1.92$, $p = 0.067$). Односторонний тест ($H_1 : \mu_1 > \mu_2$) дал бы $p = 0.037$, но, как говорилось, направление выбирают до данных.

3 Парные данные

Если измерения относятся к одним и тем же объектам (до и после обучения; два метода на одних клиентах), выборки зависимы. Тогда считаем *разности* $d_i = x_i^{\text{после}} - x_i^{\text{до}}$ и применяем одновыборочный t-тест к ним:

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \qquad \nu = n - 1. \tag{3.1}$$

ПРИМЕР 2. ОБУЧЕНИЕ СОТРУДНИКОВ

Баллы 8 сотрудников до обучения: $62, 70, 55, 68, 74, 60, 66, 71$; после: $66, 73, 58, 69, 79, 62, 70, 72$. Разности d: $4, 3, 3, 1, 5, 2, 4, 1$; $\bar{d} = 2.875$, $s_d = 1.458$, $\mathrm{SE} = 0.515$. $t = 5.58$, $\nu = 7$, $p = 0.0008$. Отвергаем $H_0 : \mu_d = 0$: обучение повысило балл в среднем на 2.9 (95% ДИ: $(1.66;\ 4.09)$).

ТИПИЧНАЯ ОШИБКА

Парные данные нельзя анализировать как независимые. Для тех же данных критерий Уэлча даст $t = 0.89$, $p = 0.39$ — эффект «потеряется» из-за большого разброса между сотрудниками (которую парный дизайн как раз устраняет). Верно и обратное: независимые выборки нельзя «спаривать» произвольно.

4 Две доли

$H_0 : p_1 = p_2$. При H_0 обе доли оценивают одно p, поэтому в тесте используют объединённую долю $\hat{p} = \frac{x_1+x_2}{n_1+n_2}$:

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}. \tag{4.1}$$

Для ДИ разности используют раздельную ошибку $\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$.

ПРИМЕР 3. ДВА ВАРИАНТА РАССЫЛКИ

Предложение A: 120 откликов из 400 ($\hat{p}_1 = 0.300$); предложение B: 150 из 420 ($\hat{p}_2 = 0.357$). $\hat{p} = 270/820 = 0.329$, SE $= \sqrt{0.329 \cdot 0.671 \cdot (1/400 + 1/420)} = 0.0328$. $z = \dfrac{-0.0571}{0.0328} = -1.74$, $p = 0.082$ (двусторонний). Различие на уровне 5% не доказано. 95% ДИ разности $p_1 - p_2$: $-0.057 \pm 1.96 \cdot 0.0327 = (-0.121;\ 0.007)$.

5 χ^2-тест независимости

Для двух категориальных признаков строим таблицу сопряжённости $r \times c$. При H_0 (признаки независимы) ожидаемая частота ячейки $E_{ij} = \dfrac{(\text{сумма строки } i)(\text{сумма столбца } j)}{N}$.

$$\chi^2 = \sum \frac{(O-E)^2}{E}, \qquad \nu = (r-1)(c-1). \tag{5.1}$$

Большое значение означает, что наблюдаемые частоты далеки от ожидаемых. Критерий всегда правосторонний. Условие: все $E_{ij} \geq 5$.

ПРИМЕР 4. КАНАЛ ОБСЛУЖИВАНИЯ И УДОВЛЕТВОРЁННОСТЬ

500 клиентов:

	Доволен	Не доволен	Всего
Сайт	90	60	150
Приложение	150	50	200
Отделение	85	65	150
Всего	325	175	500

Ожидаемые: сайт $97.5/52.5$; приложение $130/70$; отделение $97.5/52.5$ (например, $E_{11} = 150 \cdot 325/500 = 97.5$). Слагаемые $\frac{(O-E)^2}{E}$: $0.58,\ 1.07;\ 3.08,\ 5.71;\ 1.60,\ 2.98$. $\chi^2 = 15.02$, $\nu = 2$, критическое значение 5.991, $p = 0.0005$. Отвергаем независимость: доля довольных различается по каналам (60%, 75%, 56.7%). Вклад ячеек показывает, что основное отличие — клиенты приложения. Сила связи по Крамеру $V = \sqrt{\chi^2/(N \min(r-1, c-1))} = 0.17$ — слабая.

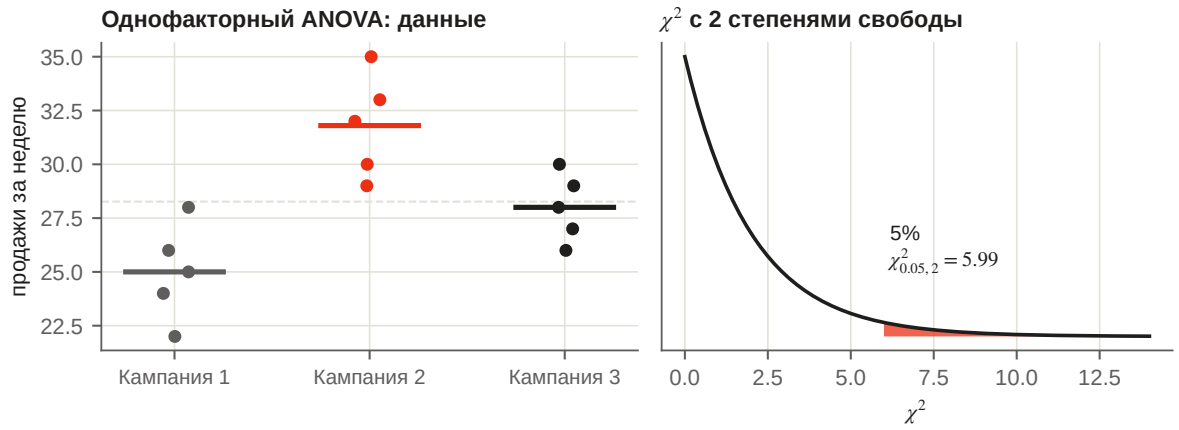


Рис. 1. Слева: данные трёх рекламных кампаний (точки) и их средние; пунктир — общее среднее. Справа: χ^2-распределение с 2 степенями свободы и область отклонения при $\alpha = 0.05$.

5.1 χ^2-тест согласия

Проверяет, соответствует ли распределение категориальной величины заданному: $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$, $\nu = k - 1$ (минус число оценённых параметров).

ПРИМЕР 5. НАГРУЗКА ПО ДНЯМ

Менеджер предполагает, что обращения равномерно распределены по пяти рабочим дням. За неделю 120 обращений: $15, 20, 24, 22, 39$. Ожидание $120/5 = 24$ на день. Слагаемые: $3.375;\ 0.667;\ 0;\ 0.167;\ 9.375$; $\chi^2 = 13.58$, $\nu = 4$, критическое значение 9.488, $p = 0.0088$. Гипотеза о равномерности отвергается — главный вклад даёт пятница.

6 Сравнение нескольких средних: ANOVA

Для трёх и более групп многократные t-тесты приводят к росту ошибки I рода (лекция 10). Дисперсионный анализ проверяет $H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$ одним тестом. Идея: сравнить изменчивость *между* групповыми средними и изменчивость *внутри* групп.

$$SSB = \sum n_j(\bar{x}_j - \bar{x})^2, \quad SSW = \sum\sum (x_{ij} - \bar{x}_j)^2, \quad SST = SSB + SSW, \tag{6.1}$$

$$F = \frac{MSB}{MSW} = \frac{SSB/(k-1)}{SSW/(N-k)}, \qquad \nu_1 = k - 1,\ \nu_2 = N - k. \tag{6.2}$$

Если H_0 верна, обе оценки дисперсии близки и $F \approx 1$; большое F означает, что групповые средние различаются сильнее, чем допускает случайность. Условия: независимость, приблизительная нормальность внутри групп, близкие дисперсии (отношение наибольшего s к наименьшему не более 2).

ПРИМЕР 6. ТРИ РЕКЛАМНЫЕ КАМПАНИИ

Продажи за пять недель: К1: $22, 25, 24, 28, 26$ ($\bar{x} = 25.0$); К2: $30, 33, 29, 35, 32$ (31.8); К3: $27, 26, 30, 29, 28$ (28.0). Общее среднее 28.27.

Источник	SS	ν	MS	F
Между группами	116.13	2	58.07	**13.20**
Внутри групп	52.80	12	4.40	
Всего	168.93	14		

Критическое значение $F_{0.05;2,12} = 3.885$; $p = 0.0009$. Отвергаем H_0: средние продажи различаются. Доля объяснённой изменчивости $\eta^2 = SSB/SST = 0.69$.

ANOVA говорит лишь о том, что хотя бы одна пара средних различается. Чтобы выяснить, какая именно, используют парные сравнения с поправкой на множественность (Бонферрони, Тьюки). В примере с $MSW = 4.4$ ($\nu = 12$) парные t-тесты с поправкой Бонферрони (умножение p на 3): К1 и К2: $p = 0.0008$; К2 и К3: $p = 0.043$; К1 и К3: $p = 0.129$ — различие между К1 и К3 не доказано.

7 Практические замечания

1. Значимость $\neq$ важность: сообщайте разность средних и ДИ.
2. Проверяйте условия: выбросы и сильная асимметрия при малых n делают t-тесты ненадёжными; для χ^2 — ожидаемые частоты ≥ 5.
3. Эксперимент со случайным распределением по группам позволяет делать причинные выводы; наблюдательное сравнение — нет (лекция 13).
4. Нулевой результат ($p > \alpha$) — это «нет доказательств различия», а не «доказательство отсутствия различия»; смотрите на ширину ДИ и мощность.

8 Ключевые термины

Термин	***English***	**Смысл**
Независимые выборки	*Independent samples*	разные объекты в группах
Парные выборки	*Paired samples*	одни объекты, два измерения
Объединённая доля	*Pooled proportion*	$\hat{p} = (x_1 + x_2)/(n_1 + n_2)$
Таблица сопряжённости	*Contingency table*	частоты по двум признакам
Ожидаемая частота	*Expected count*	$E =$ строка $\times$ столбец$/N$
Дисперсионный анализ	*ANOVA*	сравнение $k \geq 3$ средних
F-статистика	*F-statistic*	MSB/MSW

Формулы лекции 11

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}, \qquad t = \frac{\bar{d}}{s_d/\sqrt{n}}, \qquad z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)}};$$

$$\chi^2 = \sum \frac{(O-E)^2}{E}, \quad \nu = (r-1)(c-1); \qquad F = \frac{SSB/(k-1)}{SSW/(N-k)}.$$

9 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Выберите критерий (двухвыборочный t, парный t, z для двух долей, χ^2 независимости, χ^2 согласия, ANOVA): (а) средний чек в Ташкенте, Самарканде и Бухаре; (б) вес 20 клиентов до и после программы; (в) доля довольных клиентов у мужчин и у женщин; (г) связь уровня образования (3 категории) и типа выбранного тарифа (4 типа); (д) среднее время ответа у двух групп операторов; (е) соответствует ли распределение заказов по дням недели равномерному.

Задача 2 [A] Группа 1: $n = 40$, $\bar{x} = 50$, $s = 8$; группа 2: $n = 50$, $\bar{x} = 46$, $s = 10$. Проверьте $H_0 : \mu_1 = \mu_2$ (H_1 — двусторонняя, $\alpha = 0.05$) и постройте 95% ДИ для разности.

Задача 3 [A] Баланс 6 клиентов (тыс. сум) до и после рекламной акции: до $40, 52, 38, 45, 60, 48$; после $44, 55, 37, 50, 66, 49$. Проверьте, вырос ли баланс (двусторонний тест, $\alpha = 0.05$).

Задача 4 [B] Филиал A: $n = 15$, $\bar{x} = 78$, $s = 12$; филиал B: $n = 18$, $\bar{x} = 70$, $s = 9$ (баллы клиентского сервиса). Проведите тест Уэлча для $H_0 : \mu_A = \mu_B$ и постройте 95% ДИ для разности. Сравните с выводом по ДИ.

Задача 5 [B] Доля брака на линии A: 18 из 300; на линии B: 33 из 400. Проверьте $H_0 : p_A = p_B$ и постройте 95% ДИ для разности.

Задача 6 [B] Из 200 заёмщиков, получивших кредит по схеме A, просрочили 45; из 200 по схеме B — 30. Проведите χ^2-тест независимости (схема и просрочка), $\alpha = 0.05$, и сравните с z-тестом для двух долей.

Задача 7 [B] Опрос 350 клиентов: регион (Север, Центр, Юг) и предпочитаемый продукт (кредит, депозит, карта):

	Кредит	Депозит	Карта
Север	40	30	30
Центр	50	60	40
Юг	30	20	50

Проверьте независимость региона и продукта ($\alpha = 0.05$). В какой ячейке наибольшее отклонение?

Задача 8 [B] Игральный кубик бросили 60 раз; грани $1, \dots, 6$ выпали $8, 12, 9, 11, 6, 14$ раз. Проверьте честность кубика ($\alpha = 0.05$).

Задача 9 [B] Однофакторный ANOVA: 3 группы по $n = 6$ ($N = 18$); средние $20, 24, 28$; $MSW = 16$.

(а) Найдите SSB, MSB и F.

(б) Найдите критическое значение $F_{0.05}$ и сделайте вывод.

Задача 10 [B] Время выполнения операции в трёх бригадах (по 4 наблюдения): A: $10, 12, 11, 13$; B: $14, 15, 13, 16$; C: $12, 11, 13, 12$. Составьте таблицу ANOVA и сделайте вывод ($\alpha = 0.05$).

Задача 11 [C] Для двух групп ANOVA эквивалентен двухвыборочному t-тесту с объединённой дисперсией: $F = t^2$. Проверьте на данных бригад A и B из предыдущей задачи.

Задача 12 [C] В данных об обучении сотрудников (лекция 11) $s_{\text{до}} = 6.34$, $s_{\text{после}} = 6.59$, корреляция между баллами до и после $r = 0.975$. Объясните через дисперсию разности, почему парный тест намного мощнее независимого. Найдите SE для обоих подходов.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 12

Простая линейная регрессия

Как описать связь между двумя количественными переменными прямой линией, оценить её по данным и проверить качество

Тема 12 по силлабусу · неделя 12 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- строить диаграмму рассеяния и записывать модель простой линейной регрессии $y = \beta_0 + \beta_1 x + \varepsilon$;
- вычислять оценки МНК b_0, b_1 вручную и по связи с корреляцией, интерпретировать наклон и свободный член;
- вычислять остатки, SSE, SSR, SST, R^2 и стандартную ошибку регрессии s_e;
- строить прогнозы и понимать опасность экстраполяции;
- анализировать график остатков и находить нарушения условий модели.

1 Модель

Корреляция (лекция 6) измеряет силу линейной связи, но не говорит, *на сколько* в среднем изменяется y, когда x растёт на единицу. Это делает регрессия. Пусть для n объектов измерены *объясняющая* переменная x (предиктор) и *зависимая* переменная y (отклик).

МОДЕЛЬ ПРОСТОЙ ЛИНЕЙНОЙ РЕГРЕССИИ

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad \varepsilon_i \sim \text{независимые, } \mathrm{E}[\varepsilon_i] = 0,\ \mathrm{Var}(\varepsilon_i) = \sigma^2. \tag{1.1}$$

β_1 — изменение среднего y при росте x на единицу; β_0 — среднее y при $x = 0$; ε — случайная ошибка (всё, что не объясняется x). Параметры β_0, β_1 неизвестны и оцениваются по выборке.

Мы моделируем *условное среднее* $\mathrm{E}[y \mid x] = \beta_0 + \beta_1 x$. Это не означает, что x является причиной y (лекция 13).

2 Метод наименьших квадратов

Прямую $\hat{y} = b_0 + b_1 x$ выбирают так, чтобы сумма квадратов вертикальных отклонений (остатков $e_i = y_i - \hat{y}_i$) была минимальной:

$$\min_{b_0, b_1} \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2. \tag{2.1}$$

Решение (приравнивание производных к нулю):

$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}} = r\,\frac{s_y}{s_x}, \qquad b_0 = \bar{y} - b_1 \bar{x}. \tag{2.2}$$

Из второго равенства следует, что прямая всегда проходит через точку $(\bar{x}, \bar{y})$. Из формулы $b_1 = r\, s_y / s_x$ следует: знак наклона совпадает со знаком корреляции.

ПРИМЕР 1. РЕКЛАМА И ПРОДАЖИ

Данные из лекции 6: расходы на рекламу $x = 2, 3, 5, 6, 8, 10$ и продажи $y = 15, 17, 22, 31, 33, 40$ (млн сум). $\bar{x} = 5.667$, $\bar{y} = 26.333$, $S_{xx} = 45.33$, $S_{yy} = 487.33$, $S_{xy} = 145.67$.

$$b_1 = \frac{145.67}{45.33} = 3.213, \qquad b_0 = 26.333 - 3.213 \cdot 5.667 = 8.125, \qquad \hat{y} = 8.125 + 3.213\,x.$$

Интерпретация: каждый дополнительный миллион рекламы связан с ростом продаж в среднем на 3.21 млн сум. Свободный член 8.1 — продажи при нулевых расходах (здесь $x = 0$ вне диапазона данных 2–10, поэтому буквальной интерпретации он не имеет).

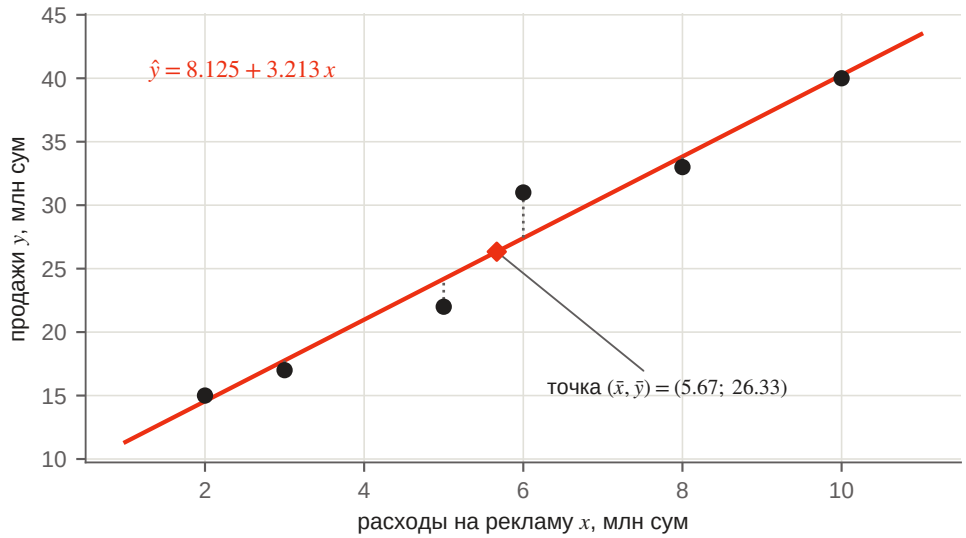


Рис. 1. Диаграмма рассеяния и линия МНК. Пунктирные отрезки — остатки; линия минимизирует сумму их квадратов. Ромб — точка $(\bar{x}, \bar{y})$, через которую проходит прямая.

3 Остатки и качество подгонки

Прогнозы $\hat{y}_i = b_0 + b_1 x_i$: $14.55;\ 17.77;\ 24.19;\ 27.40;\ 33.83;\ 40.26$. Остатки $e_i = y_i - \hat{y}_i$: $0.45;\ -0.77;\ -2.19;\ 3.60;\ -0.83;\ -0.26$. Свойства остатков МНК: $\sum e_i = 0$ и $\sum x_i e_i = 0$ (проверьте!).

Общую изменчивость y разлагают на объяснённую и необъяснённую:

$$\underbrace{\sum (y_i - \bar{y})^2}_{SST} = \underbrace{\sum (\hat{y}_i - \bar{y})^2}_{SSR} + \underbrace{\sum (y_i - \hat{y}_i)^2}_{SSE}, \qquad R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}. \tag{3.1}$$

КОЭФФИЦИЕНТ ДЕТЕРМИНАЦИИ

R^2 — доля вариации y, объяснённая линейной зависимостью от x. В простой регрессии $R^2 = r^2$.

В примере $SST = 487.33$, $SSE = 19.27$, $SSR = 468.06$; $R^2 = 0.9605$ ($= 0.980^2$): реклама объясняет 96% вариации продаж. Стандартная ошибка регрессии

$$s_e = \sqrt{\frac{SSE}{n-2}} = \sqrt{\frac{19.27}{4}} = 2.195 \tag{3.2}$$

показывает типичный размер ошибки прогноза в единицах y (мы делим на $n-2$, так как оценены два параметра).

ТИПИЧНАЯ ОШИБКА

Высокий R^2 не доказывает ни причинности, ни правильности модели; низкий R^2 не означает, что связь отсутствует (может быть нелинейная связь или значимый, но малый эффект). Всегда смотрите на график остатков.

4 Прогнозирование и экстраполяция

Прогноз среднего при $x = 7$: $\hat{y} = 8.125 + 3.213 \cdot 7 = 30.62$ млн сум. Допустимо, так как 7 лежит внутри диапазона $[2; 10]$ (*интерполяция*). Прогноз при $x = 12$ даёт 46.7, но это *экстраполяция*: за пределами данных линейность не гарантирована (насыщение рынка, убывающая отдача), и такому прогнозу доверять нельзя.

ЗАПОМНИТЕ

Регрессия y на x и регрессия x на y — разные прямые (кроме $|r| = 1$). Если нужно предсказывать y, объясняющей переменной служит x; симметрии в МНК нет. Единицы измерения: b_1 измеряется в единицах y на единицу x; при смене единиц x (млн $\to$ тыс.) b_1 меняется, r и R^2 — нет.

5 Диагностика по остаткам

Условия модели: (1) линейность; (2) независимость ошибок; (3) постоянная дисперсия ошибок (гомоскедастичность); (4) приблизительно нормальные ошибки (важно при малых n для выводов, лекция 13). Проверяют график остатков e_i против $\hat{y}_i$: при хорошей подгонке точки случайно разбросаны вокруг нуля без структуры.

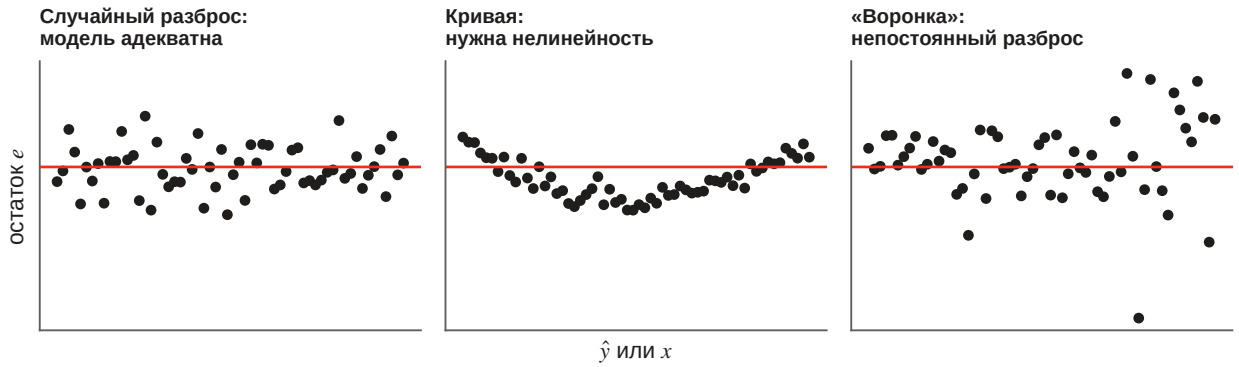


Рис. 2. Три типичные картины остатков. Кривая означает, что связь нелинейна, «воронка» — что разброс растёт с x (гетероскедастичность).

5.1 Выбросы и влиятельные наблюдения

Точка с большим остатком — выброс по y. Точка с необычным значением x (далеко от $\bar{x}$) обладает большим рычагом и может «перетянуть» прямую. Всегда выясняйте причину (ошибка ввода, особый случай) и сравнивайте результаты с точкой и без неё (как в лекции 1 для филиала 12), а не удаляйте данные ради красивой линии.

6 Ключевые термины

Термин	*English*	Смысл
Зависимая переменная	*Response*, y	объясняемая величина
Объясняющая переменная	*Predictor*, x	фактор
МНК	*Ordinary least squares*	минимум $\sum e_i^2$
Остаток	*Residual*	$e_i = y_i - \hat{y}_i$
Коэффициент детерминации	R^2	$SSR/SST = r^2$
Стандартная ошибка регрессии	*Residual standard error*	$s_e = \sqrt{SSE/(n-2)}$
Экстраполяция	*Extrapolation*	прогноз вне диапазона x
Гомоскедастичность	*Homoscedasticity*	постоянная дисперсия ошибок

Формулы лекции 12

$$b_1 = \frac{S_{xy}}{S_{xx}} = r\frac{s_y}{s_x}, \qquad b_0 = \bar{y} - b_1\bar{x}, \qquad e_i = y_i - \hat{y}_i;$$

$$SST = SSR + SSE, \qquad R^2 = \frac{SSR}{SST} = r^2, \qquad s_e = \sqrt{\frac{SSE}{n-2}}.$$

7 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Уравнение регрессии стоимости доставки y (тыс. сум) на расстояние x (км): $\hat{y} = 10 + 2.5x$.

(а) Интерпретируйте b_1 и b_0.
(б) Найдите прогноз при $x = 8$ км и остаток для наблюдения $(8;\ 32)$.

Задача 2 [A] Известно: $\bar{x} = 40$, $\bar{y} = 100$, $s_x = 10$, $s_y = 30$, $r = 0.6$. Найдите уравнение регрессии y на x и R^2.

Задача 3 [A] Время подготовки x (ч): $1, 2, 3, 4, 5$; баллы y: $50, 55, 65, 70, 85$. Найдите уравнение регрессии, прогноз при $x = 4$ и остаток для этого наблюдения.

Задача 4 [B] Для данных предыдущей задачи найдите все прогнозы и остатки, проверьте $\sum e_i = 0$, найдите SSE, SST, R^2 и s_e.

Задача 5 [B] Площадь квартиры x (м^2): $40, 50, 60, 80, 100$; цена y (тыс. долл.): $38, 45, 50, 68, 84$.

(а) Найдите уравнение регрессии.
(б) Найдите R^2 и s_e.
(в) Спрогнозируйте цену квартиры 70 м^2. Можно ли использовать модель для квартиры 200 м^2?

Задача 6 [B] Для регрессии по 22 наблюдениям $SST = 500$, $SSE = 120$.

(а) Найдите SSR и R^2.
(б) Найдите $|r|$ и s_e.
(в) Что можно сказать о знаке r?

Задача 7 [B] В регрессии из лекции 12 ($\hat{y} = 8.125 + 3.213x$, x и y в млн сум) выразите x в тысячах сум ($x' = 1000x$). Как изменятся b_0, b_1, r, R^2 и s_e?

Задача 8 [B] Аналитик с помощью регрессии из лекции 12 предсказывает продажи при рекламе 25 млн сум и получает $\hat{y} = 88.5$. Что не так с этим прогнозом? Как ему поступить?

Задача 9 [B] Для данных из лекции 12 регрессия y на x даёт $b_1 = 3.213$. (а) Найдите наклон регрессии x на y. (б) Проверьте, что произведение двух наклонов равно r^2. Можно ли найти x по прогнозу y, просто решив уравнение $y = b_0 + b_1 x$ относительно x?

Задача 10 [C] Выведите оценки МНК: найдите b_0 и b_1, минимизирующие $Q = \sum(y_i - b_0 - b_1 x_i)^2$.

Задача 11 [C] Покажите, что (а) $\sum e_i = 0$; (б) $R^2 = r^2$ в простой регрессии.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 13

Статистические выводы в регрессии, причинность и множественная регрессия

Значима ли найденная связь, насколько точны оценки и прогнозы и когда регрессия не отвечает на вопрос «почему»

Тема 13 по силлабусу · неделя 13 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- проверять гипотезу $H_0 : \beta_1 = 0$ (t- и F-тест) и строить ДИ для наклона;
- строить доверительный интервал для среднего отклика и интервал предсказания для нового наблюдения;
- интерпретировать вывод программы по регрессии;
- различать корреляцию и причинность; объяснять роль пропущенных переменных, обратной причинности и парадокса Симпсона;
- понимать смысл «при прочих равных» во множественной регрессии, R^2_{adj} и мультиколлинеарности.

1 От выборки к совокупности

Коэффициенты b_0, b_1 (лекция 12) вычислены по выборке и колеблются от выборки к выборке. Как и для среднего, нужно знать их стандартные ошибки. При выполнении условий модели (линейность, независимость, постоянная дисперсия, приближённая нормальность ошибок):

$$\mathrm{SE}(b_1) = \frac{s_e}{\sqrt{S_{xx}}}, \qquad \mathrm{SE}(b_0) = s_e\sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}, \qquad \frac{b_1 - \beta_1}{\mathrm{SE}(b_1)} \sim t_{n-2}. \tag{1.1}$$

Стандартная ошибка наклона уменьшается, когда растёт n, уменьшается s_e и когда значения x сильнее разбросаны (S_{xx} больше).

1.1 Проверка значимости наклона

$H_0 : \beta_1 = 0$ (нет линейной связи) против $H_1 : \beta_1 \neq 0$:

$$t = \frac{b_1}{\mathrm{SE}(b_1)}, \qquad \nu = n - 2; \qquad \text{ДИ: } b_1 \pm t_{\alpha/2,\,n-2}\,\mathrm{SE}(b_1). \tag{1.2}$$

ПРИМЕР 1. РЕКЛАМА И ПРОДАЖИ

Из лекции 12: $b_1 = 3.213$, $s_e = 2.195$, $S_{xx} = 45.33$. $\text{SE}(b_1) = 2.195/\sqrt{45.33} = 0.326$. $t = 3.213/0.326 = 9.86$, $\nu = 4$, $p = 0.0006$. Отвергаем H_0: связь значима. 95% ДИ: $3.213 \pm 2.776 \cdot 0.326 = (2.31;\ 4.12)$ — рост рекламы на 1 млн связан с ростом продаж на 2.3–4.1 млн. Для свободного члена: $\text{SE}(b_0) = 2.053$, $t = 3.96$, $p = 0.017$, ДИ $(2.42;\ 13.83)$. Проверка $H_0 : \beta_1 = 2$ (вдруг отдача рекламы равна 2): $t = (3.213 - 2)/0.326 = 3.72$, $p = 0.020$ — отвергаем: отдача существенно больше 2.

1.2 Таблица ANOVA регрессии и F-тест

Источник	SS	ν	MS	F
Регрессия	$SSR = 468.06$	1	468.06	**97.15**
Остатки	$SSE = 19.27$	$n - 2 = 4$	$4.82 = s_e^2$	
Всего	$SST = 487.33$	5		

$F = MSR/MSE$ проверяет ту же гипотезу $\beta_1 = 0$; в простой регрессии $F = t^2$ ($9.86^2 = 97.15$) и p-значения совпадают. F-тест становится самостоятельным во множественной регрессии (значимость модели в целом).

2 Интервалы для прогноза

При $x = x_0$ различают два вопроса. (1) Каково *среднее* значение y для всех объектов с x_0? — доверительный интервал для среднего отклика. (2) Каким будет y у *нового* объекта с x_0? — интервал предсказания (он шире, так как добавляется случайная ошибка ε):

$$\hat{y}_0 \pm t_{\alpha/2,n-2}\, s_e \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} \quad \text{(среднее)}, \tag{2.1}$$

$$\hat{y}_0 \pm t_{\alpha/2,n-2}\, s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}} \quad \text{(индивидуальное)}. \tag{2.2}$$

ПРИМЕР 2. ПРОГНОЗ ПРИ $x_0 = 7$

$\hat{y}_0 = 30.62$. $\sqrt{1/6 + (7 - 5.667)^2/45.33} = 0.4538$, $s_e \cdot 0.4538 = 0.996$. Интервал для среднего: $30.62 \pm 2.776 \cdot 0.996 = (27.85;\ 33.38)$. Интервал предсказания: $\sqrt{1 + 0.2059} = 1.098$, $2.195 \cdot 1.098 = 2.410$; $30.62 \pm 2.776 \cdot 2.410 = (23.93;\ 37.31)$. Интервал по среднему значению в $\bar{x}$ самый узкий и растёт к краям: при $x_0 = 10$ ширина для среднего ± 4.64 против ± 2.48 при $x_0 = \bar{x} = 5.67$.

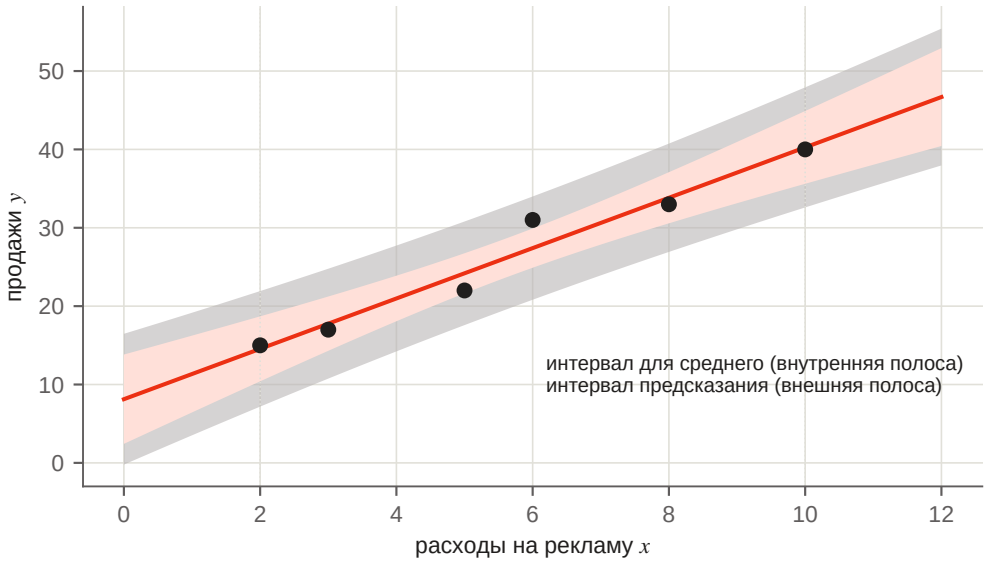


Рис. 1. Линия регрессии, 95% ДИ для среднего отклика (внутренняя полоса, сужается у $\bar{x}$) и 95% интервал предсказания для нового наблюдения (внешняя полоса).

> **ТИПИЧНАЯ ОШИБКА**
>
> Интервал предсказания не сводится к ДИ среднего: даже при бесконечной выборке индивидуальные значения остаются разбросанными вокруг линии на $\pm 1.96\,\sigma$. Не путайте «среднее по группе» и «значение для конкретного клиента».

3 Чтение вывода программы

Типичный вывод (Excel, R, Python) содержит: коэффициенты, их стандартные ошибки, t-статистики и p-значения, R^2, s_e, F и p-значение F. Для нашего примера: Intercept 8.125 (SE 2.053, $t = 3.96$, $p = 0.017$); Slope 3.213 (SE 0.326, $t = 9.86$, $p = 0.0006$); $R^2 = 0.960$; $s_e = 2.195$; $F = 97.15$ (Significance $F = 0.0006$), $n = 6$. Умение за минуту «прочитать» такой вывод — стандартное требование на экзамене.

4 Корреляция и причинность

Значимость наклона говорит лишь о том, что линейная связь в данных вряд ли случайна. Она не означает, что изменение x вызывает изменение y. Причины ложных выводов:

- **Пропущенная (скрытая) переменная** Z влияет на обе величины. Пример: чем больше пожарных на пожаре, тем больше ущерб — но обе величины определяются масштабом пожара. Продажи мороженого и число утоплений растут вместе из-за жаркой погоды.
- **Обратная причинность**: банки с большей прибылью больше тратят на рекламу — а не только реклама повышает прибыль.
- **Случайное совпадение** (особенно при поиске по множеству переменных).
- **Парадокс Симпсона**: связь в объединённых данных меняет знак внутри групп.

ПРИМЕР 3. ПАРАДОКС СИМПСОНА

Колл-центр тестирует два сценария разговора с клиентами (успех = клиент оформил продукт).

	Простые клиенты	Сложные клиенты	Всего
Сценарий A	81/87 (93.1%)	192/263 (73.0%)	273/350 (78.0%)
Сценарий B	234/270 (86.7%)	55/80 (68.8%)	289/350 (82.6%)

В каждой группе лучше сценарий A, но в сумме лучше выглядит B: сценарий A чаще применялся к сложным клиентам (263 из 350), а B — к простым (270 из 350). Тип клиента — искажающая переменная: она связана и с выбором сценария, и с результатом. Правильный вывод делают, учитывая группы.

ЗАПОМНИТЕ

Причинные выводы надёжны, когда значения x назначаются *случайно* (рандомизированный эксперимент, A/B-тест): тогда по построению x не связан с пропущенными факторами. В наблюдательных данных нужны (а) контроль искажающих переменных, (б) обоснование направления причинности и (в) осторожные формулировки: «связано с», а не «приводит к».

5 Множественная регрессия (знакомство)

Модель с несколькими объясняющими переменными: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$. Коэффициент β_j показывает изменение среднего y при росте x_j на единицу *при неизменных остальных переменных* (ceteris paribus).

ПРИМЕР 4. РЕКЛАМА, ЦЕНА И ПРОДАЖИ

10 недель: x_1 — расходы на рекламу, x_2 — цена, y — продажи.

Неделя	1	2	3	4	5	6	7	8	9	10
x_1	2	3	5	6	8	10	4	7	9	1
x_2	12	11	11	10	9	9	12	10	9	13
y	20	24	31	38	47	52	26	41	48	15

Регрессия только на x_1: $\hat{y} = 11.0 + 4.22x_1$, $R^2 = 0.989$. Множественная регрессия: $\hat{y} = 40.86 + 3.19\,x_1 - 2.29\,x_2$, $R^2 = 0.996$, $R^2_{\text{adj}} = 0.995$, $s_e = 0.944$. Интерпретация: при неизменной цене дополнительный миллион рекламы даёт в среднем $+3.19$ продаж (а не 4.22: простая регрессия «приписывала» рекламе часть эффекта цены, так как в недели с большей рекламой цену снижали, $r(x_1, x_2) = -0.95$); при неизменной рекламе рост цены на единицу снижает продажи на 2.29. Оба коэффициента значимы ($p = 0.00003$ и $p = 0.014$). Прогноз для $x_1 = 6$, $x_2 = 10$: 37.2.

ЗАПОМНИТЕ

R^2 при добавлении переменных не убывает, поэтому для сравнения моделей используют $R^2_{\text{adj}} = 1 - \dfrac{SSE/(n-k-1)}{SST/(n-1)}$. Сильная корреляция между объясняющими переменными (*мультиколлинеарность*) делает оценки неустойчивыми: большие SE и «прыгающие» коэффициенты. Категориальные факторы вводят через индикаторы (0/1): коэффициент при индикаторе — разница средних между категорией и базовой при прочих равных.

6 Ключевые термины

Термин	*English*	Смысл
Стандартная ошибка наклона	$\mathrm{SE}(b_1)$	$s_e/\sqrt{S_{xx}}$
t-тест наклона	*Slope t-test*	$t = b_1/\mathrm{SE}(b_1)$, $n-2$ ст. св.
Интервал предсказания	*Prediction interval*	для нового наблюдения
Доверительный интервал отклика	*CI for mean response*	для среднего y при x_0
Искажающая переменная	*Confounder*	связана и с x, и с y
Парадокс Симпсона	*Simpson's paradox*	связь меняет знак внутри групп
Множественная регрессия	*Multiple regression*	несколько предикторов
Мультиколлинеарность	*Multicollinearity*	сильная связь между предикторами

Формулы лекции 13

$$\mathrm{SE}(b_1) = \frac{s_e}{\sqrt{S_{xx}}}, \quad t = \frac{b_1}{\mathrm{SE}(b_1)}\ (\nu = n-2), \quad b_1 \pm t_{\alpha/2}\,\mathrm{SE}(b_1); \quad F = \frac{SSR/1}{SSE/(n-2)} = t^2;$$

$$\hat{y}_0 \pm t_{\alpha/2} s_e \sqrt{\tfrac{1}{n} + \tfrac{(x_0-\bar{x})^2}{S_{xx}}}\ \text{(среднее)}; \qquad \hat{y}_0 \pm t_{\alpha/2} s_e \sqrt{1 + \tfrac{1}{n} + \tfrac{(x_0-\bar{x})^2}{S_{xx}}}\ \text{(индивидуальное)}.$$

7 Задачи для самостоятельного решения

Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] В регрессии по $n = 27$ наблюдениям $b_1 = 2.4$, $\mathrm{SE}(b_1) = 0.6$. Проверьте $H_0 : \beta_1 = 0$ ($\alpha = 0.05$) и постройте 95% ДИ для β_1.

Задача 2 [A] Выборочная корреляция $r = 0.45$ по $n = 30$. Проверьте $H_0 : \rho = 0$ с помощью $t = r\sqrt{n-2}/\sqrt{1-r^2}$ ($\alpha = 0.05$).

Задача 3 [A] Для каждого утверждения укажите вероятную скрытую переменную или альтернативное объяснение: (а) в городах с большим числом церквей больше преступлений; (б) сотрудники, прошедшие больше обучений, получают больше; (в) фирмы с высокой рекламой имеют большую прибыль.

Задача 4 [B] Данные о подготовке: $x = 1, 2, 3, 4, 5$, $y = 50, 55, 65, 70, 85$ (лекция 12): $b_1 = 8.5$, $s_e = 3.03$, $S_{xx} = 10$.

(а) Найдите $\mathrm{SE}(b_1)$ и проверьте значимость наклона.
(б) Постройте 95% ДИ для β_1.
(в) Проверьте $H_0 : \beta_1 = 5$ против $H_1 : \beta_1 \neq 5$.

Задача 5 [B] Для данных предыдущей задачи найдите при $x_0 = 4.5$ часа 95% ДИ для среднего балла и 95% интервал предсказания для нового студента. Объясните разницу.

Задача 6 [B] Данные о квартирах (лекция 12): $\hat{y} = 5.79 + 0.776x$, $s_e = 1.576$, $n = 5$, $S_{xx} = 2320$, $\bar{x} = 66$.

(а) Проверьте значимость наклона и постройте 95% ДИ.
(б) Найдите 95% ДИ для средней цены квартир по 70 м^2 и интервал предсказания для цены конкретной квартиры 70 м^2.

Задача 7 [B] В выводе регрессии по $n = 27$ наблюдениям известно: $SSR = 160$, $SSE = 90$, $b_1 = 2.4$.

(а) Заполните таблицу ANOVA (ν, MS, F).
(б) Найдите R^2 и s_e.
(в) Найдите t-статистику наклона и $\mathrm{SE}(b_1)$.

Задача 8 [B] Кредитные заявки подаются в двух филиалах. Одобрено: филиал X — малые кредиты $18/20$, крупные $24/80$; филиал Y — малые $68/80$, крупные $5/20$. Найдите доли одобрения по группам и в целом. Какой филиал «лучше»? Объясните парадокс.

Задача 9 [B] Интернет-магазин ввёл бесплатную доставку для части клиентов, выбрав тех, кто чаще заказывает. Через месяц их средний чек вырос на 12% относительно остальных. Можно ли сказать, что бесплатная доставка увеличила чек? Как организовать исследование, чтобы сделать причинный вывод?

Задача 10 [B] Модель недельных продаж: $\hat{y} = 20 + 3x_1 - 1.5x_2$ (x_1 — реклама, x_2 — цена); $n = 20$, $R^2 = 0.80$.

(а) Интерпретируйте коэффициенты.
(б) Найдите прогноз при $x_1 = 8$, $x_2 = 10$.
(в) Найдите R^2_{adj}.

Задача 11 [C] Выведите $\mathrm{Var}(b_1) = \sigma^2/S_{xx}$, используя представление $b_1 = \sum c_i y_i$, где $c_i = (x_i - \bar{x})/S_{xx}$, а y_i независимы с дисперсией σ^2.

Задача 12 [C] Покажите, что $\mathrm{Var}(\hat{y}_0) = \sigma^2\left(\frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}\right)$ и объясните, откуда берётся «$1+$» в интервале предсказания.

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 14

Проектный практикум: от вопроса к выводу

Как провести небольшое статистическое исследование, выбрать метод, оформить результат и сделать работу воспроизводимой

Тема 14 по силлабусу · неделя 14 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- выстроить исследование по этапам: вопрос → данные → описание → метод → проверка условий → вывод → отчёт;
- выбирать метод по типу вопроса и данных и планировать объём выборки;
- оформлять результаты: таблица, график, оценка эффекта с доверительным интервалом, формулировка вывода;
- обеспечивать воспроизводимость (данные, формулы, код) и избегать «подгонки» результатов (p-hacking);
- ответственно использовать инструменты ИИ при анализе данных: проверять, а не принимать на веру.

1 Этапы статистического исследования

1. **Вопрос.** Формулируется до анализа и должен быть проверяемым: «Различается ли среднемесячный расход клиентов мобильного приложения и отделений?» Для каждого вопроса зафиксируйте единицу наблюдения, совокупность, переменные.
2. **Данные.** Откуда они, как собраны (случайная выборка, эксперимент, наблюдения), сколько пропусков, какие единицы измерения. От способа сбора зависит, какие выводы допустимы (лекции 7 и 13).
3. **Очистка и описание.** Проверка ошибок ввода, дубликатов, выбросов; описательная статистика и графики (лекция 1). Выбросы не удаляют автоматически: выясняют причину и показывают результаты с ними и без них.
4. **Метод.** Выбор по типу вопроса (раздел 2).
5. **Проверка условий.** Независимость, нормальность или большой n, равенство дисперсий, линейность и т.д.
6. **Вывод.** Оценка эффекта, ДИ, p-значение, практическая значимость, ограничения.
7. **Отчёт.** Короткий, точный текст с таблицей/графиком и честными оговорками.

2 Выбор метода

Вопрос	Данные	Метод
Каково среднее / доля?	1 количественная / 1 категориальная	ДИ (t или z), одновыборочный тест
Различаются ли 2 группы?	количественная, 2 независимые группы	тест Уэлча + ДИ разности + размер эффекта
Изменилось ли после воздействия?	пары измерений	парный t-тест
Различаются ли доли?	категориальная, 2 группы	z-тест для двух долей
Есть ли связь категорий?	две категориальные	χ^2-тест независимости, V Крамера
Различаются ли ≥ 3 групп?	количественная, k групп	ANOVA и парные сравнения с поправкой
Как y зависит от x?	две количественные	регрессия: b_1, ДИ, R^2, остатки
Нужен прогноз для нового объекта?	регрессия	интервал предсказания

3 Разбор мини-проекта

Вопрос. Различается ли ежемесячный расход клиента (млн сум) между пользователями мобильного приложения и клиентами, обслуживаемыми в отделениях? Данные: случайная выборка клиентов одного банка за один месяц, 12 клиентов приложения и 10 клиентов отделений. Для пользователей приложения известен стаж клиента (годы).

Приложение	1	2	3	4	5	6	7	8	9	10	11	12
Расход	4.2	5.1	3.8	6.0	4.9	5.5	4.4	5.8	6.3	4.7	5.2	5.0
Стаж	1	2	1	4	3	3	2	4	5	2	3	3

Отделение	1	2	3	4	5	6	7	8	9	10
Расход	3.9	4.1	3.5	4.8	5.2	3.7	4.0	4.6	3.3	4.4

Описание. Приложение: $n = 12$, $\bar{x} = 5.075$, медиана 5.05, $s = 0.745$, диапазон 3.8–6.3. Отделение: $n = 10$, $\bar{x} = 4.150$, медиана 4.05, $s = 0.599$, диапазон 3.3–5.2. Выбросов нет, распределения симметричны, значения близки по разбросу ($s_1/s_2 = 1.24 < 2$). Малый объём выборок ($n < 30$) требует приблизительной нормальности, что при отсутствии выбросов и асимметрии допустимо.

Метод и результат. Двухвыборочный тест Уэлча ($H_0 : \mu_1 = \mu_2$). Разность 0.925 млн, SE $= 0.286$, $t = 3.23$, $\nu \approx 20.0$, $p = 0.0042$. 95% ДИ разности: $(0.33;\ 1.52)$ млн. Размер эффекта (d Коэна) $= \dfrac{0.925}{s_p} = \dfrac{0.925}{0.683} = 1.35$ — большой. 95% ДИ для среднего расхода: приложение $(4.60;\ 5.55)$, отделение $(3.72;\ 4.58)$.

Регрессия внутри группы приложения. Расход y на стаж x: $\hat{y} = 3.48 + 0.580\,x$, SE$(b_1) = 0.0626$, $t = 9.27$, $p < 0.001$, $R^2 = 0.896$, $s_e = 0.252$. 95% ДИ наклона $(0.44;\ 0.72)$: каждый год стажа связан с ростом среднего расхода на 0.44–0.72 млн.

Формулировка вывода (пример хорошего абзаца).

ЗАПОМНИТЕ

«Среди 22 клиентов банка средний месячный расход пользователей приложения (5.08 млн сум, $s = 0.74$, $n = 12$) выше, чем клиентов отделений (4.15, $s = 0.60$, $n = 10$). Разность составила 0.93 млн сум (95% ДИ от 0.33 до 1.52; тест Уэлча, $t(20.0) = 3.23$, $p = 0.004$). Эффект большой ($d = 1.35$). Поскольку клиенты не распределялись между каналами случайно, различие нельзя трактовать как влияние самого приложения: оно может отражать различия в составе клиентов (например, в стаже и доходе). Выборка мала, поэтому результат нужно подтвердить на большем объёме данных.»

4 Как сообщать результаты

- Сначала ответ на вопрос, затем число с единицами и ДИ, затем оговорки. Не заставляйте читателя искать вывод.
- Приводите *размер эффекта* и ДИ, а не только p-значение; p округляйте разумно ($p = 0.004$; $p < 0.001$), а не «$p = 0.0000$».
- Различайте *статистическую* и *практическую* значимость; интерпретируйте в единицах задачи.
- Не пишите «доказано» и «принимается H_0»: говорите «данные согласуются с…» / «недостаточно доказательств…».
- График: подписанные оси с единицами, начало оси y для столбцов — ноль, без избыточных эффектов; для малых выборок показывайте сами точки.
- Для таблицы: не более 3 значащих цифр, пояснение условных обозначений.
- Указывайте число наблюдений, способ отбора, пропуски и ограничения (причинность, репрезентативность).

4.1 Типичные нарушения

Выбор теста после просмотра результатов; повторные тесты до получения $p < 0.05$ (p-hacking); удаление «неудобных» наблюдений без обоснования; игнорирование множественных сравнений (20 тестов дают 64% шанс ложного открытия); интерпретация корреляции как причинности; отчёт только о «значимых» результатах (publication bias); применение метода без проверки условий.

5 Планирование: объём выборки для сравнения двух долей

Для $\alpha = 0.05$ (двусторонний) и мощности 80% число наблюдений *в каждой группе*

$$n \approx \frac{(z_{\alpha/2} + z_{\beta})^2 \left[p_1(1-p_1) + p_2(1-p_2)\right]}{(p_1 - p_2)^2}, \qquad (z_{\alpha/2} + z_{\beta})^2 = (1.96 + 0.8416)^2 = 7.85. \quad (5.1)$$

Для обнаружения роста конверсии с 10% до 12%: $n \approx 7.85 \cdot (0.09 + 0.1056)/0.0004 = 3838$ в группе. Малые эффекты требуют очень больших выборок: поэтому важно заранее определить минимальный практически значимый эффект.

6 Воспроизводимость

Результат воспроизводим, если другой человек получит те же числа из ваших данных и описания. Практика: хранить исходные данные неизменными, а очищенные — отдельно; все преобразования записывать формулами/скриптом, а не ручными правками; фиксировать версии файлов; для случайных процедур указывать зерно генератора; комментировать, что делает каждый шаг.

Задача	Excel	Python (scipy)
Среднее, s	`AVERAGE`, `STDEV.S`	`x.mean()`, `x.std(ddof=1)`
$P(Z < z)$	`NORM.S.DIST(z,TRUE)`	`norm.cdf(z)`
Критическое t	`T.INV.2T(0.05,df)`	`t.ppf(0.975,df)`
Тест Уэлча	`T.TEST(A,B,2,3)`	`ttest_ind(a,b,equal_var=False)`
Парный тест	`T.TEST(A,B,2,1)`	`ttest_rel(a,b)`
χ^2-тест	`CHISQ.TEST(obs,exp)`	`chi2_contingency(obs)`
ANOVA	Анализ данных → ANOVA	`f_oneway(g1,g2,g3)`
Регрессия	`LINEST`, Анализ данных	`linregress(x,y)`

7 Ответственное использование ИИ

Языковые модели и другие инструменты ИИ могут объяснять методы, помогать писать код и формулы, предлагать структуру отчёта. Но:

- **Проверяйте числа.** Модель может ошибиться в арифметике и выдумать значения таблиц; пересчитайте ключевые результаты независимо (калькулятор, Excel, код) и сверьте с таблицами.
- **Проверяйте метод.** Убедитесь, что тест подходит данным и условия выполнены; ИИ часто выбирает «стандартный» метод, не глядя на структуру данных (парные выборки как независимые!).
- **Не придумывайте данные и источники.** Любые данные должны быть реальными или явно помечены как учебные/смоделированные.
- **Защищайте персональные и коммерчески чувствительные данные:** не загружайте их во внешние сервисы без разрешения; агрегируйте и обезличивайте.
- **Указывайте использование ИИ** в соответствии с правилами вашей организации; ответственность за вывод несёте вы.
- **Не заменяйте понимание.** Если вы не можете объяснить, почему выбран метод и что означает результат, отчёт готов не будет.

8 Ключевые термины

Термин	*English*	Смысл
Размер эффекта	*Effect size*	разность/ d Коэна $= \Delta / s_p$
Воспроизводимость	*Reproducibility*	те же данные и код дают те же числа
p**-hacking**	*p-hacking*	подбор анализа до значимого p
Множественные сравнения	*Multiple comparisons*	рост ошибки I рода при многих тестах
Репрезентативность	*Representativeness*	выборка отражает совокупность

Формулы лекции 14

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p}, \quad s_p = \sqrt{\frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-2}}; \qquad n_{\text{гр}} \approx \frac{(z_{\alpha/2}+z_{\beta})^2[p_1(1-p_1)+p_2(1-p_2)]}{(p_1-p_2)^2};$$

Бонферрони: $\alpha^* = \alpha/m$; $\qquad P(\text{хотя бы одна ложная тревога}) = 1-(1-\alpha)^m$.

9 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Для проекта «Что влияет на сумму кредита?» классифицируйте переменные и предложите по одному графику: (а) сумма кредита; (б) тип кредита (потребительский / ипотека / авто); (в) стаж работы заёмщика; (г) регион; (д) сумма кредита против стажа.

Задача 2 [A] Выберите метод: (а) изменилось ли среднее время обработки заявки после внедрения новой системы (у тех же 30 сотрудников); (б) связаны ли пол клиента и выбранный тип карты; (в) различаются ли средние оценки сервиса в 4 филиалах; (г) на сколько растёт расход при росте дохода на 1 млн; (д) различаются ли доли просрочки у двух схем кредитования.

Задача 3 [A] Используя данные разбора мини-проекта (отделение: $n = 10$, $\bar{x} = 4.15$, $s = 0.599$), постройте 95% ДИ для среднего расхода клиентов отделений.

Задача 4 [B] Две выборки клиентов: группа 1: $n = 40$, $\bar{x} = 52$, $s = 10$; группа 2: $n = 45$, $\bar{x} = 47$, $s = 12$.

(а) Найдите d Коэна.
(б) Проведите тест Уэлча и постройте 95% ДИ разности.
(в) Согласуются ли «статистическая» и «практическая» значимость? Как сформулировать вывод?

Задача 5 [B] Найдите недостатки в отчёте: «Мы опросили 15 клиентов, выбранных менеджером из тех, кто согласился ответить. Средняя оценка 4.5 из 5. Тест показал $p = 0.00$, значит наш сервис безусловно лучший в отрасли, и новая программа лояльности **доказала** рост удовлетворённости. Выбросы (две оценки 1) были удалены.»

Задача 6 [B] Аналитик разбил клиентов на 20 подгрупп (по возрасту, региону, каналу и т.п.) и для каждой проверил, отличается ли средний чек от среднего по банку ($\alpha = 0.05$). В 2 подгруппах $p < 0.05$, и он опубликовал только их.

(а) Какова вероятность хотя бы одной «значимой» подгруппы, если на самом деле различий нет (тесты независимы)?
(б) Какой порог p при поправке Бонферрони? Как правильно сообщить результаты?

Задача 7 [B] Данные расходов в столбцах A (приложение, A2:A13) и B (отделение, B2:B11). Напишите формулы Excel для: (а) среднего и s по столбцу A; (б) p-значения теста Уэлча; (в) критического t для 95% ДИ среднего по A; (г) $P(Z < 1.5)$. Каков результат (б)?

Задача 8 [B] Для пилотной выборки $s = 0.745$. Какой объём выборки нужен, чтобы 95% ДИ среднего расхода имел предельную ошибку $E = 0.2$ млн сум?

Задача 9 [B] Регрессия расхода на стаж (приложение): $\hat{y} = 3.48 + 0.580x$, $\text{SE}(b_1) = 0.0626$, $n = 12$, стаж наблюдался от 1 до 5 лет.

(а) Постройте 95% ДИ для β_1.
(б) Спрогнозируйте средний расход при стаже 3 года. Можно ли прогнозировать при стаже 10 лет?
(в) Означает ли $b_1 > 0$, что стаж увеличивает расход?

Задача 10 [B] В данных приложения клиент 9 имел расход 6.3. Допустим, при вводе ошибочно записали 14.5. Пересчитайте среднее, s и тест Уэлча (отделение без изменений). Сравните с исходным результатом и сформулируйте, что нужно сделать с таким значением.

Задача 11 [C] ИИ-ассистент сообщил для данных мини-проекта: «$t = 2.90$, $\nu = 22$, $p = 0.008$, разность средних значима». Как проверить это утверждение? Что неверно?

Задача 12 [C] Для A/B-теста конверсии базовая доля 30%; нужно обнаружить рост до 35% ($\alpha = 0.05$, мощность 80%). (а) Найдите n в группе. (б) Что будет, если требуется обнаружить рост до 32%? (в) Почему результат важно планировать заранее?

STAT201 · СТАТИСТИКА · ЛЕКЦИЯ 15

Итоговое повторение и подготовка к экзамену

Сводка курса, сводная таблица методов, лист формул и пробный экзаменационный вариант

Тема 15 по силлабусу · неделя 15 · 4 академических часа

ЦЕЛИ ЛЕКЦИИ

- связать темы курса в одну цепочку: данные → вероятность → распределения → выборка → оценивание → проверка гипотез → регрессия;
- быстро выбирать метод и формулу по условию задачи;
- пользоваться таблицами z, t, χ^2, F (приложение «Статистические таблицы»);
- решить пробный экзамен в формате итогового контроля и самостоятельно оценить свою подготовку.

1 Сквозная логика курса

Весь курс отвечает на один вопрос: *как принимать обоснованные решения в условиях неопределённости*. Основные звенья:

1. **Описание данных** (лекция 1): центр, разброс, форма, выбросы, связь двух переменных.
2. **Вероятность** (2–3): события, правила сложения и умножения, условная вероятность, теорема Байеса.
3. **Случайные величины** (4–6): ожидание и дисперсия, биномиальное, пуассоновское, нормальное и другие распределения, ковариация и корреляция.
4. **Связь выборки и совокупности** (7–8): выборочное распределение, стандартная ошибка, ЦПТ.
5. **Статистический вывод** (9–11): ДИ и проверка гипотез для среднего, доли, разности, категорий и нескольких групп.
6. **Модели** (12–13): регрессия, вывод, причинность.
7. **Практика** (14): исследование, отчёт, воспроизводимость, ответственное использование ИИ.

Общий шаблон вывода везде один: $\dfrac{\text{оценка} - \text{значение при } H_0}{\text{SE}}$ сравнивается с нормальным или t-распределением. Умение находить правильную SE и правильное число степеней свободы — ядро курса.

2 Сводная таблица стандартных ошибок и критериев

Параметр	Стандартная ошибка	Распределение	Степени свободы
μ (σ известна)	$\sigma/\sqrt{n}$	$N(0,1)$	—
μ (σ неизвестна)	$s/\sqrt{n}$	t	$n-1$
p	$\sqrt{p_0(1-p_0)/n}$ (тест); $\sqrt{\hat{p}(1-\hat{p})/n}$ (ДИ)	$N(0,1)$	—
$\mu_1-\mu_2$ (независ.)	$\sqrt{s_1^2/n_1+s_2^2/n_2}$	t (Уэлч)	формула Уэлча
μ_d (пары)	$s_d/\sqrt{n}$	t	$n-1$
p_1-p_2	$\sqrt{\hat{p}(1-\hat{p})(\frac{1}{n_1}+\frac{1}{n_2})}$ (тест)	$N(0,1)$	—
β_1	$s_e/\sqrt{S_{xx}}$	t	$n-2$
Таблица $r\times c$	$\sum(O-E)^2/E$	χ^2	$(r-1)(c-1)$
k средних	$F=MSB/MSW$	F	$k-1$; $N-k$

3 Лист формул курса

Описание данных и вероятность

$$\bar{x}=\tfrac{1}{n}\sum x_i,\quad s^2=\tfrac{1}{n-1}\sum(x_i-\bar{x})^2,\quad CV=\tfrac{s}{\bar{x}},\quad IQR=Q_3-Q_1;$$

границы выбросов: $Q_1-1.5\,IQR$ и $Q_3+1.5\,IQR$;

$$P(A\cup B)=P(A)+P(B)-P(A\cap B);\quad P(A\cap B)=P(A)P(B\mid A);$$

$$P(A\mid B)=\tfrac{P(A\cap B)}{P(B)};\quad C_n^k=\tfrac{n!}{k!(n-k)!};\quad P(A_i\mid B)=\tfrac{P(B|A_i)P(A_i)}{\sum_j P(B|A_j)P(A_j)};$$

шансы: $\text{odds}_{\text{post}}=\text{odds}_{\text{prior}}\cdot LR$.

Случайные величины и распределения

$$\mu=\sum xp(x),\quad \sigma^2=\sum x^2p(x)-\mu^2;\quad \mathrm{E}[aX+b]=a\mu+b,\quad \mathrm{Var}(aX+b)=a^2\sigma^2;$$

$$\mathrm{Bin}(n,p):\ \mu=np,\ \sigma^2=np(1-p);\qquad \mathrm{Pois}(\lambda):\ \mu=\sigma^2=\lambda;$$

$$\mathrm{Exp}(\lambda):\ \mu=\tfrac{1}{\lambda};\qquad U(a,b):\ \mu=\tfrac{a+b}{2},\ \sigma^2=\tfrac{(b-a)^2}{12};$$

$$z=\tfrac{x-\mu}{\sigma};\quad \mathrm{Cov}(X,Y)=\mathrm{E}[XY]-\mu_X\mu_Y;\quad \rho=\tfrac{\mathrm{Cov}}{\sigma_X\sigma_Y};$$

$$\mathrm{Var}(X\pm Y)=\mathrm{Var}\,X+\mathrm{Var}\,Y\pm 2\,\mathrm{Cov}\,.$$

Выводы и регрессия

$$\mathrm{SE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}; \quad \bar{x} \pm t_{\alpha/2,n-1}\frac{s}{\sqrt{n}}; \quad \hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}};$$

$$n \geq \left(\frac{z\sigma}{E}\right)^2; \quad n \geq \frac{z^2 p(1-p)}{E^2};$$

$$t = \frac{\bar{x}-\mu_0}{s/\sqrt{n}}; \quad z = \frac{\hat{p}-p_0}{\sqrt{p_0(1-p_0)/n}}; \quad t = \frac{\bar{x}_1-\bar{x}_2}{\sqrt{s_1^2/n_1+s_2^2/n_2}}; \quad t = \frac{\bar{d}}{s_d/\sqrt{n}};$$

$$\chi^2 = \sum \frac{(O-E)^2}{E}; \quad F = \frac{SSB/(k-1)}{SSW/(N-k)};$$

$$b_1 = \frac{S_{xy}}{S_{xx}} = r\frac{s_y}{s_x}; \quad b_0 = \bar{y} - b_1\bar{x}; \quad R^2 = \frac{SSR}{SST}; \quad s_e = \sqrt{\frac{SSE}{n-2}}; \quad \mathrm{SE}(b_1) = \frac{s_e}{\sqrt{S_{xx}}};$$

$$\hat{y}_0 \pm t\, s_e\sqrt{1 + \frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}}.$$

4 Типичные ошибки на экзамене

- Перепутаны $\sigma/\sqrt{n}$ (среднее), $\sigma\sqrt{n}$ (сумма) и σ (одно наблюдение).
- Не проверены условия применимости (нормальное приближение, независимость, $n \geq 30$, ожидаемые частоты ≥ 5).
- z вместо t при неизвестной σ и малом n; неверное число степеней свободы.
- Неправильное направление альтернативы и неверное p-значение (удвоение для двустороннего).
- Интерпретация ДИ и p-значения как «вероятности гипотезы»; вывод «доказали H_0».
- Парные данные анализируют как независимые, и наоборот.
- Экстраполяция регрессии; причинные выводы из корреляции.
- Отсутствие единиц измерения и словесной интерпретации в ответе.

5 Как готовиться и как решать экзамен

1. Решите пробный вариант (ниже) за 120 минут без подсказок, затем сверьтесь с решениями и разберите каждую ошибку: к какой теме она относится.
2. Составьте собственный «лист формул» на одной странице (даже если разрешены таблицы), это лучший способ запомнить формулы.
3. На экзамене: прочитайте все задачи; начните с тех, что умеете делать; в каждой — «дано / найти / метод / вычисление / вывод словами».
4. Контролируйте разумность: вероятность в $[0, 1]$, дисперсия ≥ 0, $|r| \leq 1$, ДИ симметричен вокруг оценки, p согласовано с решением и ДИ.
5. Округляйте только в конце; промежуточные значения держите с 4–5 знаками.

6 Ключевые термины курса

Термин	*English*	Смысл
Выборочное распределение	*Sampling distribution*	распределение статистики
Стандартная ошибка	*Standard error*	SD статистики
Доверительный интервал	*Confidence interval*	оценка $\pm$ критич.$\times$SE
p-значение	*p-value*	$P(\text{не менее экстремальное} \mid H_0)$
Мощность	*Power*	$1-\beta$
Остаток	*Residual*	$y-\hat{y}$
Искажающая переменная	*Confounder*	связана с x и y

7 Задачи для самостоятельного решения

> Уровень задачи в квадратных скобках: **[A]** — базовая, проверяет понимание определений; **[B]** — стандартная расчётная; **[C]** — повышенная, требует вывода или интерпретации. Десятичные дроби пишем через точку, как в калькуляторе, Excel и R. Если задача требует таблиц, используйте приложение «Статистические таблицы».

Задача 1 [A] Месячные продажи (млн сум) восьми менеджеров: $14,\ 18,\ 20,\ 22,\ 25,\ 27,\ 31,\ 63$.

(а) Найдите среднее, медиану и стандартное отклонение.
(б) Найдите Q_1, Q_3, IQR и границы выбросов. Есть ли выбросы?
(в) Какая мера центра предпочтительнее и почему? Как изменится среднее без наибольшего значения?

Задача 2 [B] Доля заёмщиков с дефолтом 4%. Скоринг помечает как «рискованных» 80% будущих дефолтеров и 10% надёжных заёмщиков. Заёмщик помечен. Какова вероятность того, что он станет дефолтером? Какой станет вероятность, если заёмщика пометили два независимых скоринга с такими же характеристиками?

Задача 3 [B] Клиент принимает предложение с вероятностью 0.25 независимо от других; предложение сделано 12 клиентам.

(а) Найдите ожидаемое число принявших и стандартное отклонение.
(б) Найдите вероятность того, что приняли не менее 5.
(в) Найдите вероятность того, что приняли ровно 3.

Задача 4 [A] Баллы теста $X \sim N(65, 8^2)$. Найдите $P(X > 75)$, $P(60 < X < 70)$ и 85-й процентиль.

Задача 5 [B] Число покупок на клиента: $\mu = 2.5$, $\sigma = 1.2$. Выборка $n = 64$ клиентов. Найдите $\text{SE}(\bar{X})$ и $P(\bar{X} > 2.7)$. Объясните, почему можно использовать нормальное распределение.

Задача 6 [B] Выборка из 20 клиентов: $\bar{x} = 48$ мин, $s = 9$. (а) Постройте 95% ДИ для среднего. (б) Проверьте $H_0 : \mu = 45$ против $H_1 : \mu \neq 45$ ($\alpha = 0.05$). (в) Согласуются ли результаты (а) и (б)?

Задача 7 [B] В выборке 250 клиентов приложением пользуются 62%. (а) Постройте 95% ДИ для доли. (б) Сколько клиентов нужно опросить, чтобы предельная ошибка составила 4 п.п. (при неизвестной доле)?

Задача 8 [B] Время обработки (мин) у 7 сотрудников до и после внедрения новой системы: до $30, 28, 35, 40, 25, 33, 38$; после $27, 26, 33, 36, 25, 30, 35$. Проверьте, сократилась ли обработка (двусторонний тест, $\alpha = 0.05$), и постройте 95% ДИ среднего изменения.

Задача 9 [B] Опрос 350 клиентов: возрастная группа и использование приложения.

	Используют	Не используют
До 30 лет	60	40
30–45 лет	50	70
Старше 45 лет	40	90

Проверьте независимость ($\alpha = 0.05$). Какая группа вносит основной вклад в χ^2?

Задача 10 [B] ANOVA для 4 групп по 5 наблюдений: $SSB = 84$, $SSW = 160$. Заполните таблицу и сделайте вывод ($\alpha = 0.05$).

Задача 11 [B] По $n = 10$ наблюдениям: $\bar{x} = 20$, $\bar{y} = 50$, $S_{xx} = 400$, $S_{xy} = 600$, $S_{yy} = 1200$.

(а) Найдите уравнение регрессии, R^2, s_e.
(б) Проверьте значимость наклона и постройте 95% ДИ для β_1.
(в) Спрогнозируйте y при $x = 25$ и постройте 95% интервал предсказания.

Задача 12 [C] Исследователь обнаружил положительную значимую связь между числом проведённых в банке тренингов и средним доходом клиентов региона ($r = 0.62$, $p < 0.01$) и предложил увеличить число тренингов, чтобы повысить доход. Дайте критическую оценку вывода и предложите, как проверить причинность.

Задача 13 [C] Менеджер хочет узнать, различается ли удовлетворённость клиентов (оценка 1–5) в трёх филиалах, и выбирает: «провести три парных t-теста A–B, A–C, B–C на уровне 0.05». Почему это неправильно? Что предложить? Какое значение α надо использовать для каждого парного сравнения при поправке Бонферрони?

Задача 14 [C] Выполните мини-анализ. В данных 200 клиентов средний расход $\bar{x} = 4.8$ млн, $s = 1.5$. (а) Постройте 95% ДИ среднего. (б) Банк утверждает, что $\mu = 5$. Проверьте. (в) Какой размер эффекта $d = (\bar{x} - \mu_0)/s$? (г) Достаточен ли $n = 200$ для обнаружения отклонения 0.2 млн с мощностью 80%?